Automated Nociceptive Pain Assessment Using Physiological Signals and a Hybrid Deep Learning Network

การประเมินความเจ็บปวดอัตโนมัติจากสัญญาณทางสรีรวิทยาโดยใช้เครือข่ายการเรียนรู้เชิงลึกแบบไฮบริด

บทคัดย่อ

การจัดการความเจ็บปวดหลังผ่าตัดเป็นความท้าทายทางการแพทย์และการพยาบาล ในปัจจุบันโรงพยาบาลใช้มาตรการวัดความเจ็บปวดเฉียบพลันด้วยการรายงานจากผู้ป่วยเอง เช่น มาตรวัดความเจ็บปวดแบบ Visual Analogue Scale และ Numeric Pain Intensity Scale แต่วิธีการเหล่านี้ขาดความแม่นยำเนื่องจากขึ้นอยู่กับการรายงานจากผู้ป่วยแต่ละราย จึงมีความต้องการวิธีที่เป็นระบบเชิงวัตถุและเชิงปริมาณเพื่อใช้ในการติดตามความเจ็บปวดอย่างต่อเนื่อง งานวิจัยนี้ได้นำเสนอระบบตรวจวัดความเจ็บปวดเฉียบพลันอัตโนมัติโดยใช้สัญญาณทางสรีรวิทยาและเครือข่ายการเรียนรู้เชิงลึกแบบไฮบริด ซึ่งเครือข่ายนี้ประกอบด้วยเครือข่าย CNN ที่ช่วยสกัดข้อมูลสำคัญจากสัญญาณสรีรวิทยาและส่งไปยังเครือข่าย LSTM เพื่อประมวลผลเพิ่มเติม กระบวนการนี้ช่วยให้สามารถจับคู่ข้อมูลความเจ็บปวดจากข้อมูลสัญญาณได้โดยตรง

งานวิจัยนี้ได้ใช้ฐานข้อมูล BioVid Heat Pain เพื่อศึกษาประสิทธิภาพของเครือข่ายแบบไฮบริด CNN_LSTM ในการจำแนกระดับความเจ็บปวด โดยทำการทดลองใน 3 รูปแบบ คือ การใช้สัญญาณ ECG อย่างเดียว การใช้สัญญาณ EDA อย่างเดียว และการใช้ทั้งสัญญาณ ECG และ EDA ร่วมกัน ผลการทดลองพบว่า เมื่อใช้เฉพาะสัญญาณ ECG เครือข่ายสามารถจำแนกความแตกต่างระหว่าง BL1 กับ PA1 ได้ที่ความแม่นยำ 68.70% ระหว่าง BL1 กับ PA2 ที่ 62.61% ระหว่าง BL1 กับ PA3 ที่ 67.86% และระหว่าง BL1 กับ PA4 ที่ 75.21% ในขณะที่การใช้เฉพาะสัญญาณ EDA ให้ผลลัพธ์ที่ดีกว่า โดยสามารถจำแนกความแตกต่างได้ที่ 85.65% สำหรับ BL1 กับ PA1, 74.47% สำหรับ BL1 กับ PA2, 80.80% สำหรับ BL1 กับ PA3 และ 80.17% สำหรับ BL1 กับ PA4 และการใช้ทั้งสัญญาณ ECG และ EDA ร่วมกันในเครือข่ายแบบไฮบริดให้ผลลัพธ์ที่ดีที่สุด โดยสามารถจำแนกความแตกต่างได้ที่ 93.91% สำหรับ BL1 กับ PA1, 86.97% สำหรับ BL1 กับ PA2, 90.75% สำหรับ BL1 กับ PA3 และสูงสุดที่ 94.12% สำหรับ BL1 กับ PA4

บทนำ

ความเจ็บปวดเป็นเหตุผลหลักที่ทำให้บุคคลไปพบแพทย์ คำว่า “ความเจ็บปวด” เป็นสิ่งที่ทุกคนเรียนรู้จากประสบการณ์ ในงานวิจัยแสดงให้เห็นว่าผู้ป่วยกว่า 52.2% ตอบว่าความเจ็บปวดเป็นปัญหาสำคัญ โดยมีเพียง 34.1% เท่านั้นที่บ่นถึงปัญหาอื่น ๆ งานวิจัยอีกยังสรุปว่าประมาณ 35% ของผู้ป่วยในโรงพยาบาลมีความเจ็บปวดเฉียบพลันรุนแรง และประมาณ 50% มีความเจ็บปวดระดับปานกลาง หากความเจ็บปวดไม่ได้รับการรักษาในเวลาที่เหมาะสม จะมีกระทบต่อชีวิตประจำวัน และอาจส่งผลต่อระบบภูมิคุ้มกัน ระบบ

ประสาท และระบบต่อมไร้ท่อความเจ็บปวดอาจได้รับผลกระทบจากปัจจัยต่าง ๆ เช่น เพศ สถานะทางร่างกาย พฤติกรรม สถานะทางอารมณ์ ประวัติการเจ็บปวด และความบกพร่องทางสติปัญญา ดังนั้นจึงควรมีการออกแบบโมเดลการประเมินความเจ็บปวดที่เหมาะสม [3] ประสบการณ์ความเจ็บปวดของแต่ละบุคคลสามารถวินิจฉัยได้จากสาเหตุของความเจ็บปวด เช่น จากการสื่อสารและการประเมินความเจ็บปวดจากผู้ดูแล ซึ่งจากหลายกรณีในการหาสาเหตุและการตอบสนองต่อความเจ็บปวดสามารถระบุได้ง่าย แต่บางครั้งก็ยากที่จะประเมินได้อย่างแม่นยำ ดังนั้นการประเมินความเจ็บปวดจึงต้องทำอย่างเหมาะสมเพื่อระบุความเจ็บปวดเฉียบพลัน

เพื่อจัดการความเจ็บปวดในโรงพยาบาล แนวคิดของดูแลความเจ็บปวดเฉียบพลัน (Acute Pain Services หรือ APS) ได้ถูกนำมาใช้ APS มุ่งเน้นไปที่การดูแลจากผู้เชี่ยวชาญด้านสุขภาพในการประเมิน ติดตาม และรักษาความเจ็บปวดในห้อง ICU รวมถึงการรักษาผลข้างเคียงที่เกิดจากยาแก้ปวดเป็นประจำ APS เป็นที่ยอมรับและปฏิบัติกันมาในประเทศที่พัฒนาแล้วมานานกว่า 30 ปี แต่ในประเทศอินเดีย APS ยังคงไม่ได้รับการพัฒนาและไม่ได้นำมาใช้ในทางการแพทย์อย่างแพร่หลาย

การวัดความเจ็บปวดเฉียบพลันช่วยให้เข้าใจสถานการณ์ที่เกิดขึ้นในร่างกาย เช่น การบาดเจ็บของเนื้อเยื่อ ความเจ็บปวดเฉียบพลันมีระยะเวลาสั้นและวัดได้ยากเนื่องจากมีความซับซ้อนและเป็นการรับรู้ส่วนบุคคลที่แตกต่างกัน ในปัจจุบันการประเมินความเจ็บปวดเฉียบพลันดำเนินการโดยเจ้าหน้าที่ทางการแพทย์หรือผู้ดูแลโดยใช้การรายงานจากผู้ป่วยเองหรือมาตรวัดความเจ็บปวด อย่างไรก็ตาม วิธีการเหล่านี้ไม่สามารถใช้ได้ผลกับผู้ป่วยที่มีปัญหาทางจิตใจและต้องการการสังเกตอย่างใกล้ชิดในการประเมินความเจ็บปวด อีกทั้งยังทำให้การเลือกปริมาณยาแก้ปวดสำหรับผู้ป่วยใน ICU ทำได้ยาก ถึงแม้จะมีผลกระทบอย่างมาก ความเจ็บปวดเฉียบพลันมักถูกมองข้ามและไม่ได้รับการรักษา ดังนั้นจึงจำเป็นต้องมีระบบคอมพิวเตอร์อัตโนมัติที่เชื่อถือได้และมีความแม่นยำในการตรวจจับและติดตามความเจ็บปวดของผู้ป่วย

ตามทฤษฎีความเจ็บปวดจะมีการเชื่อมโยงกับการทำงานของระบบประสาทอัตโนมัติ (ANS) ซึ่งทำหน้าที่ช่วยให้มนุษย์รู้สึกถึงระดับความรุนแรงของความเจ็บปวด ANS มีสองส่วนคือ ระบบประสาทพาราซิมพาเทติก (PNS) ซึ่งทำงานขณะพักผ่อน และระบบประสาทซิมพาเทติก (SNS) ซึ่งทำงานเมื่อเกิดความเครียดหรือความเจ็บปวด เมื่อ ANS ถูกกระตุ้น SNS จะทำให้สัญญาณทางสรีรวิทยาเปลี่ยนแปลงอย่างชัดเขน เช่น สัญญาณคลื่นไฟฟ้าหัวใจ (ECG), การแปรปรวนของอัตราการเต้นของหัวใจ (HRV), กิจกรรมไฟฟ้าทางผิวหนัง (EDA) และอัตราการเต้นของหัวใจ (HR) ซึ่งสามารถนำมาใช้ในการวัดระดับความเจ็บปวดได้โดยตรง

A. Related Works and Motivation

มีการวิจัยที่เกี่ยวกับระบบการรู้จำความเจ็บปวดเฉียบพลันในผู้ใหญ่อยู่มาก งานวิจัยด้านล่างนี้เป็นเพียงตัวอย่างงานวิจัยบางส่วนที่สนับสนุนงานวิจัยนี้ Cho D. et al. ได้พัฒนาระบบวัดระดับความเครียดจากสัญญาณทางสรีรวิทยา โดยใช้เครื่อง Virtual Reality เพื่อสร้างระดับความเครียด 5 ระดับ คือ ปกติ, ความเครียดเล็กน้อย, ปานกลาง, รุนแรง และฟื้นตัว โดยวัดสัญญาณ PPG, คุณลักษณะสูงสุดของ EDA และ

การเปลี่ยนแปลงของอุณหภูมิที่ผิวหนัง (SKT) เพื่อตรวจวัดระดับความเครียด จากนั้นสกัดคุณลักษณะจากสัญญาณและใช้การทดสอบ ANOVA เพื่อหาพารามิเตอร์ที่มีนัยสำคัญ และให้คุณลักษณะเหล่านี้เป็นข้อมูลที่ใช้สำหรับตัวจำแนก Extreme Learning Machine (ELM) เพื่อจำแนกความเครียดทั้ง 5 ระดับ โดยได้ความแม่นยำ 95%

Daniel Lopez-Martinez และ Rosalind Picard ได้นำเสนออัลกอริทึม Long Short-Term Memory Neural Network (LSTM-NN) เพื่อวิเคราะห์สัญญาณ EDA แยกเป็นส่วนประกอบ tonic และ phasic และสกัดคุณลักษณะเพื่อนำเข้าสู่ LSTM recurrent neural network regressor เพื่อประมาณระดับความเจ็บปวดต่าง ๆ นอกจากนี้ ยังได้ใช้การแปรปรวนของอัตราการเต้นของหัวใจเพื่อประเมินความเจ็บปวด แต่ผลลัพธ์จาก EDA ให้ความแม่นยำสูงกว่า Yaqi Chu et al. ใช้สัญญาณ BVP, ECG, และ SCL เพื่อตรวจวัดระดับความเจ็บปวด 4 ระดับ โดยใช้ไฮบริดอัลกอริทึมแบบ Genetic Algorithm เพื่อแยกระดับความเจ็บปวดในรูปแบบต่าง ๆ ซึ่งรวมถึงการใช้สัญญาณเดียว, หลายคน, หลายวัน, ระหว่างบุคคล และหลายสัญญาณ

ในปีหลัง ๆ วิธีการเรียนรู้เชิงลึก (Deep Learning) ได้ถูกนำมาใช้ในงานที่เกี่ยวข้องกับสัญญาณทางสรีรวิทยาอย่างแพร่หลาย ในการสร้างแบบจำลองการรับรู้ทางอารมณ์ การสกัดและเลือกคุณลักษณะเป็นขั้นตอนที่ซับซ้อน ซึ่งปัญหานี้สามารถแก้ไขได้โดยใช้วิธีการ Deep Learning บทความต่อไปนี้แสดงถึงการใช้ Deep Learning ในการจำแนกระดับความเจ็บปวด L. Santamaria-Granados et al. [20] พัฒนาโมเดลตรวจจับอารมณ์ด้วย Deep Convolutional Neural Network (DCNN) โดยใช้ ECG และ EDA ในการจำแนกสถานะ arousal และ valence ส่วน Patrick Thaim et al. ใช้สัญญาณ EDA, ECG และ EMG และออกแบบเครือข่าย CNN เพื่อจำแนกสภาวะเจ็บปวดและไม่เจ็บปวด โดยมีความแม่นยำ 84.57% ซึ่ง EDA ให้ผลที่แม่นยำในการจำแนกระหว่างสภาวะเจ็บปวดและไม่เจ็บปวดมากกว่าสัญญาณสรีรวิทยาอื่น ๆ จากงานวิจัยเหล่านี้ เห็นได้ว่าสัญญาณ ECG และ EDA สามารถใช้ในการศึกษาการรับรู้ความเจ็บปวดได้ และอัลกอริทึม Deep Learning สามารถให้ผลลัพธ์ที่ดีกว่าอัลกอริทึมมาตรฐานที่ใช้คุณลักษณะที่กำหนดเอง

B.Objective and Key Contribution

วัตถุประสงค์หลักของบทความนี้คือการเสนออัลกอริทึม DL แบบ shallow เพื่อระบุความเจ็บปวดเฉียบพลัน (nociceptive pain) โดยการมีส่วนร่วมสำคัญของงานวิจัยนี้ประกอบด้วย:

- การสำรวจการใช้สัญญาณสรีรวิทยา เช่น EDA และ ECG ในการตรวจจับความเจ็บปวด
- การพัฒนาขั้นตอนการประมวลผลเบื้องต้นเพื่อลบสัญญาณรบกวนที่ไม่ต้องการออกจากสัญญาณ ECG และ EDA
- การใช้เครือข่าย CNN-LSTM แบบ shallow hybrid เพื่อตรวจจับความเจ็บปวดโดยใช้สัญญาณสรีรวิทยา
- การสำรวจอิทธิพลของเพศในการตรวจจับความเจ็บปวดเฉียบพลัน

จากการศึกษากลุ่มตัวอย่างหลายกลุ่มแสดงให้เห็นว่าสัญญาณ ECG และ EDA เป็นข้อมูลที่ดีที่สุดในการระบุความเจ็บปวดเฉียบพลันในผู้ใหญ่ ดังนั้นสัญญาณเหล่านี้จึงถูกใช้เพื่อตรวจจับความเจ็บปวดแบบ nociceptive โดยใช้เครือข่ายแบบไฮบริดตื้น CNN-LSTM ซึ่งประสิทธิภาพของเครือข่ายนี้ขึ้นอยู่กับการเลือกค่าพารามิเตอร์ที่เหมาะสมเป็นหลัก โดยมีการลองใช้วิธีการเชิงไม่ต่อเนื่อง (Discrete methods) เพื่อกำหนดค่าสำหรับพารามิเตอร์ที่เหมาะสม ในรูปที่ 1 แสดงภาพรวมของงานที่เสนอ ในที่นี้ เครือข่ายที่เสนอนี้มีทั้งหมดห้าชั้น ได้แก่ ชั้นข้อมูลนำเข้า (input layer), ชั้น CNN, ชั้น LSTM, ชั้น dense และชั้นข้อมูลขาออก (output layer)

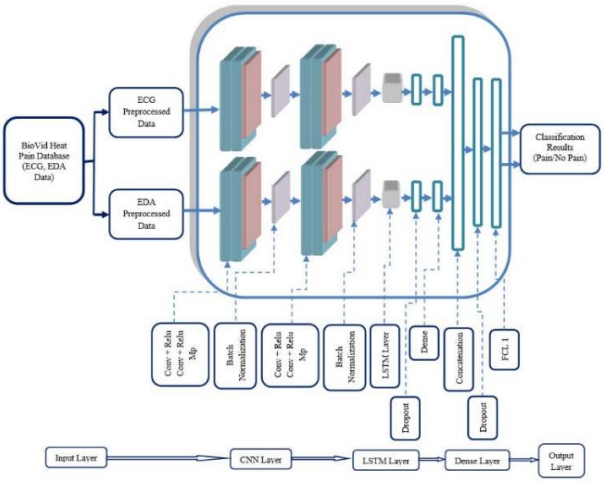

รูปที่ 1 ภาพรวมของระบบที่เสนอ

APPROACH AND METHODOLOGY

ในส่วนนี้จะกล่าวถึงฐานข้อมูลที่ใช้ในการวิเคราะห์ ขั้นตอนการเตรียมข้อมูล และขั้นตอนการสร้างอัลกอริทึมการเรียนรู้เชิงลึกสำหรับการวัดความเจ็บปวด ซึ่งแบ่งเป็นส่วนย่อย ๆ ดังนี้:

A. BioVid Heat Pain Database

ฐานข้อมูล BioVid Heat Pain เป็นฐานข้อมูลที่มีข้อมูลสัญญาณชีวภาพ เช่น สัญญาณ ECG, GSR และ EMG ที่บันทึกจากกล้ามเนื้อ trapezius รวมถึงวิดีโอการแสดงออกทางใบหน้า ฐานข้อมูลนี้พัฒนาขึ้นโดยความร่วมมือระหว่างกลุ่ม Neuro-Information Technology จากมหาวิทยาลัย Magdeburg และกลุ่ม Medical Psychology จากมหาวิทยาลัย Ulm การเก็บข้อมูลนี้ได้จากการกระตุ้นความเจ็บปวดด้วยระดับความร้อน 4 ระดับ ได้แก่ BL1 (ไม่มีความเจ็บปวด), PA1 (ความเจ็บปวดเล็กน้อย), PA2 (ความเจ็บปวดปานกลาง), PA3 (ความเจ็บปวดรุนแรง) และ PA4 (ความเจ็บปวดรุนแรงมาก) จากผู้เข้าร่วม 87 คนในสภาพแวดล้อมที่ควบคุมได้ แต่ละระดับจะถูกกระตุ้นเป็นเวลา 4 วินาที และเว้นช่วงพักระหว่าง 8-12 วินาที โดยในงานวิจัยนี้ได้เลือกใช้ข้อมูลจากผู้เข้าร่วม 67 คน

B. Experimental Setup and Real-Time Data Collection

สำหรับการเก็บข้อมูลแบบเรียลไทม์ ใช้ระบบ Biopac โดยใช้ซอฟต์แวร์ Biopac Student Lab 4.0 ในการวิเคราะห์ แสดงผล และตีความข้อมูล ซึ่ง Biopac MP45 ใช้สำหรับการเก็บข้อมูล มีการติดตั้งอิเล็กโทรด ในช่องสัญญาณที่ 1 สำหรับเก็บสัญญาณ EDA เชื่อมต่อกับสายอิเล็กโทรด SS57LA และช่องสัญญาณที่ 2 สำหรับเก็บสัญญาณ ECG เชื่อมต่อกับสายอิเล็กโทรด SS2LB จากอาสาสมัครในสถานะที่ไม่มีความเจ็บปวด จำนวน 10 คน

C. Physiological Data Acquisition

สัญญาณ ECG และ EDA ถูกเก็บที่อัตราสุ่ม 2000 ตัวอย่างต่อวินาที และขยายสัญญาณเป็น 1000 เท่า สัญญาณที่บันทึกอาจมีเสียงรบกวน จึงใช้วิธีการกรองที่เหมาะสม เช่น การกรอง Butterworth แบบ Bandpass อันดับสามที่ช่วงความถี่ 0.1-40 Hz สำหรับสัญญาณ ECG เพื่อกรองเสียงรบกวนต่ำและสูงออกไป และการกรอง low-pass สำหรับสัญญาณ EDA ที่ความถี่ตัด 0.2 Hz เพื่อกรองเสียงรบกวนอื่น ๆ ออก

D. Data Analysis

งานวิจัยนี้ใช้ข้อมูลสรีรวิทยาจากผู้เข้าร่วม 67 คนในฐานข้อมูล BioVid Heat Pain โดยในบางกรณีใช้เพียงบางส่วนของข้อมูล โดยเลือกข้อมูลจาก 27 คน จะเลือก 14 ไฟล์จากการบันทึก20 ครั้ง และ 40 คน จะเลือกการบันทึกข้อมูลชีวสัญญาณทั้งหมดบันทึกทั้ง 20 ครั้งกับ 5 ระดับความเจ็บปวดที่แตกต่างกัน ข้อมูลสำหรับการศึกษาทำให้ได้ข้อมูล ECG ทั้งหมด 5890 ชุดข้อมูล เวลาเดียวกัน ข้อมูล EDA ก็มี 5890 ชุดเช่นกัน เพื่อช่วยลดความซับซ้อนในการคำนวณ สัญญาณ ECG และ EDA ถูกจัดให้อยู่ในรูปแบบชุดข้อมูลตามช่วงเวลาที่กำหนด และมีการกำกับข้อมูลตามระดับความเจ็บปวดตามการประเมินแบบ VAS (Visual Analog Scale)

E. A Deep Learning Model Based on a Hybrid Network: CNN_LSTM

CNN เป็นโครงข่ายประสาทเทียมที่นิยมใช้มาก เพราะออกแบบมาให้ตรวจจับรูปแบบต่างๆ ได้ดี เช่น การเปลี่ยนแปลง รูปแบบที่หลากหลาย และการบิดเบือนทางเรขาคณิต

สำหรับงานนี้ CNN ใช้ข้อมูลเข้าเป็นข้อมูลลำดับเวลาแบบหนึ่งมิติ โครงสร้างไฮบริดที่นำเสนอคือ CNN_LSTM ซึ่งประกอบด้วยชั้นต่างๆ ได้แก่ ชั้นข้อมูลเข้า (Input Layer - IL) ชั้นคอนโวลูชัน (Convolutional Layer - CL) ชั้นลดขนาด (Pooling Layer - PL) ชั้นปรับค่าปกติ (Batch Normalization Layer - BNL) ชั้น LSTM และชั้นเชื่อมต่อเต็มรูปแบบ (Fully Connected Layer - FCL)ในชั้นคอนโวลูชัน

ข้อมูลจะถูกคอนโวลูชันกับฟิลเตอร์เพื่อสร้างแผนที่คุณลักษณะ โดยทุกหน่วยในแผนที่นี้จะใช้น้ำหนักเดียวกัน ชั้นนี้ได้รับผลกระทบจากขนาดเคอร์เนล และใช้ฟังก์ชันการกระตุ้นแบบ ReLU เพื่อช่วยให้การเรียนรู้เร็วขึ้น ชั้นลดขนาดจะลดมิติข้อมูลลงครึ่งหนึ่งโดยไม่เสียข้อมูลสำคัญ และส่งต่อข้อมูลไปยังชั้น LSTM

ชั้น CNN เหมาะสำหรับการสกัดคุณลักษณะเชิงพื้นที่จากสัญญาณทางสรีรวิทยา ส่วนชั้น LSTM ที่ตามมา จะจับพลวัตของเวลาของข้อมูลเหล่านี้ โดยจะรวมข้อมูลที่คล้ายกัน และกรองข้อมูลที่ไม่จำเป็นออก เพื่อเก็บคุณลักษณะที่สำคัญไว้ในหน่วยความจำ ข้อมูลที่ได้จากชั้น LSTM จะถูกส่งต่อไปยังชั้น FCL ซึ่งจะใช้

ฟังก์ชัน Sigmoid ในการคำนวณค่าความน่าจะเป็นในแต่ละคลาส ทำให้ FCL สามารถประเมินคลาสสุดท้ายของผลลัพธ์ CNN ได้

โมเดล CNN_LSTM อาจมีการฟิตมากเกินไปในช่วงฝึก ดังนั้นจึงมีการใช้เทคนิคการลดสัญญาณ (drop-out) เพื่อป้องกันการฝึกที่จำเพาะเจาะจงกับข้อมูลมากเกินไปตามที่แสดงในรูปที่ 1 CNN ใช้สำหรับการสกัดคุณลักษณะ และ LSTM ใช้สำหรับรวมและจัดเก็บคุณลักษณะที่สำคัญ โดยขั้นตอนการทำงานของชั้น CNN และ LSTM สามารถแสดงด้วยสมการทางคณิตศาสตร์ตามที่แสดงในสมการ

$$z_i^{(l)} = \tanh\left(b_i^{(l)} + \text{pooling}_{\max}\left(\sum_{j=1}^{m_{l-1}} k_{i,j}^{(l)} * z_j^{(l-1)}\right)\right)$$

การทำงานของชั้น LSTM แสดงด้วยสมการทางคณิตศาสตร์ดังนี้:

$$f_t^{(s)} = \sigma\left(w_{fs}^{(h)}.h_{t-1} + w_{fs}^{(g)}.g_t + b_s^{(f)}\right)$$

$$i_t^{(n)} = \sigma\left(w_{in}^{(h)}.h_{t-1} + w_{in}^{(g)}.g_t + b^{(in)}\right)$$

$$q_t = \sigma\left(w_q^{(h)}.h_{t-1} + w_q^{(g)}.g_t + b^{(q)}\right)$$

$$\tilde{c}_t = \tanh\left(w_{c\tilde{l}}^{(h)}.h_{t-1} + w_{c\tilde{l}}^{(g)}.g_t + b^{(c\tilde{l})}\right)$$

$$c_t = c_{t-1} * f_t^{(s)} + i_t^{(n)} * \tilde{c}_t$$

$$h_t = q_t * \tanh(c_t)$$

ซึ่งประกอบด้วยการประมวลผลข้อมูลตามขั้นตอนของแต่ละเกตและฟังก์ชันต่างๆ เช่น ฟังก์ชัน Sigmoid สำหรับตัดสินใจเก็บหรือลืมข้อมูล ผลลัพธ์สุดท้ายจากเครือข่าย LSTM จะเป็นข้อมูลเข้าของชั้น FCL ของ CNN เพื่อตัดสินผลการจัดหมวดหมู่ขั้นสุดท้าย เครือข่าย CNN_LSTM นี้จึงเป็นโครงข่ายไฮบริดที่ใช้วิธีการเรียนรู้แบบ Backpropagation Through Time

RESULTS AND DISCUSSIONS

การเตรียมข้อมูลล่วงหน้าเป็นสิ่งจำเป็นในกระบวนการจำแนกประเภทข้อมูล โดยในที่นี้มีการกำหนดอัตราการสุ่มตัวอย่างที่ 512Hz และใช้ฟิลเตอร์ Butterworth ลำดับที่สามในการลดสัญญาณรบกวนจากสัญญาณ ECG และ EDA ตามที่ได้กล่าวไว้ในโมดูลการเก็บข้อมูลแบบเรียลไทม์ แม้ว่าจะผ่านการกรองแล้ว สัญญาณ ECG ยังอาจได้รับผลกระทบจากการลอยของเส้นฐาน จึงมีการหักค่าด้วยการปรับเส้นโค้งของพหุนามลำดับที่ห้าเพื่อแยกสัญญาณออก ข้อมูลที่ได้สุดท้ายถูกเตรียมโดยการสกัดสัญญาณในช่วงเวลาขนาด 5.5 วินาที

เพื่อสร้าง Array ข้อมูล 1 มิติ ขนาด 5.5 × 512 = 2816 ดังนั้น แต่ละสัญญาณทางสรีรวิทยาจะมีข้อมูล (27×14 × 2816×1) + (60×20 × 2816×1) สำหรับป้อนเข้าสู่ตัวจำแนกข้อมูล

จากงานวิจัยพบว่า ผู้หญิงมีความไวต่อความเจ็บปวดมากกว่าผู้ชาย โดยที่อารมณ์มีผลต่อการรับรู้ความเจ็บปวดมากกว่าผู้ชาย ผู้หญิงยังอาจมีผลข้างเคียง เช่น การหายใจ เมื่อได้รับยาระงับปวดในปริมาณเท่ากับผู้ชาย ดังนั้น การรักษาความเจ็บปวดระหว่างเพศชายและหญิงจึงมีความแตกต่างกัน และจำเป็นต้องมีการศึกษารายละเอียดเพื่อให้จัดการความเจ็บปวดได้อย่างเหมาะสมในแต่ละเพศ ด้วยเหตุนี้งานวิจัยนี้จึงได้พัฒนาระบบจดจำความเจ็บปวดตามเพศ โดยใช้เครือข่ายการเรียนรู้เชิงลึกแบบผสมผสาน CNN_LSTM เพื่อระบุการเริ่มต้นของความเจ็บปวด โดยใช้ชุดข้อมูล BVDB ของผู้หญิง ผู้ชาย และข้อมูล BVDB ทั้งหมด

A.Hyper-Parameter Selection

การเลือก hyperparameters มีความสำคัญอย่างยิ่งในการพัฒนาโมเดลแบบผสม CNN-LSTM โดยในการศึกษานี้ได้เลือกใช้ตัวปรับค่าแบบ Adaptive Moment Estimation (Adam) เป็นอัลกอริธึมหลักในการปรับปรุงพารามิเตอร์ของโมเดล พร้อมกำหนด learning rate ไว้ที่ 10^{-5} ส่วนเลเยอร์อินพุตประกอบด้วยสัญญาณ ECG และ EDA ที่มีขนาด 2816×1 สำหรับแต่ละสัญญาณ จากนั้นในเลเยอร์ซ่อนแรก จะประกอบด้วยเลเยอร์ convolutional แบบ 1 มิติ (Conv1D) สองเลเยอร์ โดยแต่ละเลเยอร์มี kernel จำนวน 256 ที่มีขนาด 5 และกำหนดให้ border_mode เป็น 'same' ตามด้วยเลเยอร์ max pooling ที่มีขนาด window เท่ากับ 2 และ padding แบบ 'same' และปิดท้ายด้วยเลเยอร์ batch normalization

เลเยอร์ซ่อนที่สองถูกออกแบบในลักษณะเดียวกับเลเยอร์แรก กล่าวคือประกอบด้วยเลเยอร์ convolutional สองเลเยอร์ ตามด้วยเลเยอร์ max pooling และเลเยอร์ batch normalization หลังจากนั้นจะเป็นเลเยอร์ LSTM ที่มี hidden units จำนวน 200 units และปิดท้ายด้วยเลเยอร์ Fully Connected (FCL1) และเลเยอร์เอาต์พุต ซึ่งทำหน้าที่ปรับ feature matrix เพื่อให้ได้ผลการจำแนกตามที่ต้องการสำหรับการจำแนกประเภทนั้น ใช้ activation function แบบ 'sigmoid' ที่จะให้ผลลัพธ์เป็นสองกลุ่มคือ ไม่มีความเจ็บปวด หรือ มีความเจ็บปวด ในขณะที่เลเยอร์ convolutional ทั้งหมดใช้ activation function แบบ 'ReLU' ซึ่งมีสมการคือ ReLU(x) = max(0, x)เพื่อป้องกันปัญหา overfitting ได้มีการใช้เทคนิค dropout หลังเลเยอร์ LSTM โดยกำหนดค่า dropout rate ไว้ที่ 0.25 ทั้งนี้ ประสิทธิภาพโดยรวมของเครือข่าย CNN-LSTM แบบตื้นนี้จะขึ้นอยู่กับการเลือกค่า hyperparameters ที่เหมาะสม

B.The Proposed Hybrid CNN-LSTM Architecture

สถาปัตยกรรมผสม CNN_LSTM ที่นำเสนอโดยละเอียดสำหรับการจำแนกสัญญาณทางสรีรวิทยาว่าเป็น "ไม่มีความเจ็บปวด" หรือ "มีความเจ็บปวด" โดยแผนภาพบล็อกของระบบที่เสนอแสดงในรูปที่ 1 ซึ่ง

ประกอบด้วยหน่วยการเก็บข้อมูล, หน่วยการประมวลผลล่วงหน้า และโมดูลของอัลกอริธึมการเรียนรู้ลึกที่ใช้ในการกำหนดผลการจำแนกประเภท

ในงานนี้สัญญาณทางสรีรวิทยา EDA และ ECG จากฐานข้อมูล BioVid Heat Pain Database (BVDB) ถูกใช้ทดสอบประสิทธิภาพของอัลกอริธึม โดยสัญญาณเหล่านี้ได้รับการประมวลผลล่วงหน้าเพื่อขจัดอาร์ติแฟกต์หรือเสียงรบกวนที่ไม่จำเป็น ซึ่งเป็นขั้นตอนที่จำเป็นในการให้ผลลัพธ์การจำแนกประเภทที่ดี เครือข่าย CNN-LSTM แบบผสมจะใช้ในการเรียนรู้ข้อมูลที่ผ่านการประมวลผลล่วงหน้าและในการวัดจุดเริ่มต้นของความเจ็บปวด ประสิทธิภาพของอัลกอริธึมที่นำเสนอนี้ได้รับการทดสอบบนฐานข้อมูล Part-A ของ BioVid Heat Pain Database โดยใช้เกณฑ์ต่างๆ ได้แก่ ความถูกต้องในการจำแนก,ค่าเฉลี่ยกำลังสองของความผิดพลาด, และ Confusion Matrix ซึ่งแสดงรายละเอียดเกี่ยวกับจำนวนการทำนายที่ถูกต้องและไม่ถูกต้องจากตัวจำแนกประเภท

การทดลองต่างๆ ที่ดำเนินการและประสิทธิภาพของอัลกอริธึมในการกำหนดจุดเริ่มต้นของความเจ็บปวด ในงานนี้ การกำหนดความเจ็บปวดแบบ (nociceptive pain) โดยอิงจากเพศได้ถูกนำมาใช้ ข้อมูล ECG ถูกแบ่งออกเป็นข้อมูลการฝึก (Female & Male BVDB - 1059 ตัวอย่าง) และข้อมูลทดสอบ (Female & Male BVDB - 119 ตัวอย่าง) สำหรับการกำหนดความเจ็บปวดแบบตามเพศ ข้อมูล EDA ก็ถูกแบ่งในลักษณะเดียวกัน โดยข้อมูลการฝึก (Female & Male BVDB - 1055 ตัวอย่าง) และข้อมูลทดสอบ (Female & Male BVDB - 123 ตัวอย่าง) สำหรับการกำหนดความเจ็บปวดตามเพศเช่นกัน

ในการวิเคราะห์ข้อมูลทางสรีรวิทยาทั้งหมดของ BVDB สำหรับการจำแนกความเจ็บปวด ข้อมูล ECG ถูกแบ่งเป็นข้อมูลการฝึก (ทั้ง BVDB - 2118 ตัวอย่าง) และข้อมูลทดสอบ (ทั้ง BVDB - 238 ตัวอย่าง) ข้อมูล EDA ก็ถูกแบ่งเป็นข้อมูลการฝึก (ทั้ง BVDB - 2119 ตัวอย่าง) และข้อมูลทดสอบ (ทั้ง BVDB - 237 ตัวอย่าง) เช่นเดียวกัน

สำหรับจำแนกประเภท (BL1 Vs PA1, BL1 Vs PA2, BL1 Vs PA3, และ BL1 Vs PA4) เครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG จากฐานข้อมูล Female BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 79.83%, 81.93%, 78.15% และ 83.19% ตามลำดับ ส่วนเครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG จากฐานข้อมูล Male BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 68.91%, 76.89%, 75.63% และ 72.69% ตามลำดับการจำแนกประเภท (BL1 Vs PA1, BL1 Vs PA2, BL1 Vs PA3, และ BL1 Vs PA4) เครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG จากฐานข้อมูล Female BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 79.83%, 81.93%, 78.15% และ 83.19% ตามลำดับ ส่วนเครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG จากฐานข้อมูล Male BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 68.91%, 76.89%, 75.63% และ 72.69% ตามลำดับ สุดท้าย เครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG จากฐานข้อมูล Entire BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 68.70%, 62.61%, 67.86% และ 75.21% ตามลำดับ

สำหรับการจำแนกประเภท (BL1 Vs PA1, BL1 Vs PA2, BL1 Vs PA3, และ BL1 Vs PA4) เครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ EDA จากฐานข้อมูล Female BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภททได้ 77.24%, 78.86%, 54.10% และ 83.33% ตามลำดับ เช่นเดียวกับเครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ EDA จากฐานข้อมูล Male BVDB ซึ่งได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 84.65%, 67.98%, 57.46% และ 78.51% ตามลำดับ สุดท้าย เครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ EDA จากฐานข้อมูล Entire BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 85.65%, 74.47%, 80.80% และ 80.17% ตามลำดับ

CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG และ EDA จากฐานข้อมูล Female BVDB สำหรับเหตุการณ์การจำแนกประเภท (BL1 Vs PA1, BL1 Vs PA2, BL1 Vs PA3, และ BL1 Vs PA4) ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 84.55%, 61.38%, 77.46% และ 81.71% ตามลำดับ เช่นเดียวกับเครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG และ EDA จากฐานข้อมูล Male BVDB ซึ่งได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 93.09%, 86.13%, 78.15%, และ 76.79% ตามลำดับ

CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG และ EDA จากฐานข้อมูล Entire BVDB ได้ผลลัพธ์ความถูกต้องในการจำแนกประเภทที่ 93.91%, 86.97%, 90.75%, และ 94.12% ตามลำดับ ซึ่งเครือข่าย CNN_LSTM แบบผสมที่ใช้สัญญาณ ECG และ EDA ที่ประสานกันมีความสามารถในการกำหนดความเจ็บปวดเล็กน้อยและความเจ็บปวดทนไม่ได้ได้อย่างมีประสิทธิภาพเมื่อเทียบกับเทคนิคที่มีอยู่ แม้แต่การจำแนกประเภทของไม่มีความเจ็บปวด (BL1) และมีความเจ็บปวด (PA1+PA2+PA3+PA4) ก็สามารถทำได้อย่างมีประสิทธิภาพโดยใช้เครือข่ายเดียวกัน การประเมินผลประสิทธิภาพของอัลกอริธึม CNN_LSTM แบบผสมที่ใช้ข้อมูลจากฐานข้อมูลของผู้หญิง (ECG & EDA) และชาย (ECG & EDA) และข้อมูลทั้งหมด (ECG & EDA) ซึ่งความถูกต้องในการจำแนกประเภทของพวกเขาได้ดีกว่าผลงานอื่นๆ ที่มีอยู่

ดังนั้นจึงได้พิสูจน์ว่าทั้งข้อมูล ECG และ EDA มีข้อมูลที่สำคัญเกี่ยวกับอาการปวดเฉียบพลัน เมื่อเปรียบเทียบกับระบบที่ใช้กันในปัจจุบัน เครือข่าย multi ที่ใช้สัญญาณ ECG และ EDA สามารถกำหนดอาการปวดเล็กน้อยและอาการปวดที่ทนไม่ได้ได้อย่างมีประสิทธิภาพ นอกจากนี้ เครือข่าย Unimodal hybrid CNN_LSTM ยังสามารถทำความถูกต้องในการจำแนกข้อมูลสำหรับทั้งสัญญาณ ECG และ EDA โดยใช้ข้อมูลจากผู้หญิง BVDB เมื่อเปรียบเทียบกับข้อมูลจากผู้ชาย BVDB และข้อมูลทั้งหมดของ BVDB การจำแนกอาการปวดตามเพศมักจะเป็นเรื่องยาก โดยเฉพาะเมื่อพิจารณาอาการปวดในผู้หญิง เพราะผู้หญิงมักมีความพึ่งพาทางอารมณ์ ดังนั้น ผลลัพธ์สุดท้ายจากการจำแนกควรได้รับการเปรียบเทียบกับอารมณ์ของแต่ละบุคคลเพื่อช่วยในการตัดสินใจเกี่ยวกับขนาดยาที่ใช้บรรเทาอาการปวด

จากข้อมูลที่ป้อนให้กับตัวจำแนก ความแม่นยำในการจำแนกจะเปลี่ยนแปลงไป ดังนั้นจึงจำเป็นต้องมีการให้ข้อมูลที่เพียงพอแก่ตัวจำแนก ระบบการจำแนกอาการปวดแบบ unimodal และ multimodal ที่

พัฒนาขึ้นสามารถจำแนกข้อมูลว่าเป็นอาการปวดหรือไม่ปวด โดยใช้สัญญาณ ECG และ EDA ซึ่งให้ผลลัพธ์การจำแนกที่มีนัยสำคัญเมื่อเปรียบเทียบกับระบบฐาน

ข้อมูลในเวลาจริงถูกเก็บรวบรวมโดยใช้ระบบ Biopac และได้ทดสอบประสิทธิภาพของการจำแนกแบบ unimodal hybrid CNN_LSTM ตามข้อมูล ECG และ EDA ในที่นี้เลือกกลุ่มตัวอย่างปกติในช่วงอายุ 20-30 ปี สำหรับการศึกษา โดยเก็บข้อมูลที่ไม่มีอาการปวดจากกลุ่มตัวอย่างและทดสอบประสิทธิภาพของอัลกอริธึมที่เสนอ

การศึกษานี้มีส่วนประกอบสามโมดูล โมดูลแรกคือการพัฒนาระบบการจำแนกอาการปวดแบบ unimodal โมดูลที่สองคือการพัฒนาระบบการจำแนกอาการปวดแบบ multimodal และโมดูลสุดท้ายคือการพัฒนาระบบการจำแนกอาการปวดแบบ multimodal ตามเพศ ทั้งสามโมดูลได้รับการพัฒนาอย่างสำเร็จและมีความแม่นยำในการจำแนกที่ยอมรับได้ ดังที่ได้กล่าวไว้ก่อนหน้านี้ ระบบการจำแนกอาการปวดแบบ multimodal ตามเพศเป็นสิ่งจำเป็นเพื่อช่วยในการให้การรักษาด้วยระบบ APS (Acute Pain Service) และเพื่อเริ่มต้นการใช้ APS ในประเทศอินเดีย

CONCLUSION AND FUTURE WORK

ในการศึกษานี้ได้ใช้ Keras และ TensorFlow เป็นเครื่องมือที่รองรับการทำงานร่วมกับ Windows Server 2012 R2 Standard ซึ่งเปิดใช้งาน Deep Learning framework ในระบบปฏิบัติการ Windows 2012 โดยสรุปงานนี้ได้พัฒนาเครือข่าย hybrid CNN_LSTM สำหรับการจำแนกอาการปวด nociceptive โดยใช้การจำแนกแบบ Unimodal ด้วยข้อมูล ECG และ EDA แยกกัน และการจำแนกแบบ Multimodal โดยใช้ข้อมูล ECG และ EDA แม้ว่าจะมีงานวิจัยบางส่วนที่ใช้อัลกอริธึม Deep Learning สำหรับการจำแนกอาการปวดบน BVDB แต่ผลงานที่นำเสนอในงานนี้ที่ใช้การจำแนกแบบ unimodal และ multimodal ได้แสดงผลลัพธ์ที่สำคัญเมื่อเปรียบเทียบกับงานวิจัยที่ใช้เทคนิคในปัจจุบัน

การจำแนกหลายคลาสยังต้องได้รับการพัฒนา การพิจารณาแค่สัญญาณทางสรีรวิทยาเพื่อวัดอาการปวด nociceptive อาจไม่ใช่ทางเลือกที่ดีที่สุด เนื่องจากมันได้รับผลกระทบจากหลายปัจจัย เช่น ยาที่ให้กับผู้ป่วย ความกลัว การผ่าตัด การรักษา ความเครียดของผู้ป่วย ดังนั้นจึงจำเป็นต้องใช้วิธีการแบบ multimodal เพื่อวัดอาการปวด nociceptive อย่างมีความแม่นยำ แม้ว่าอัลกอริธึม Deep Learning จะให้ผลลัพธ์ที่ดีที่สุด แต่การทำความเข้าใจเครือข่ายลึกยังคงเป็นเรื่องที่ซับซ้อนและไม่เพียงพอ ดังนั้นจึงควรปรับโมเดลเครือข่ายที่ไม่เป็นเชิงเส้นให้เป็นเครือข่ายเชิงเส้นโดยการคำนวณค่า Eigenvalues และ Eigenvectors

Multimodal physiological sensing for the assessment of acute pain

การตรวจวัดทางสรีรวิทยาหลายรูปแบบเพื่อการประเมินความเจ็บปวดเฉียบพลัน

การประเมินความเจ็บปวดเป็นงานที่ท้าทายสำหรับบุคลากรทางการแพทย์ ในบริบทของการแพทย์แล้ว การรายงานความเจ็บปวดของผู้ป่วยถือเป็นมาตรฐานสูงสุดในการประเมินความเจ็บปวด อย่างไรก็ตาม ผู้ป่วยที่ไม่สามารถรายงานความเจ็บปวดด้วยตนเองได้มีความเสี่ยงที่จะไม่ได้รับการวินิจฉัยถึงความเจ็บปวด การศึกษานี้ได้สำรวจการใช้เทคโนโลยีการตรวจวัดแบบหลายช่องทางเพื่อเฝ้าสังเกตการเปลี่ยนแปลงทางสรีรวิทยาที่สามารถใช้เป็นตัวแทนในการวัดความเจ็บปวดเฉียบพลันอย่างเป็นระบบ โดยรวบรวมข้อมูลจากสัญญาณกิจกรรมทางผิวหนัง (Electrodermal Activity - EDA), สัญญาณการไหลเวียนเลือดผ่านผิวหนัง (Photoplethysmography - PPG) และสัญญาณการหายใจ (Respiration - RESP) จากผู้เข้าร่วม 22 คน ภายใต้ระดับความเจ็บปวดสองระดับ (ต่ำและสูง) และตำแหน่งสองแห่ง (แขนและมือ) จากนั้น นำข้อมูลเข้าสู่แบบจำลองการเรียนรู้ของเครื่องจักรสามแบบ คือ Support Vector Machine (SVM), Decision Tree (DT) และ Linear Discriminant Analysis (LDA) เพื่อตรวจหาความเจ็บปวดโดยศึกษาในสถานการณ์ต่างๆ เช่น การระบุว่ามีอาการปวดหรือไม่ การจำแนกระดับความรุนแรงของอาการปวด และการระบุตำแหน่งของอาการปวด ผลการศึกษาแสดงให้เห็นว่า EDA เป็นเซ็นเซอร์ที่ให้ข้อมูลที่ดีที่สุด โดยสามารถระบุอาการปวดได้ถูกต้อง 93.2 ± 8%, จำแนกระดับความรุนแรงได้ 68.9 ± 10%และระบุตำแหน่งที่มีอาการปวดได้ 56.0± 8% ในขณะที่ PPG และ RESP มีประสิทธิภาพต่ำกว่า จึงสรุปว่า EDA เป็นเซ็นเซอร์ที่มีประสิทธิภาพสูงสุดในการประเมินอาการปวด อย่างไรก็ตาม ยังต้องมีการวิจัยเพิ่มเติมเพื่อยืนยันผลและเพิ่มความเป็นไปได้ในการนำไปใช้ในสถานการณ์จริง

บทนำ

การประเมินความเจ็บปวดเป็นงานที่ท้าทายมากสำหรับแพทย์ โดยทั่วไป วิธีที่ใช้ในการประเมินความเจ็บปวดที่เชื่อถือได้มากที่สุดคือการให้ผู้ป่วยรายงานความรู้สึกเจ็บปวดด้วยตนเอง อย่างไรก็ตาม สำหรับผู้ป่วยที่ไม่สามารถสื่อสารได้ ทำให้การประเมินความเจ็บปวดกลายเป็นปัญหา การที่ผู้ป่วยไม่สามารถรายงานความเจ็บปวดได้ ไม่ได้หมายความว่าผู้ป่วยไม่ได้รู้สึกเจ็บปวดและไม่ต้องการการรักษาเพื่อลดความเจ็บปวด

ในกรณีที่ผู้ป่วยไม่สามารถรายงานอาการได้ มีเครื่องมือหลายอย่างที่สามารถใช้สำหรับการประเมินความเจ็บปวดในผู้ป่วยที่ไม่สามารถพูดได้ เช่น Behavioral Pain Scale (BPS), Critical-Care Pain Observation Tool (CPOT) และ Nonverbal Pain Scale (NVPS) แต่การใช้เครื่องมือเหล่านี้มีข้อเสียได้แก่ การตีความผิด ทำให้ความน่าเชื่อถือระหว่างผู้ประเมินต่ำ และบางครั้งยังเป็นการวัดที่ทำเพียงครั้งเดียว หากจำเป็นต้องมีการสังเกตซ้ำบ่อยๆ จะเป็นการเพิ่มภาระงานให้พยาบาลจนเกินไป

การจัดการความเจ็บปวดหลังผ่าตัดเป็นองค์ประกอบสำคัญที่ช่วยให้ผู้ป่วยฟื้นตัวได้เร็วขึ้น ลดโอกาสในการเกิดภาวะแทรกซ้อนต่างๆ การประเมินและการจัดการความเจ็บปวดที่ไม่เพียงพอส่งผลให้เกิดอัตราการป่วยและอัตราการเสียชีวิตที่เพิ่มขึ้น อีกทั้งยังสามารถนำไปสู่ความทุกข์ทั้งทางร่างกายและจิตใจ เช่น ภาวะซึมเศร้า ความวิตกกังวล หรือความเจ็บปวดเรื้อรัง และอาจทำให้ต้องเข้ารับการรักษาในโรงพยาบาลเป็นระยะเวลานานขึ้น ดังนั้นการพัฒนาเครื่องมือที่สามารถช่วยแพทย์ในการประเมินความเจ็บปวดเฉียบพลันจึงเป็นสิ่งจำเป็น ซึ่งจะช่วยให้การวินิจฉัยมีความแม่นยำและน่าเชื่อถือมากขึ้น

สัญญาณทางสรีรวิทยาต่างๆ สามารถใช้วัดการเปลี่ยนแปลงที่เกิดขึ้นในร่างกายเมื่อเกิดความเจ็บปวดเฉียบพลัน ตัวอย่างเช่น Electrodermal Activity (EDA), Photoplethysmography (PPG), และ Respiration (RESP) ซึ่งเทคโนโลยีการตรวจจับเหล่านี้สามารถตรวจจับสัญญาณประสาทอัตโนมัติ (Autonomic Nervous System หรือ ANS) ที่ตอบสนองต่อความเจ็บปวดได้

การใช้การเรียนรู้ของเครื่องมีบทบาทสำคัญในการประมวลผลข้อมูลทางสรีรวิทยาเพื่อระบุรูปแบบที่ซับซ้อนของความเจ็บปวดจากข้อมูลทางสรีรวิทยา ดังนั้น การศึกษานี้มีวัตถุประสงค์เพื่อสำรวจการใช้เทคโนโลยีการตรวจจับหลายรูปแบบในการตรวจหาความเจ็บปวดเฉียบพลัน (ไม่มีความเจ็บปวดกับมีความเจ็บปวด) การจำแนกความรุนแรงของความเจ็บปวด (ไม่มีความเจ็บปวด, ความเจ็บปวดน้อย, ความเจ็บปวดมาก) และการระบุแหล่งที่มาของความเจ็บปวด

การเรียนรู้ของเครื่อง (Machine Learning) ได้กลายเป็นส่วนสำคัญสำหรับความสำเร็จของระบบที่ใช้ข้อมูลทางสรีรวิทยาในการตรวจจับอาการปวด ในบริบทนี้การเรียนรู้ของเครื่องถูกนำมาใช้เพื่อช่วยในการตีความความซับซ้อนของอาการปวด โดยการเปิดเผยรูปแบบต่างๆ ที่อยู่ในข้อมูลทางสรีรวิทยา วรรณกรรมมีการนำเสนอความพยายามต่างๆ ในการใช้การตรวจจับหลายรูปแบบและการเรียนรู้ของเครื่องเพื่อการตรวจจับอาการปวด ตัวอย่างเช่น ในการศึกษาของ Teichmann et al. ใช้เซ็นเซอร์ ECG และ PPG เพื่อติดตามสัญญาณทางสรีรวิทยาจากผู้เข้าร่วมและออกแบบตัวจำแนกแบบ Random Forest (RF) เพื่อระบุความรู้สึกปวด ในการศึกษาของ Chu et al. ใช้สัญญาณ PPG, ECG และ EDA เพื่อตรวจจับการมีและไม่มีอาการปวดโดยใช้การวิเคราะห์แยกเชิงเส้น (LDA), k-nearest neighbour (KNN), และเครื่องเวกเตอร์สนับสนุน (SVM) ในทำนองเดียวกัน Jiang et al. ใช้เซ็นเซอร์ EDA, อัตราการเต้นของหัวใจ (HR), อัตราการหายใจ (BR), EDA และคลื่นไฟฟ้ากล้ามเนื้อ(EMG) เพื่อระบุอาการปวดโดยใช้เครือข่ายประสาทเทียม ในการศึกษาของ Yang et al. เพื่อสำรวจความเป็นไปได้ในการใช้การวัดทางสรีรวิทยาหลายตัวในการระบุอาการปวด ได้มีการใช้โมเดลการถดถอยโลจิสติก (Logistic Regression) โดยใช้ข้อมูลออกซิเจนในเลือด (SpO2), ความดันโลหิต (BP), HR, การหายใจ (RESP) และอุณหภูมิผิวหนัง ผลลัพธ์จากตัวอย่างเหล่านี้แสดงให้เห็นว่า ตัวชี้วัดทางสรีรวิทยาและการเรียนรู้ของเครื่องสามารถนำมาใช้ในการระบุอาการปวดในมนุษย์ได้

ในการศึกษานี้จะวิธีการประเมินอาการปวดต่างๆ โดยใช้เซ็นเซอร์ทางสรีรวิทยาหลายตัว (EDA, PPG, RESP) ก่อนอื่น ได้มีการศึกษาการใช้เทคโนโลยีการตรวจจับเหล่านี้ในการระบุอาการปวดเฉียบพลัน (เช่น ไม่มีอาการปวด vs อาการปวด) ต่อมาสำรวจว่าอาการปวดที่มีความรุนแรงต่างกันสามารถระบุได้ในปัญหาหลายประเภทหรือไม่ เช่น ไม่มีอาการปวด, อาการปวดระดับน้อย, อาการปวดระดับมาก และสุดท้ายจะแก้ไขปัญหาการระบุแหล่งที่มาของอาการปวดโดยใช้เซ็นเซอร์ทางสรีรวิทยา ดังนั้น เราจึงออกแบบแนวทางการกระตุ้นที่มีสองระดับ ในสองตำแหน่งทางกายวิภาคที่แตกต่างกันที่แขนท่อนล่างและมือ เป้าหมายคือการระบุตัวชี้วัดทางสรีรวิทยาที่สามารถนำมาใช้ในการกระตุ้นการสนับสนุนทางเทคโนโลยีเพื่อช่วยแพทย์ในการประเมินอาการปวดเฉียบพลันในงานวิจัยในอนาคต ดังนั้น การศึกษานี้นำเสนอผลงานดังต่อไปนี้เสนอการศึกษาทางสำรวจที่มีจุดมุ่งหมายในการเปรียบเทียบเทคโนโลยีเซ็นเซอร์ต่างๆ ในการใช้วิธีการตรวจจับแบบจำเพาะ (unimodal) และหลายรูปแบบ (multimodal) เพื่อการประเมินอาการปวดเฉียบพลันอย่างเป็นกลางด้วยชุดข้อมูลใหม่ การศึกษานี้ทำหน้าที่เป็นการยืนยันว่า EDA เป็นเทคโนโลยีเซ็นเซอร์ที่เหนือกว่าในการประเมินอาการปวด และเป็นตัวเลือกที่เป็นไปได้สำหรับการวิจัยเพิ่มเติมในสถานการณ์ทางคลินิกนำเสนอชุดคุณลักษณะจาก EDA เป็นตัวชี้วัดที่อาจใช้ในการระบุอาการปวดเฉียบพลันโดยใช้ EDA และการเรียนรู้ของเครื่อง นี่เป็นการศึกษาครั้งแรกที่สำรวจการใช้สัญญาณทางสรีรวิทยาในการระบุตำแหน่งทางกายวิภาคที่อาการปวดเกิดขึ้น ซึ่งกำหนดผลการทดลองที่เป็นพื้นฐานสำหรับการศึกษาต่อไป การใช้งานทางคลินิกของข้อเสนอนี้ยังมีข้อจำกัด จำเป็นต้องมีการทดลองเพิ่มเติมก่อนที่จะพิจารณาการนำไปใช้ในสถานการณ์ทางคลินิกหรือในสถานการณ์จริง

2. Methodology

2.1. Participants

ในการทดลองนี้มีผู้เข้าร่วมทั้งหมด 22 คน (ผู้หญิง 12 คน, ผู้ชาย 10 คน) อายุของผู้เข้าร่วมอยู่ในช่วง 19 ถึง 36 ปี (อายุเฉลี่ย 27 ± 4.19 ปี) ไม่มีผู้เข้าร่วมคนใดที่มีประวัติการเจ็บป่วยทางระบบประสาทหรือจิตเวช, อาการปวดเรื้อรัง, การใช้ยาปกติ หรือการใช้ยาระหว่างการทดสอบ ผู้เข้าร่วมได้รับการอธิบายรายละเอียดเกี่ยวกับขั้นตอนการทดลองเมื่อมาถึง และได้รับการยินยอมเป็นลายลักษณ์อักษรก่อนเริ่มการทดลอง ขั้นตอนการทดลองที่เกี่ยวข้องกับมนุษย์ที่อธิบายไว้ในเอกสารนี้ได้รับการอนุมัติจากคณะกรรมการจริยธรรมมนุษย์ของมหาวิทยาลัยแคนเบอร์รา (หมายเลข: 11837)

2.2 Experimental procedure

การทดลองทั้งหมดดำเนินการที่ห้องปฏิบัติการ Human-Machine Interface ณ มหาวิทยาลัยแคนเบอร์รา ประเทศออสเตรเลีย ผู้เข้าร่วมทดลองนั่งบนเก้าอี้หน้าโต๊ะโดยให้แขนทั้งสองข้างพักอยู่บนโต๊ะ เซ็นเซอร์ EDA และ PPG ถูกติดตั้งที่มือซ้าย ขณะที่เซ็นเซอร์การหายใจ (RESP) ถูกติดตั้งที่หน้าอกของผู้เข้าร่วม เซ็นเซอร์ทั้งหมดผลิตโดย Biosignal plux สำหรับเซ็นเซอร์ EDA อิเล็กโทรดสองตัวถูกติดตั้งที่ปลาย

นิ้วชี้และนิ้วกลางของมือซ้าย และเซ็นเซอร์ PPG ถูกติดตั้งที่นิ้วกลาง ส่วนเครื่องกระตุ้นประสาทด้วยกระแสไฟฟ้า (TENS) ถูกติดตั้งที่แขนท่อนในและด้านหลังมือขวา โดยตำแหน่งเหล่านี้ถูกเลือกเพื่อสำรวจความเป็นไปได้ในการระบุแหล่งที่มาของอาการปวด การกระตุ้นอาการปวดในแต่ละตำแหน่งและความรุนแรงได้รับการออกแบบให้สลับกันเพื่อหลีกเลี่ยงการคุ้นเคยกับความเจ็บปวดที่ทำซ้ำและผลกระทบจากลำดับของการทดลอง

การทดลองแบ่งออกเป็นสองส่วนหลัก ได้แก่ การระบุความรู้สึกปวดของแต่ละบุคคลและส่วนการกระตุ้นอาการปวด ในส่วนแรกของการทดลอง ผู้เข้าร่วมได้รับการประเมินความรู้สึกปวดโดยใช้โปรโตคอลการทดสอบความรู้สึกเชิงปริมาณ (QST) โดยไม่มีการใช้เซ็นเซอร์ใด ๆ โปรโตคอล QST ใช้เพื่อกำหนดเกณฑ์ความเจ็บปวดและความทนทานต่ออาการปวด โดยเกณฑ์ความเจ็บปวด (อาการปวดระดับน้อย) คือความรุนแรงของการกระตุ้นที่ต่ำที่สุดที่ทำให้รู้สึกเจ็บปวด และความทนทานต่ออาการปวด (อาการปวดมาก) คือความรุนแรงสูงสุดที่สามารถทนได้ก่อนถึงจุดที่ไม่สามารถทนได้ ผู้เข้าร่วมได้รับการกระตุ้นที่เพิ่มขึ้นอย่างค่อยเป็นค่อยไปและได้รับการประเมินความรุนแรงของอาการปวดทางวาจา (0 = "ไม่มีอาการปวด", 10 = "อาการปวดสูงสุด") ความรุนแรงของเครื่อง TENS ที่ทำให้เกิดอาการปวดทั้งสองเกณฑ์ได้รับการบันทึกไว้เพื่อนำไปใช้ในขั้นตอนการกระตุ้น

ในส่วนที่สอง การศึกษาความรุนแรงของอาการปวดและตำแหน่งที่เกิดอาการปวดเริ่มต้น โดยก่อนเริ่มการกระตุ้น ผู้เข้าร่วมจะถูกติดตั้งเซ็นเซอร์ทางสรีรวิทยา EDA, PPG และ RESP ที่มือซ้ายและหน้าอก เมื่อเริ่มต้นการทดลอง จะมีการบันทึกช่วงพื้นฐาน 60 วินาที โดยให้ผู้เข้าร่วมคงสภาพสงบ ช่วงพื้นฐานนี้จะใช้เป็นสภาวะที่ไม่มีอาการปวดสำหรับการจำแนกประเภท จากนั้น การกระตุ้นจะถูกสลับระหว่างความรุนแรง (ต่ำหรือสูง) และตำแหน่ง (แขนท่อนล่างหรือมือ) โดยการกระตุ้นจะทำซ้ำทั้งหมด 6 ครั้ง ครั้งละ 10 วินาที หลังจากการกระตุ้นแต่ละครั้ง ผู้เข้าร่วมได้รับการขอให้ประเมินความรุนแรงของการกระตุ้นทางวาจาโดยใช้มาตราส่วนเดียวกับที่ใช้ในการประเมินความรู้สึกปวด (0 = ไม่มีอาการปวด, 10 = อาการปวดสูงสุด) หลังจากประเมินความรุนแรงของอาการปวดแล้ว จะมีช่วงพัก 40 วินาทีเพื่อให้สัญญาณทางสรีรวิทยาทั้งหมดกลับสู่ระดับพื้นฐาน โดยรวมแล้วจะมีการบันทึกทั้งหมด 24 ครั้ง (2 ความรุนแรง × 2 ตำแหน่ง × 6 การทำซ้ำ) จากผู้เข้าร่วมแต่ละคน การทดลองทั้งหมดใช้เวลาประมาณหนึ่งชั่วโมง (30 นาทีสำหรับการเตรียมการและการประเมินความรู้สึกปวดส่วนบุคคล และ 30 นาทีสำหรับการกระตุ้นอาการปวด)

2.3. Pre-processing

ข้อมูลทางสรีรวิทยาทั้งหมดถูกสุ่มตัวอย่างที่ 100 Hz โดยที่แต่ละสัญญาณทางสรีรวิทยาจะได้รับการจัดการแยกจากกันเพื่อขจัดสัญญาณรบกวน ข้อมูลการหายใจถูกกรองด้วย Band-pass Butterworth filter (0.1–0.5 Hz) เนื่องจากช่วงความถี่นี้ตรงกับความถี่การหายใจของร่างกายมนุษย์ สำหรับข้อมูล EDA ได้ใช้ Low-pass Butterworth filter (5 Hz) เพื่อลบการสั่นสะเทือนความถี่สูงและการแทรกแซงจากสายไฟ

หลังจากนั้น สัญญาณ EDA จะถูกแยกเป็นส่วนที่มีความถี่ผันผวน (Phasic) และส่วนที่มีความถี่คงที่ (Tonic) ตามกระบวนการมาตรฐานของ Makowski et al. (21) โดยใช้ High-pass Butterworth filter (0.05 Hz) และ Low-pass Butterworth filter (0.05 Hz) ตามลำดับ แต่ส่วนที่มีความถี่ผันผวนถูกเลือกใช้สำหรับการวิเคราะห์ที่เหลือ เนื่องจากมันให้การตอบสนองที่ดีกว่าต่อการเปลี่ยนแปลงอย่างรวดเร็วใน EDA ที่ตอบสนองต่อการกระตุ้น ข้อมูล PPG ถูกกรองด้วย Band-pass Butterworth filter (0.04–1.7 Hz) เพื่อให้ได้ข้อมูลที่เกี่ยวข้องกับระบบหัวใจและหลอดเลือด ซึ่งสอดคล้องกับการเต้นของหัวใจปกติ (60–100 บีตต่อวินาที) และการเต้นของหัวใจที่สัมพันธ์กับการหายใจ (respiratory sinus arrhythmia)

2.4. Data analysis

2.4.1. Validation of experimental conditions

การศึกษาใช้การออกแบบการทดลองแบบภายในบุคคล (within-subjects design) โดยที่ผู้เข้าร่วมทุกคนจะทำการทดลองในทุกเงื่อนไขการทดลอง ซึ่งประกอบไปด้วย 4 เงื่อนไข ได้แก่ (1) อาการปวดระดับต่ำที่มือ, (2) อาการปวดระดับต่ำที่แขนท่อนล่าง, (3) อาการปวดระดับสูงที่มือ, และ (4) อาการปวดระดับสูงที่แขนท่อนล่าง เพื่อยืนยันความถูกต้องของการออกแบบการทดลองและเงื่อนไขการทดลอง ผู้เข้าร่วมจะรายงานอาการปวดของตนเองหลังจากการกระตุ้นในแต่ละครั้ง ซึ่งจะใช้เป็นตัววัดอาการปวด การแจกแจงข้อมูลถูกตรวจสอบด้วยการทดสอบ Shapiro-Wilk ซึ่งแสดงให้เห็นว่า ข้อมูลไม่เบี่ยงเบนจากการแจกแจงปกติอย่างมีนัยสำคัญ ($p > 0.05$) ดังนั้นจึงใช้การทดสอบทางพารามิเตอร์ การวิเคราะห์ความแปรปรวนแบบทางเดียว (One-way ANOVA) ถูกใช้เพื่อตรวจสอบว่า การประเมินอาการปวดมีความสัมพันธ์กับเงื่อนไขการทดลอง (อาการปวดระดับสูงและต่ำ) ในกลุ่มผู้เข้าร่วมทั้งหมด โดยสมมติฐานศูนย์ (Ho) คือการรับรู้ถึงอาการปวดไม่ขึ้นอยู่กับเงื่อนไขการทดลอง เมื่อพบความแตกต่างที่มีนัยสำคัญ การเปรียบเทียบหลังการทดสอบจะถูกทำโดยใช้การทดสอบ Tukey’s HSD (honestly significant difference)

2.4.2. Feature extraction

เพื่อการสกัดคุณลักษณะจากข้อมูลเซ็นเซอร์ ข้อมูลจากเซ็นเซอร์ทั้งหมดถูกวิเคราะห์โดยใช้หน้าต่าง (windows) ขนาดหน้าต่าง 10 วินาทีถูกเลือกใช้ในการสกัดคุณลักษณะ เนื่องจากขนาดหน้าต่างนี้เป็นขนาดที่เหมาะสมที่สุดหลังจากทดสอบหลายขนาดหน้าต่าง (เช่น 1-10 วินาที) โดยใช้ข้อมูลจากสามเซ็นเซอร์ร่วมกัน คุณลักษณะที่ได้จากแต่ละหน้าต่างข้อมูลมีสองประเภท ได้แก่ คุณลักษณะทางสถิติจากเซ็นเซอร์ทางสรีรวิทยทั้งหมด และคุณลักษณะเฉพาะจากเซ็นเซอร์แต่ละตัว (EDA, RESP, PPG) จากเซ็นเซอร์ทางสรีรวิทยาทั้งสามตัว มีการสกัดคุณลักษณะทางสถิติที่เป็นที่รู้จักจำนวน 10 ตัว ได้แก่: ค่าเฉลี่ย (Mean), ส่วนเบี่ยงเบนมาตรฐาน (Standard deviation), ค่าต่ำสุด (Min), ค่าสูงสุด (Max), ช่วง (Range), มัธยฐาน (Median), ผลรวม (Sum), ช่วง (Range), ค่าควอไทล์ที่ 1 (Q1), ค่าควอไทล์ที่ 2 (Q2), ค่าควอไทล์ที่ 3 (Q3),

ค่าควอไทล์ที่ 4 (Q4), และช่วงระหว่างควอไทล์ (Inter-Quartile Range) สำหรับคุณลักษณะเฉพาะ มีการใช้เครื่องมือ Neurokit2 Python toolbox ในการสกัด สำหรับชุดคุณลักษณะที่สกัดทั้งหมด ผู้อ่านที่สนใจสามารถอ้างอิงไปยังแหล่งที่มาเพื่อรายละเอียดเพิ่มเติม หลังจากการลบคุณลักษณะที่มีค่าสูญหายมากกว่า 50% ของจำนวนตัวอย่างทั้งหมด มีการสกัดคุณลักษณะทั้งหมด 122 ตัว โดยมีจำนวนคุณลักษณะที่สกัดจากเซ็นเซอร์แต่ละตัว ดังนี้: 12 คุณลักษณะจาก EDA, 30 จากRESP และ 80 จาก PPG โดยช่วงของแต่ละคุณลักษณะถูกปรับขนาดใหม่ให้เป็นช่วง [0,1] เพื่อทำให้ช่วงของคุณลักษณะมีความสอดคล้องกัน

2.4.3. Feature selection

การเลือกคุณลักษณะ (Feature selection) ได้รับการดำเนินการเพื่อลดจำนวนคุณลักษณะและเพิ่มความแม่นยำของโมเดลการเรียนรู้ โดยการเลือกคุณลักษณะนี้ทำหลังจากกระบวนการสกัดคุณลักษณะเสร็จสิ้น เกณฑ์การเลือกใช้ข้อมูลจากการวัดความสัมพันธ์ร่วม (joint mutual information, JMI) ซึ่งวิธีนี้สามารถใช้ในการจัดอันดับคุณลักษณะตามการรวมข้อมูลร่วม (mutual information) ของแต่ละคุณลักษณะได้ JMI มุ่งเน้นที่จะระบุคุณลักษณะที่ให้ข้อมูลมากที่สุด โดยมีความสัมพันธ์สูงกับตัวแปรเป้าหมายและในขณะเดียวกันจะลดความซ้ำซ้อนระหว่างคุณลักษณะต่างๆ JMI วัดข้อมูลร่วมระหว่างตัวแปรเป้าหมายและแต่ละคุณลักษณะเพื่อหาความสัมพันธ์ทางสถิติระหว่างตัวแปรทั้งสอง กล่าวคือ มันวัดปริมาณข้อมูลที่แต่ละคุณลักษณะให้เกี่ยวกับตัวแปรเป้าหมาย คุณลักษณะที่มีข้อมูลร่วมสูงจะถือว่าให้ข้อมูลที่มีความสำคัญและมีแนวโน้มที่จะช่วยให้การทำนายมีความแม่นยำมากขึ้น นอกจากนี้ วิธีนี้ยังใช้ข้อมูลร่วมระหว่างคุณลักษณะต่างๆ เพื่อระบุคุณลักษณะที่ซ้ำซ้อนหรือไม่เกี่ยวข้อง ซึ่งทำให้ JMI สามารถจับข้อมูลที่มีความหลากหลายและเป็นเอกลักษณ์จากชุดคุณลักษณะได้ โดยการระบุคุณลักษณะที่มีข้อมูลร่วมสูงกับตัวแปรเป้าหมายและข้อมูลร่วมต่ำกับกันและกัน เหตุผลที่เลือกใช้ JMI เพราะมันนำเสนอการแลกเปลี่ยนที่ดีในแง่ของความแม่นยำ ความเสถียร และความยืดหยุ่นเมื่อเทียบกับวิธีการจัดอันดับอื่นๆ นอกจากนี้ JMI ยังประเมินคุณลักษณะโดยไม่ขึ้นกับโมเดลการจำแนกประเภทใดๆ และการคำนวณจะทำเพียงครั้งเดียวเท่านั้น วิธีนี้ยังใช้วิธีการ รวมคุณลักษณะ (feature fusion) โดยการรวมคุณลักษณะที่คำนวณทั้งหมดก่อนทำการจำแนกประเภท.

2.4.4. Classification

วัตถุประสงค์หลักของการจำแนกประเภทคือการระบุความรุนแรงของอาการปวดภายใต้สภาวะการปวดต่างๆ โดยใช้ข้อมูลทางสรีรวิทยา งานการจำแนกประเภทหลักสามประการถูกดำเนินการ ได้แก่ (1) ไม่มีอาการปวด vs อาการปวดมาก (2) ไม่มีอาการปวด vs ปวดเล็กน้อย vs ปวดรุนแรง และ (3) อาการปวดที่แขน (ปวดเล็กน้อยและปวดรุนแรง) vs อาการปวดที่มือ (ปวดเล็กน้อยและปวดรุนแรง) ชุดข้อมูลประกอบด้วยจำนวนตัวอย่างที่เท่ากัน ในแต่ละประเภท รวมทั้งสิ้น 528 ตัวอย่าง (6 รอบ × 2 ความรุนแรงของอาการปวด × 2 ตำแหน่ง × 22 ผู้เข้าร่วม) สำหรับการจำแนกประเภทนี้ ได้ใช้โมเดลการเรียนรู้เครื่องที่เป็นที่รู้จักสามตัว ได้แก่ Linear Discriminant Analysis (LDA), Decision Tree (DT), และ Support Vector

Machine (SVM)โดยใช้ Gaussian Kernel (RBF) ทั้งหมด โมเดลการเรียนรู้และงานการจำแนกประเภทได้รับการดำเนินการโดยใช้ Python 3.10

การตรวจสอบความถูกต้องแบบ leave-one-subject-out ถูกใช้ในการประเมินโมเดลการจำแนกประเภท โดยในวิธีนี้ โมเดลการเรียนรู้จะได้รับการฝึกจากข้อมูลของผู้เข้าร่วม 21 คน และทดสอบด้วยข้อมูลของผู้เข้าร่วมที่เหลือ วิธีนี้จะทำซ้ำจนกว่าผู้เข้าร่วมทั้งหมดจะได้เป็นส่วนหนึ่งของชุดข้อมูลการทดสอบก่อนอื่น ค่าประสิทธิภาพอ้างอิงจะได้รับจากการใช้คุณลักษณะทั้งหมด (โดยไม่เลือกคุณลักษณะ) จากแต่ละเซ็นเซอร์แยกกัน และจากนั้นก็ใช้ร่วมกับเซ็นเซอร์ทั้งหมด ในขั้นตอนนี้ การปรับพารามิเตอร์ของโมเดลการเรียนรู้จะทำโดยใช้ grid search พร้อมการตรวจสอบความถูกต้องแบบ 10-fold โดยใช้ชุดฝึกอบรมเท่านั้นและใช้คุณลักษณะทั้งหมด 122 ตัว พารามิเตอร์ที่ใช้ ได้แก่ สำหรับ SVM พารามิเตอร์ C [1,10,100,1000] และ y [0.0001,0.001,0.01,0.1]; สำหรับ DT ฟังก์ชันเกณฑ์ [Gini, Entropy]; และสำหรับ LDA ไม่มีการปรับพารามิเตอร์เพราะ LDA มีวิธีแก้ปัญหาที่เป็นรูปแบบปิด จากนั้นหลังจากการเลือกคุณลักษณะโดยใช้ JMI, คุณลักษณะทั้งหมดจะถูกจัดอันดับและนำไปฝึกและทดสอบโมเดลการจำแนกประเภท รูปที่ 2 แสดงการนำเสนอกราฟิกของกระบวนการนี้ ในทั้งสองกรณี ผลลัพธ์สุดท้ายจะถูกแสดงเป็นค่าเฉลี่ยและค่าเบี่ยงเบนมาตรฐานของเมตริกประสิทธิภาพจากทุกๆ ผู้เข้าร่วมในการทดสอบ

3 Results

ในส่วนนี้จะอธิบายผลการเปรียบเทียบระหว่างวิธีการเรียนรู้ของคอมพิวเตอร์ 3 แบบ (LDA, SVM, DT) ที่ใช้แยกแยะสถานการณ์ทดลองต่างๆ การวิเคราะห์ได้ดำเนินการใน 3 ส่วนหลัก ส่วนแรก แสดงผลการตรวจสอบว่าการทดลองถูกต้องหรือไม่ ส่วนที่สอง ดูผลการแยกประเภทจากเครื่องวัดแต่ละตัว และจากการใช้เครื่องวัดทุกตัวพร้อมกัน ส่วนที่สาม มีการใช้การปรับค่าพารามิเตอร์เพื่อระบุชุดคุณลักษณะที่ดีที่สุดในการจำแนกแต่ละสภาวะความเจ็บปวด

3.1. Validation of experimental conditions

การสรุปการให้คะแนนความเจ็บปวดของแต่ละบุคคลตามสภาวะการทดลองทั้งสี่ ความเจ็บปวดระดับสูง ได้รับคะแนนสูงกว่าระดับความเจ็บปวดเริ่มต้น เนื่องจากความทนต่อความเจ็บปวดใช้ความเข้มของการกระตุ้นที่สูงกว่ามาก ในการออกแบบสภาวะการทดลอง มีการคาดการณ์ว่ายิ่งมีการกระตุ้นสูงขึ้นประสบการณ์ความเจ็บปวดของผู้เข้าร่วมจะยิ่งสูงขึ้น และส่งผลให้คะแนนความเจ็บปวดสูงขึ้นด้วย ซึ่งคะแนนความเจ็บปวดของผู้เข้าร่วมเป็นไปตามการตอบสนองที่คาดการณ์ไว้ ส่วนของตำแหน่งทางกายวิภาคและระดับความเจ็บปวด เห็นได้ชัดว่าคะแนนความเจ็บปวดเชิงตัวเลขในสภาว ความเจ็บปวดระดับสูง สูงกว่าเล็กน้อยเมื่อให้การกระตุ้นที่มือ (8.69 ± 1.16) เทียบกับที่แขนท่อนปลาย (8.37 ± 1.34) ในทำนองเดียวกัน คะแนน

ความเจ็บปวดเชิงตัวเลขในสภาวะระดับความเจ็บปวดเริ่มต้นสูงกว่าเล็กน้อยเมื่อให้การกระตุ้นที่มือ (3.45 ± 1.57) เทียบกับที่แขนท่อนปลาย (3.31 ± 1.65)

ประการที่สอง เพื่อตรวจสอบความถูกต้องของสภาวะการทดลอง คะแนนความเจ็บปวดเชิงตัวเลขจากผู้เข้าร่วมทั้งหมดได้รับการวิเคราะห์โดยใช้วิธีทางสถิติที่อธิบายไว้ข้างต้น พบว่ามีความแตกต่างอย่างมีนัยสำคัญทางสถิติในคะแนนความเจ็บปวดระหว่างอย่างน้อยสองกลุ่ม ($F(2, 18) = 401.23$, $p = 0.000$) การทดสอบ Tukey's HSD สำหรับการเปรียบเทียบหลายกลุ่มพบว่าค่าเฉลี่ยของคะแนนความเจ็บปวดแตกต่างกันอย่างมีนัยสำคัญระหว่างความทนต่อความเจ็บปวด (ความเจ็บปวดระดับสูง) และระดับความเจ็บปวดเริ่มต้น (ความเจ็บปวดระดับต่ำ) ทั้งที่แขน ($p < 0.001$, 95% C.I. = [-5.78, -4.69]) และแขนท่อนปลาย ($p < 0.001$, 95% C.I. = [-5.59, -4.51]) ไม่พบความแตกต่างอย่างมีนัยสำคัญทางสถิติในค่าเฉลี่ยคะแนนความเจ็บปวดระหว่างตำแหน่งการกระตุ้นสองตำแหน่ง (แขนและแขนท่อนปลาย) ในระหว่างความทนต่อความเจ็บปวด (ความเจ็บปวดระดับสูง) ($p = 0.413$, 95% C.I. = [-0.21, 0.86]) และในระหว่างระดับความเจ็บปวดเริ่มต้น (ความเจ็บปวดระดับต่ำ) ($p = 0.91$, 95% C.I. = [-0.40, 0.68]) และช่วงความเชื่อมั่น (C.I.) แคบ แสดงว่าการประมาณค่าความแตกต่างของเรามีความแม่นยำค่อนข้างสูง สิ่งนี้สะท้อนว่าสภาวะการทดลองส่งผลต่อคะแนนความเจ็บปวดจริง และจำนวนผู้เข้าร่วมไม่ส่งผลกระทบต่อความแม่นยำของการประมาณค่าในการศึกษานี้

3.2 Reference values

ผลการคำนวณคุณลักษณะจากแต่ละเซ็นเซอร์จะถูกใช้เพื่อประเมินผลการทำงานของโมเดลการเรียนรู้ ผลการทดสอบจะถูกตรวจสอบโดยการใช้คุณลักษณะจากแต่ละเซ็นเซอร์แยกกัน และจากการรวมคุณลักษณะทั้งหมด ผลลัพธ์จากการทดสอบใช้โมเดล LDA, SVM และ DT ผลลัพธ์นี้แสดงถึงความแม่นยำในการจำแนกประเภทและส่วนเบี่ยงเบนมาตรฐาน ขณะที่จำนวนคุณลักษณะที่ใช้ในแต่ละโมเดลจะแสดงในวงเล็บ ผลลัพธ์การทดสอบเบื้องต้นจะถูกใช้ในการประเมินผลโมเดลการเรียนรู้ในขั้นตอนการเลือกคุณลักษณะ

มีการจำแนก3ประเภท ได้แก่ การระบุความเจ็บปวด (ไม่มีความเจ็บปวด, ความเจ็บปวดมาก), การจำแนกประเภทหลายกลุ่ม (ไม่มีความเจ็บปวด, ความเจ็บปวดน้อย, ความเจ็บปวดมาก), และการระบุตำแหน่งของความเจ็บปวด (แขน, แขนบน) ผลการจำแนกประเภทจากทั้งสามแสดงผลลัพธ์ทแตกต่างกันอันดับแรก ข้อมูลจาก EDA ให้ผลลัพธ์ที่ดีที่สุดในการระบุความเจ็บปวด (ไม่มีความเจ็บปวด, ความเจ็บปวด) โมเดลการเรียนรู้สองตัวที่แสดงผลลัพธ์ที่ดีที่สุดเมื่อใช้คุณลักษณะสิบสองรายการจากข้อมูล EDA ได้แก่ LDA (acc = 0.938) และ SVM (acc = 0.931) ในขณะที่ผลลัพธ์จากการใช้คุณลักษณะรวมทั้งหมด (n = 122) แสดงผลลัพธ์ที่คล้ายกันจากโมเดล SVM (acc = 0.931) อันดับสอง EDA ยังให้ผลลัพธ์ที่ดีที่สุดในงานจำแนกประเภทหลายกลุ่ม ในกรณีนี้, SVM ให้ผลลัพธ์ที่ดีที่สุดเมื่อใช้ EDA เพียงอย่างเดียว (acc = 0.678) และผลลัพธ์ที่คล้ายกันเมื่อใช้ข้อมูลจากเซ็นเซอร์ทั้งหมดร่วมกัน (acc = 0.672) อันดับสาม คุณลักษณะจาก PPG

แสดงผลลัพธ์ที่ดีที่สุดในการระบุตำแหน่งของความเจ็บปวด (แขน, แขนบน) โมเดล DT ให้ผลลัพธ์ที่ดีที่สุด (acc = 0.531) เมื่อใช้คุณลักษณะจากข้อมูล PPG เพียงอย่างเดียว

3.3. Classification after feature selection

หลังจากที่ใช้การคำนวณข้อมูลร่วม (joint mutual information, JMI) เพื่อหาความสำคัญของแต่ละคุณลักษณะแล้ว คุณลักษณะทั้งหมดจะถูกจัดลำดับและใช้ในการฝึกและทดสอบโมเดลการเรียนรู้ การระบุโมเดลที่มีประสิทธิภาพดีที่สุดจะถูกทดสอบแบบเป็นระบบโดยใช้จำนวนคุณลักษณะต่างๆ ตามความสำคัญของคุณลักษณะ กระบวนการประเมินคุณลักษณะนี้จะถูกดำเนินการสำหรับแต่ละงานการจำแนกประเภท การค้นหาแบบเป็นระบบเพื่อระบุชุดคุณลักษณะที่ดีที่สุดจะดำเนินการโดยใช้สามโมเดลการเรียนรู้ ได้แก่ SVM LDA และ DT

3.3.1 Identification of pain

งานการเรียนรู้แรกที่ถูกประเมินคือการระบุความเจ็บปวด (ไม่มีความเจ็บปวด vs ความเจ็บปวดมาก) มีผลลัพธ์ความแม่นยำเฉลี่ย (acc = 93.1) ที่ใช้คุณลักษณะทั้งหมด (n = 122) ผลลัพธ์ที่ดีที่สุด (acc = 94.1 + 8) ซึ่งได้จากการใช้โมเดล SVM โดยใช้ 112 คุณลักษณะ โมเดล DT แสดงผลลัพธ์ที่คล้ายกัน (acc = 93.8 + 7) โดยใช้ 49 คุณลักษณะ และโมเดล LDA แสดงผลลัพธ์ที่ต่ำกว่าเล็กน้อย (acc = 92.8 + 9) โดยใช้ 28 คุณลักษณะ จากการสังเกตจะเห็นว่าโมเดล SVM และ DT ได้ผลลัพธ์ที่ดีกว่าผลลัพธ์มาตรฐานโดยใช้คุณลักษณะที่น้อยกว่า นอกจากนี้ยังสามารถสังเกตได้ว่าเมื่อใช้แค่ 10 คุณลักษณะ โมเดล SVM ยังให้ผลลัพธ์ที่ใกล้เคียงกับค่ามาตรฐาน (acc = 93.2 + 8) ชุดคุณลักษณะ 10 ตัวนี้ประกอบด้วยคุณลักษณะจาก EDA เท่านั้น ซึ่งมีลำดับความสำคัญลดลงตามลำดับดังนี้: EDA range, EDA std, EDA max, EDA q3, EDA sum, EDA mean, EDA median, EDA q1, EDA lqr, EDA min

3.3.2 Multiclass problem

ปัญหาการเรียนรู้หลายกลุ่ม (ไม่มีความเจ็บปวด, ความเจ็บปวดน้อย, ความเจ็บปวดมาก) เป็นงานการเรียนรู้ที่สอง ผลลัพธ์สำหรับปัญหาการเรียนรู้หลายกลุ่มจะเห็นว่า โมเดลสองตัว (SVM และ LDA) แสดงผลลัพธ์ที่ดีกว่าค่าความแม่นยำมาตรฐาน (acc = 67.2 + 14) เมื่อใช้การรวมคุณลักษณะทั้งหมดที่ได้รับมา ผลลัพธ์ที่ดีที่สุด (acc = 69.2 + 14) ได้รับจากการใช้โมเดล LDA โดยใช้ 49 คุณลักษณะ ผลลัพธ์ที่คล้ายกัน (acc = 69.0 + 16) ได้รับจากการใช้โมเดล SVM โดยใช้ 30 คุณลักษณะ การทำงานที่แย่ที่สุดจากโมเดลการเรียนรู้ทั้งสามตัวแสดงโดยโมเดล DTC ซึ่งได้ผลลัพธ์ที่ดีที่สุด (acc = 60.0 + 13) โดยใช้ 11 คุณลักษณะ จะสังเกตได้ว่าโมเดล SVM เมื่อใช้แค่ 8 คุณลักษณะให้ผลลัพธ์ที่ต่ำกว่าผลลัพธ์ที่ดีที่สุดที่ได้รับจากโมเดล LDA; ชุดคุณลักษณะ 8 ตัวนี้ก็ประกอบด้วยคุณลักษณะจาก EDA เท่านั้น รวมถึง (โดยลำดับความสำคัญลดลง): EDA max, EDA q3, EDA median, EDA q1, EDA mean, EDA sum, EDA range, EDA min

3.3.3. Pain location

งานเรียนรู้ล่าสุดคือการระบุตำแหน่งของอาการปวด หมายถึงการระบุตำแหน่งทางกายวิภาคที่อาการปวดเกิดขึ้น สถานที่ทางกายวิภาคสองแห่งที่ได้รับการศึกษา ได้แก่ แขนท่อนล่างและมือ ทั้งสองอยู่ที่แขนขวาของผู้เข้าร่วมงาน ผลการจำแนกประเภทสำหรับงานเรียนรู้นี้ โดยแสดงค่าอ้างอิง (acc = 51.4 ± 8) จากการใช้คุณลักษณะที่มีอยู่ทั้งหมด ในกรณีนี้ทุกการเรียนรู้ได้แสดงผลที่ดีกว่าค่าอ้างอิง โดยที่โมเดล SVM แสดงผลที่ต่ำที่สุด (acc = 51.7 ± 5) จากสามตัวจำแนก ซึ่งใช้คุณลักษณะ 67 ตัว โมเดล LDA ได้ผลลัพธ์ที่ดีกว่าเล็กน้อย (acc = 52.1 ± 10) ด้วยคุณลักษณะเพียง 4 ตัว และสุดท้าย โมเดล DT ได้ผลลัพธ์ที่ดีที่สุด (acc = 56.0 ± 8) โดยใช้คุณลักษณะ 8 ตัว ชุดคุณลักษณะ 8 ตัวนี้ประกอบด้วยคุณลักษณะจากข้อมูล EDA เท่านั้น ได้แก่ (ตามลำดับความสำคัญจากมากไปน้อย) EDA q3, EDA max, EDA min, EDA q1, EDA median, EDA lqr, EDA mean, EDA

4. Discussion

ในการศึกษานี้ได้ดำเนินการทดลองกระตุ้นเพื่อระบุชุดของตัวบ่งชี้ที่สามารถใช้ในการประเมินอาการปวดของมนุษย์ การทดลองออกแบบมาเพื่อกระตุ้นผู้เข้าร่วมด้วยระดับความเจ็บปวดสองระดับ (ต่ำและสูง) และในตำแหน่งในร่างกาย คือ แขนท่อนล่างและมือ การคำนวณคุณลักษณะทั้งหมด 112 ตัวจากเซ็นเซอร์สามประเภท EDA, PPG, และ Resp) โดยใช้เทคนิคการคัดเลือกคุณลักษณะเพื่อรับคุณลักษณะที่สำคัญที่สุดสำหรับแต่ละงานการเรียนรู้ และหลังจากนั้นคุณลักษณะเหล่านี้ได้ถูกประเมินในงานการเรียนรู้ต่างๆ หลังจากการทำงานการจำแนกประเภทแต่ละงาน จะมีชุดคุณลักษณะที่กระชับมากขึ้นที่ได้รับการระบุ ซึ่งชุดคุณลักษณะเหล่านี้แสดงถึงกลุ่มของตัวบ่งชี้ทางสรีรวิทยาที่เป็นไปได้สำหรับการประเมินอาการปวดอย่างเป็นวัตถุประสงค์

การทดลองและสมมติฐานโดยรวมของการทดลองได้รับการยืนยันการเพิ่มการกระตุ้นระดับความเจ็บปวด ทำให้ประสบการณ์อาการปวดของผู้เข้าร่วมเพิ่มขึ้น ($p < 0.000$) ซึ่งสอดคล้องกับการทดลองก่อนหน้านี้ที่ดำเนินการในงานศึกษาอื่นๆ ตัวอย่างเช่นในการทดลองเพื่อสังเกตผลกระทบของการกระตุ้นอาการปวดจากความร้อนจากข้อมูล EDA พบว่ามีความแตกต่างทางสถิติที่สำคัญระหว่างสถานะไม่มีอาการปวดและอาการปวด ในทำนองเดียวกันในการศึกษาที่ใช้การถ่ายภาพใกล้อินฟราเรดฟังก์ชัน (fNIRS) และการกระตุ้นด้วยความร้อน พบว่าการให้คะแนนอาการปวดของแต่ละบุคคลสูงขึ้นในระหว่างการทนต่ออาการปวดมากกว่าในระหว่างการกระตุ้นที่มีขีดจำกัดของความเจ็บปวด

การศึกษานี้แสดงผลลัพธ์ที่มีแนวโน้มที่ดีในการระบุตัวอาการปวด (เช่น ไม่มีอาการปวด vs อาการปวด) โดยใช้ข้อมูลจากเซ็นเซอร์ EDA แม้ว่าผลลัพธ์ที่ดีที่สุดจะได้จากการใช้คุณลักษณะ 112 ตัวจากการรวมเซ็นเซอร์ทั้งสามตัว (EDA, RESP, PPG) ด้วยความแม่นยำ 94.1% แต่ก็พบว่าโมเดล SVM ได้ผลลัพธ์ที่เทียบเท่า

กับการใช้ 10 อันดับแรกของคุณลักษณะด้วยความแม่นยำ 93.2% และชุดคุณลักษณะ 10 ตัวนี้คำนวณจากข้อมูล EDA ซึ่งมีน้ำหนักสูงสุดในบริบทของตัวจำแนกประเภทmulti model การเปรียบเทียบตรงกันกับการศึกษาอื่นๆ เป็นเรื่องยากเนื่องจากใช้เงื่อนไขการทดลอง สัญญาณสรีรวิทยาและกลุ่มตัวอย่างที่แตกต่างกันและวิธีการยืนยันผลรวมถึงโมเดลการจำแนกประเภทที่แตกต่างกันด้วย ในการเปรียบเทียบกับการศึกษาอื่นๆ สำหรับการระบุตัวอาการปวดโดยใช้ข้อมูลจากเซ็นเซอร์ EDA งานศึกษาของเราได้แสดงผลลัพธ์ที่เทียบเท่ากับการศึกษาอื่นๆ ตัวอย่างเช่น Susam et al. ใช้ EDA เพื่อแยกความแตกต่างระหว่างอาการปวดที่รุนแรง (ปานกลางถึงรุนแรง) กับไม่มีอาการปวดในเด็กหลังการผ่าตัด โดยมีความแม่นยำ 77.66% ด้วยการใช้ SVM เชิงเส้น ในการศึกษาครั้งอื่นที่ใช้ข้อมูล EDA ที่เก็บจากผู้ป่วยหลังการผ่าตัด Aqajari et al. ใช้โมเดล random forest (RF) เพื่อแยกความแตกต่างระหว่างฐานข้อมูล (ไม่มีอาการปวด) และอาการปวดระดับต่ำ และระหว่างฐานข้อมูลกับอาการปวดระดับสูง โดยมีความแม่นยำ 86% และ 61.5% ตามลำดับ นอกจากนี้ยังมีงานวิจัยของ Aqajari et al ที่ศึกษาการระบุความเจ็บปวดโดยใช้การตอบสนองของ EDA ในการทดลองความเจ็บปวดจากความร้อน โดยใช้โมเดล polynomial SVM ในการแยกแยะระหว่างไม่มีความเจ็บปวดกับมีความเจ็บปวด ซึ่งได้ความแม่นยำ 90% และอีกงานหนึ่งใช้ Gaussian SVM ในการแยกแยะระหว่างไม่มีความเจ็บปวดกับความเจ็บปวดระดับสูง โดยใช้ข้อมูล EDA ซึ่งได้ความแม่นยำ 87%

การศึกษานี้ยังได้ทดลองจำแนกระดับความเจ็บปวดออกเป็น 3 ระดับ คือ ไม่มีความเจ็บปวด ปวดน้อย และปวดมาก ซึ่งพบว่ามีความแม่นยำต่ำกว่าการจำแนกแบบ 2 ระดับ (ปวด/ไม่ปวด) ซึ่งเป็นเรื่องที่เข้าใจได้ เนื่องจากการจำแนก 3 ระดับมีโอกาสถูกเพียง 33.33% หรือ 1 ใน 3 เท่านั้น นอกจากนี้อีกสาเหตุที่อาจทำให้ความแม่นยำต่ำคือ การตอบสนองต่อความเจ็บปวดในแต่ละระดับคล้ายๆ กัน

ผลความแม่นยำที่ได้ก็สอดคล้องกับงานวิจัยอื่นๆ ที่พยายามจำแนกระดับความเจ็บปวดหลายระดับ เช่น งานวิจัยของ Kong และคณะ ที่ใช้ข้อมูล EDA แยกแยะระหว่างความเจ็บปวดระดับต่ำ ปานกลาง และสูง ได้ความแม่นยำ 63% ส่วน Jiang และคณะ ใช้การวัดอัตราการเต้นของหัวใจ อัตราการหายใจ EDA และคลื่นไฟฟ้ากล้ามเนื้อใบหน้า ในการจำแนกระหว่างไม่ปวด ปวดเล็กน้อย และปวดรุนแรง ได้ความแม่นยำ 68.2% โดยใช้โครงข่ายประสาทเทียม และ Yang และคณะ ใช้การวัดระดับออกซิเจนในเลือด ความดันโลหิต อัตราการเต้นของหัวใจ การหายใจ และอุณหภูมิ เพื่อระบุความเจ็บปวด (ปกติ ปวดน้อย และปวดมาก) ในผู้ป่วยโรคเม็ดเลือดแดงรูปเคียว ได้ความแม่นยำ 40.4% โดยใช้แบบจำลองการถดถอยโลจิสติกแบบหลายกลุ่ม

นอกจากนี้การศึกษานี้ยังได้สำรวจความเป็นไปได้ในการระบุตำแหน่งของความเจ็บปวดโดยใช้ข้อมูลทางสรีรวิทยา ซึ่งผลการจำแนกมีความแม่นยำต่ำที่สุด (56.0%) ในบรรดางานทั้งสามอย่าง ซึ่งเป็นเรื่องที่คาดการณ์ได้เนื่องจากเป็นงานที่ยากมาก โดยเฉพาะอย่างยิ่งเมื่อตำแหน่งที่กระตุ้นอยู่บนแขนเดียวกัน จากการสืบค้นยังไม่พบงานวิจัยอื่นที่ศึกษาการระบุตำแหน่งความเจ็บปวดโดยใช้ข้อมูลทางสรีรวิทยา การใช้เซนเซอร์วัดระบบประสาท เช่น EEG หรือ fNIRS ที่ให้ข้อมูลเพิ่มเติมอาจทำให้การระบุตำแหน่งความเจ็บปวดแม่นยำมากขึ้น การค้นหาตำแหน่งความเจ็บปวดมีความสำคัญอย่างยิ่งสำหรับผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยเฉพาะ

ในสถานการณ์การระบาดของโควิด-19 ที่มีผู้ป่วยใส่ท่อช่วยหายใจจำนวนมาก ซึ่งการใส่ท่อช่วยหายใจอาจก่อให้เกิดความเจ็บปวดและบาดแผลทางจิตใจ แม้จะได้รับยากล่อมประสาทและยาแก้ปวดแล้วก็ตาม จากการศึกษาของ Clukey และคณะ พบว่าการให้ยากล่อมประสาทอาจบดบังความเจ็บปวดที่ควบคุมไม่ได้ในผู้ป่วยใส่ท่อช่วยหายใจ และทำให้พวกเขาไม่สามารถสื่อสารอาการนี้กับพยาบาลได้ เมื่อผู้ป่วยใส่ท่อช่วยหายใจยังมีสติ พวกเขาสามารถชี้บอกตำแหน่งที่เจ็บปวดหรือชี้ตำแหน่งบนภาพร่างกายได้ แต่เมื่อผู้ป่วยไม่สามารถรายงานอาการด้วยตนเองได้ การระบุตำแหน่งความเจ็บปวดจะยากมาก ในกรณีเช่นนี้ พยาบาลจะปฏิบัติตามแนวทางการคัดกรองความเจ็บปวด ซึ่งรวมถึงการตรวจร่างกายด้วยการคลำและการฟัง เพื่อประเมินความเจ็บปวดและตำแหน่งที่ปวด พยาบาลจะสังเกตสัญญาณที่ไม่ใช้คำพูดระหว่างการตรวจ เช่น การร้องไห้ การครวญคราง การแสดงออกทางสีหน้า หรือการเคลื่อนไหวร่างกายเพื่อป้องกันตัว เช่น การระวังหรือกอดส่วนใดส่วนหนึ่งของร่างกาย อย่างไรก็ตาม นี่เป็นงานที่ซับซ้อนและบางครั้งอาจเกิดการตีความข้อมูลผิดพลาดได้ ดังนั้น ระบบที่สามารถระบุความเจ็บปวดและตำแหน่งที่ปวดได้จะช่วยพยาบาลในการประเมินความเจ็บปวดในผู้ป่วยที่ไม่สามารถสื่อสารด้วยคำพูดได้อย่างมาก

การศึกษานี้ได้ออกแบบการใช้เซนเซอร์หลายชนิด (EDA, PPG, RESP) อย่างไรก็ตาม ข้อมูลจากเซนเซอร์ EDA แสดงผลการจำแนกที่ดีที่สุดในทุกงาน แม้ว่าการใช้เทคโนโลยีการตรวจจับหลายอย่างจะถูกนำมาใช้โดยคาดหวังว่าจะช่วยปรับปรุงความแม่นยำในการจำแนก และแม้ว่าสิ่งนี้จะเป็นความจริงบางส่วนเพราะคุณลักษณะรวม (120 ตัว) จากเซนเซอร์ทั้งหมดแสดงผลลัพธ์ที่ดีกว่าเซนเซอร์แต่ละตัวเล็กน้อยในบางงานจำแนก แต่หลังจากกระบวนการคัดเลือกคุณลักษณะ คุณลักษณะที่อิงจาก EDA แสดงความแม่นยำที่ดีกว่าเทคโนโลยีการตรวจจับอื่นๆ ซึ่งสอดคล้องกับการศึกษาต่างๆ ที่ใช้ระบบเซนเซอร์หลายรูปแบบ โดยเฉพาะกับการศึกษาที่ใช้ชุดข้อมูล Biovid และ X-ITE ตัวอย่างเช่น ในการศึกษาที่ใช้ EDA, คลื่นไฟฟ้าหัวใจ (ECG) และคลื่นไฟฟ้ากล้ามเนื้อ (EMG) พบว่าคุณลักษณะที่อิงจาก EDA แสดงผลการจำแนกที่ดีกว่าในการแยกแยะระหว่างภาวะปกติ (ไม่มีความเจ็บปวด) และความทนต่อความเจ็บปวด (ปวดมาก) ในการทดลองอื่นที่ใช้ EDA, ECG และ EMG พบว่า EDA เป็นเซนเซอร์ที่ให้ข้อมูลมากที่สุดสำหรับการทำนายความเข้มของความเจ็บปวดอย่างต่อเนื่อง ในทำนองเดียวกัน EDA ถูกพบว่าเป็นรูปแบบเดี่ยวที่ดีที่สุดทั้งในการจำแนกและการถดถอยโดยใช้เซนเซอร์ EDA, ECG และ EMG ในการศึกษานี้คุณลักษณะที่อิงจาก EDA แสดงถึงชุดคุณลักษณะที่กะทัดรัดกว่าซึ่งสามารถสร้างแบบจำลองการเรียนรู้ที่ซับซ้อนน้อยลง ข้อดีของการค้นพบรูปแบบเซนเซอร์ที่ดีที่สุดคือ EDA สามารถเก็บข้อมูลได้จากนาฬิกาอัจฉริยะหรือเซนเซอร์ชีวภาพที่ข้อมือ ซึ่งสามารถเก็บข้อมูลได้ง่ายเป็นระยะเวลานาน ในสภาวะต่างๆ (เช่น ระหว่างการเคลื่อนย้ายภายในโรงพยาบาล หรือตอนกลางคืนขณะที่ผู้ป่วยนอนหลับ) การติดตามจากระยะไกล (เช่น ที่บ้าน) และไม่รบกวนผู้ป่วย

สัญญาณทางสรีรวิทยาทั้งหมด (EDA, PPG, RESP) ที่ศึกษาในงานวิจัยนี้มีความเกี่ยวข้องอย่างใกล้ชิดกับระบบประสาทอัตโนมัติ (ANS) ระบบอัตโนมัตินี้เกี่ยวข้องกับการควบคุมกระบวนการทางสรีรวิทยาที่เกิดขึ้นโดยไม่ได้ตั้งใจ เช่น การควบคุมการเหงื่อออก ความดันโลหิต หรือการหายใจ ANS ยังเชื่อมโยงกับความ

เจ็บปวดเนื่องจากสิ่งเร้าที่ก่อให้เกิดความเจ็บปวดจะกระตุ้นการตอบสนองแบบป้องกันตัวโดยอัตโนมัติในร่างกาย การตอบสนองนี้ถูกออกแบบมาเพื่อป้องกันอันตรายเพิ่มเติมและช่วยให้หลีกหนีจากสิ่งเร้าที่ทำให้เจ็บปวด องค์ประกอบสำคัญในการตอบสนองต่อความเจ็บปวดทันทีใน ANS คือระบบประสาทซิมพาเทติก (SNS) ซึ่งรับผิดชอบการตอบสนองแบบสู้หรือหนีของร่างกาย เมื่อประสบกับความเจ็บปวด SNS จะเริ่มการตอบสนองทางสรีรวิทยาที่ส่งผลให้เกิดการเปลี่ยนแปลงต่างๆ เช่น การเปลี่ยนแปลงความดันโลหิต การบริโภคออกซิเจน และการเหงื่อออก เมื่อ SNS ถูกกระตุ้นเนื่องจากความเจ็บปวด สามารถใช้ EDA เป็นตัววัดกิจกรรมของ SNS ได้ เนื่องจากกิจกรรม SNS ที่เพิ่มขึ้นสามารถนำไปสู่การเพิ่มขึ้นของเหงื่อ (นั่นคือการเพิ่มขึ้นของการนำไฟฟ้าบนผิวหนัง) ในทำนองเดียวกัน PPG และ RESP สามารถประเมินกิจกรรมซิมพาเทติกโดยวัดการเปลี่ยนแปลงในการไหลเวียนของเลือดที่ผิวหนังและอัตราการหายใจตามลำดับ อย่างไรก็ตาม PPG และ RESP ยังได้รับอิทธิพลจากปัจจัยอื่นๆ เช่น อุณหภูมิและการเสียน้ำใน PPG และความวิตกกังวลหรือกิจกรรมทางกายในข้อมูล RESP ในทางกลับกัน EDA ถือเป็นการวัด SNS โดยตรง เนื่องจากการเปลี่ยนแปลงในการนำไฟฟ้าของผิวหนังถูกควบคุมหลักโดยการแทรกซึมของ SNS ของต่อมเหงื่อในผิวหนัง ดังนั้นเมื่อเทียบกับ PPG และ RESP แล้ว EDA อาจเหมาะสมกว่าสำหรับการตรวจจับความเจ็บปวดในแง่ของกิจกรรม SNS เนื่องจากให้การวัดการกระตุ้นซิมพาเทติกที่ค่อนข้างตรงกว่า

ผลการศึกษาเบื้องต้นที่นำเสนอในการศึกษานี้น่าสนใจ อย่างไรก็ตาม เราตระหนักว่าการศึกษานี้มีข้อจำกัดบางประการที่ควรได้รับการแก้ไขในการวิจัยในอนาคต ปัจจัยกวนเช่น ความเครียด ความวิตกกังวลหรืออารมณ์อื่นๆ สามารถส่งผลต่อการระบุความเจ็บปวด โดยเฉพาะอย่างยิ่งเนื่องจากการคาดการณ์การกระตุ้นความเจ็บปวดที่กำลังจะเกิดขึ้น ดังนั้นในการทดลองวิจัยในอนาคตของเรา เราจะพยายามลดความเครียดของผู้เข้าร่วมให้มากที่สุดเท่าที่จะเป็นไปได้โดยขอให้ผู้เข้าร่วมปิดตาเพื่อหลีกเลี่ยงการคาดการณ์ความเจ็บปวดหรือโดยการเปลี่ยนแปลงความยาวของช่วงพักระหว่างสิ่งเร้า นอกจากนี้ความเจ็บปวดเฉียบพลันในบริบททางคลินิกอาจมีพลวัตการเริ่มต้นที่แตกต่างกัน ทำให้การระบุความเจ็บปวดยากขึ้นหากไม่ทราบเวลาเริ่มต้น วิธีแก้ปัญหาที่เป็นไปได้คือการใช้ตัวจำแนกหน้าต่างเคลื่อนที่เพื่อสร้างแบบจำลองการเรียนรู้ที่ระบุจุดเริ่มต้นของความเจ็บปวดที่แตกต่างกัน นอกจากนี้ยังมีความสำคัญที่จะต้องกล่าวว่าจำเป็นต้องมีการวิจัยเพิ่มเติมสำหรับการตรวจจับความเจ็บปวดในผู้ป่วยที่มีอาการปวดเรื้อรัง ข้อจำกัดอีกประการหนึ่งของการศึกษาปัจจุบันคือการขาดเซ็นเซอร์ประสาทสรีรวิทยา (เช่น fNIRS, EEG) เนื่องจากเซ็นเซอร์ประเภทนี้สามารถปรับปรุงความแม่นยำโดยรวมและปรับปรุงผลลัพธ์ในตำแหน่งของความเจ็บปวด ในงานในอนาคตของเรา เราจะสำรวจเทคนิคการจำแนกที่ก้าวหน้ามากขึ้น (เช่น การเรียนรู้เชิงลึก) ที่สามารถช่วยปรับปรุงผลลัพธ์ปัจจุบัน ท้ายที่สุด ควรทราบว่าการประยุกต์ใช้ทางคลินิกของระบบปัจจุบันจะต้องมีการทดลองและวิจัยเพิ่มเติม รวมถึงความจำเป็นในการรวมผู้เข้าร่วมที่มีช่วงอายุที่กว้างขึ้นและมีสภาวะความเจ็บปวดที่แตกต่างกันเพื่อให้แบบจำลองการเรียนรู้สามารถนำไปใช้กับประชากรที่แตกต่างกันได้ดีขึ้น

5. Conclusions

การศึกษานี้ได้ศึกษาการใช้เทคโนโลยีการตรวจจับหลายประเภทเพื่อระบุสถานการณ์การประเมินความเจ็บปวดที่แตกต่างกัน โดยใช้เซ็นเซอร์สามประเภท ได้แก่ EDA, PPG, และ RESP เพื่อระบุชุดตัวบ่งชี้ที่สามารถใช้ประเมินความเจ็บปวดในเชิงวัตถุได้ สภาพการทดลองในงานศึกษานี้ได้รับการตรวจสอบและยืนยันโดยการวิเคราะห์คะแนนความเจ็บปวดที่รายงานโดยผู้เข้าร่วมการทดลองโดยใช้การวิเคราะห์ทางสถิติ เราได้ผลลัพธ์การจัดประเภทอ้างอิงจากเซ็นเซอร์แต่ละตัวและจากการรวมเซ็นเซอร์ทั้งหมด หลังจากกระบวนการเลือกคุณสมบัติ ผลลัพธ์แสดงว่า EDA เป็นเซ็นเซอร์ที่ให้ข้อมูลมากที่สุดในการทำนายในสามสภาพความเจ็บปวด (การระบุความเจ็บปวด, การจำแนกหลายระดับ และตำแหน่งของความเจ็บปวด) เท่าที่เราทราบ นี่เป็นการศึกษาครั้งแรกที่ศึกษาการใช้สัญญาณทางสรีรวิทยาเพื่อระบุตำแหน่งทางกายภาพที่เกิดความเจ็บปวด ซึ่งเป็นการตั้งค่าเบื้องต้นสำหรับการศึกษาครั้งต่อไปในสาขานี้ การใช้งานทางคลินิกในปัจจุบันของแนวทางที่เสนอแนะนี้เน้นถึงความจำเป็นในการทดลองเพิ่มเติมเพื่อยืนยันความเหมาะสมในการใช้งานในสภาพแวดล้อมทางคลินิกหรือสถานการณ์จริง สุดท้าย งานวิจัยในอนาคตจะใช้ตัวบ่งชี้ทางสรีรวิทยาที่เสนอแนะเพื่อการศึกษาเพิ่มเติมและพัฒนาเครื่องมือที่มุ่งช่วยเหลือคลินิกในการประเมินความเจ็บปวดเฉียบพลัน

อ้างอิง

Fernandez Rojas, R., Hirachan, N., Brown, N., Waddington, G., Murtagh, L., Seymour, B., & Goecke, R. (2023). Multimodal physiological sensing for the assessment of acute pain. Frontiers in Pain Research. https://doi.org/10.3389/fpain.2023.1150264

Zhang, Y., Li, M., & Wang, X. (2021). Automated nociceptive pain assessment using physiological signals and a hybrid deep learning network. *IEEE Transactions on Biomedical Engineering, 68*(5), 1302–1313.https://doi.org/10.1109/TBME.2020.3027345