การออกแบบและพัฒนาโมเดลการเรียนรู้ของเครื่องเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยกิจกรรมทางไฟฟ้าบนผิวหนังและความผันแปรของอัตราการเต้นของหัวใจ

The Design and Development of Machine Learning Models for Pain Assessment Recognition using Electrodermal Activity and Heart Rate Variability

ทิชานนท์ ทรงเลิศ

Thichanon Songlerd

อานิต้า อิสสภาพ

Anita Itsapap

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญา
วิทยาศาสตรบัณฑิต สาขาวิชานวัตกรรมสารสนเทศทางการแพทย์
มหาวิทยาลัยวลัยลักษณ์

A Project Submitted in Partial Fulfillment of the Requirements
for the Degree of Innovation of Medical Informatics
Walailak University

2568

การออกแบบและพัฒนาโมเดลการเรียนรู้ของเครื่องเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยกิจกรรมทางไฟฟ้าบนผิวหนังและความผันแปรของอัตราการเต้นของหัวใจ

The Design and Development of Machine Learning Models for Pain Assessment Recognition using Electrodermal Activity and Heart Rate Variability

ทิชานนท์ ทรงเลิศ

Thichanon Songlerd

อานิต้า อิสสภาพ

Anita Itsapap

โครงงานนี้เป็นส่วนหนึ่งของการศึกษาตามหลักสูตรปริญญา
วิทยาศาสตรบัณฑิต สาขาวิชานวัตกรรมสารสนเทศทางการแพทย์
มหาวิทยาลัยวลัยลักษณ์

A Project Submitted in Partial Fulfillment of the Requirements
for the Degree of Innovation of Medical Informatics
Walailak University

2568

สำนักวิชาสารสนเทศศาสตร์
มหาวิทยาลัยวลัยลักษณ์

หัวข้อโครงงาน การออกแบบและพัฒนาโมเดลการเรียนรู้ของเครื่องเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยกิจกรรมทางไฟฟ้าบนผิวหนังและความผันแปรของอัตราการเต้นของหัวใจ

ผู้เขียน ทิชานนท์ ทรงเลิศ
อานิต้า อิสสภาพ

สาขา นวัตกรรมสารสนเทศทางการแพทย์

ปีการศึกษา 2567

บทคัดย่อ

การประเมินระดับความเจ็บปวดของกลุ่มผู้ป่วยที่ไม่สามารถช่วยเหลือตนเองได้เป็นเรื่องที่ซับซ้อนและท้าทาย เนื่องจากต้องใช้บุคคลากรทางการแพทย์ในการสังเกตและติดตามอาการ โครงงานนี้จึงนำเสนอการประเมินระดับความเจ็บปวดแบบอัตโนมัติโดยอาศัยการเรียนรู้แบบของเครื่อง Boosting algorithms ร่วมกับสัญญาณทางสรีรวิทยา ได้แก่ ความผันแปรของอัตราการเต้นของหัวใจ (Heart Rate Variability : HRV) กิจกรรมทางไฟฟ้าบนผิวหนัง (Electrodermal activity: EDA) และ อุณหภูมิผิวหนัง (Skin Temperature : SKT) ซึ่งมีการรวบรวมสัญญาณทางสรีรวิทยาผ่านเครื่องขยายสัญญาณ BIOPAC MP36 ร่วมกับคุณลักษณะส่วนบุคคล ได้แก่ Body Mass Index (BMI) โดยผู้เข้าร่วมการทดลองจะถูกกระตุ้นความเจ็บปวดด้วยอุณหภูมิร้อนและเย็นจำนวน 30 คน จากการทดลองพบว่า Boosting algorithms สามารถจำแนกระดับความเจ็บปวดได้อย่างดีเยี่ยม โดยเฉพาะอย่างอัลกอริทึม LightGBM โดยมีค่า F1-score 99.92 % และมีการทดสอบความแข็งแกร่งของอัลกอริทึมดังกล่าว โดยใช้ชุดข้อมูลที่มีการขาดหายไป (Missing Velue) 10-50% ซึ่งพบว่าค่า F1-score ลดลงอย่างไม่มีนัยสำคัญ จึงสามารถสรุปได้ว่าการนำสัญญาณทางสรีวิทยา EDA และ HRV ร่วมกับการเรียนรู้ของเครื่องสามารถประยุกต์ใช้ในการประเมินความเจ็บปวดแบบอัตโนมัติได้

คำเฉพาะ : สัญญาณทางสรีรวิทยา ระดับความเจ็บปวด คุณลักษณะส่วนบุคคล ความแข็งแกร่งของอัลกอรึทึม ข้อมูลที่ขาดหายไป อัตโนมัติ

Project Title The Design and Development of Machine Learning Models for Pain Assessment Recognition using Electrodermal Activity and Heart Rate Variability

Author Thichanon Songlerd
Anita Itsapap

Major Program Innovation of Medical Informatics
Academic Year 2024

Abstract

The pain level assessment in patients who are unable to care for themselves is a challenging task, as it requires medical personnel to monitor symptoms. This research proposes an automatic pain level assessment using machine learning through boosting algorithms based on physiological signals, including Heart Rate Variability (HRV), Electrodermal Activity (EDA), and Skin Temperature (SKT). The physiological signals were collected using the BIOPAC MP36 amplifier, alongside personal characteristics such as Body Mass Index (BMI). Thirty participants were subjected to pain stimulation using hot and cold temperatures. The results demonstrated that boosting algorithms, particularly the LightGBM algorithm, achieved excellent pain level classification performance, with an F1-score of 99.92%. The algorithm's robustness was further evaluated with datasets containing missing values ranging from 10% to 50%. It was found that the F1-score decreased insignificantly. This suggests that integrating physiological signals, specifically EDA and HRV, with machine learning can potentially be applied for automatic pain assessment.

Keywords : Physiological Signal, Pain level, Personal characteristics, Algorithm's robustness, Missing values, Automatic

กิตติกรรมประกาศ

โครงงานเรื่องการออกแบบและพัฒนาโมเดลการเรียนรู้ของเครื่องเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยกิจกรรมทางไฟฟ้าบนผิวหนังและความผันแปรของอัตราการเต้นของหัวใจฉบับนี้สำเร็จลุล่วงได้ด้วยความกรุณาจากผู้มีพระคุณหลายท่านที่ให้ความช่วยเหลือแนะนำให้คำปรึกษาและให้ความเห็นทางวิชาการที่มีประโยชน์อย่างยิ่ง และความร่วมมือของบุคคลหลายฝ่ายที่ต้องขอกราบพระคุณ ณ ที่นี้

ผู้จัดทำขอขอบพระคุณ ผู้ช่วยศาสตราจารย์ ดร.บูคอรี ซาเหาะ ที่ปรึกษาโครงงานนี้ที่ได้สละเวลาอันมีค่าในการรับเป็นที่ปรึกษา ให้คำแนะนำ ปรับปรุง แก้ไขข้อบกพร่องต่าง ๆ รวมถึงให้ความรู้ทางวิชาการที่มีค่ายิ่ง และส่งเสริมสนับสนุนการทำวิจัยในครั้งนี้จนสำเร็จด้วยดีตามวัตถุประสงค์ครบถ้วนสมบูรณ์ ผู้จัดทำขอขอบพระคุณเป็นอย่างสูง

ผู้จัดทำขอขอบพระคุณ รองศาสตราจารย์ ดร.ยรรยงค์ พันธ์สวัสดิ์ ผู้เชี่ยวชาญด้านการวัดสัญญาณทางสรีรวิทยา ที่ให้คำปรึกษา แนะนำ และให้ความรู้เรื่องหลักการวัดสัญญาณทางสรีรวิทยาตลอดจนความรู้ด้านเซนเซอร์ต่าง ๆ อย่างลึกซึ้งจนโครงงานชิ้นนี้สำเร็จไปได้ด้วยดี

ผู้จัดทำขอขอบคุณผู้เข้าร่วมการทดลองทุกท่านที่ให้ความร่วมมือในการเป็นกลุ่มตัวอย่างสำหรับการทดลอง ซึ่งทำให้ได้ข้อมูลที่มีคุณภาพและสามารถนำไปใช้ประโยชน์ได้เป็นอย่างดี

ความสำเร็จจากการทำโครงงานฉบับนี้ผู้จัดทำขอน้อมระลึกถึงคุณพระบิดาและมารดา ผู้เป็นแรงบันดาลใจ และคอยให้การอบรมสั่งสอน ปลูกฝังความใฝ่รู้ในการศึกษา สนับสนุนและให้กำลังใจที่ดีเสมอมา ตลอดจนเพื่อนร่วมสาขานวัตกรรมสารสนเทศทางการแพทย์และรุ่นพี่นักศึกษาดุษฎีบัณฑิตที่คอยช่วยเหลือและสนับสนุนการทำวิจัยนี้เรื่อยมา

ท้ายที่สุดคุณประโยชน์ใดที่ได้จากโครงงานฉบับนี้ ผู้ศึกษาขอมอบแด่ผู้มีพระคุณทุกท่านและขอขอบพระคุณผู้ที่เป็นเจ้าของแนวคิดและทฤษฎีต่าง ๆ ในงานวิจัย วารสาร และบทความที่ผู้จัดทำได้ทำมาอ้างอิงในการทำโครงงานฉบับนี้ ผู้จัดทำขอกราบขอบพระคุณเป็นอย่างสูงมา ณ โอกาสนี้

ทิชานนท์ ทรงเลิศ

อานิต้า อิสสภาพ

สารบัญ

หน้า

บทคัดย่อ 1
ABSTRACT 2
กิตติกรรมประกาศ 3
สารบัญ 4
สารบัญตาราง 6
สารบัญภาพ 7
บทที่ 1 บทนำ 8
1.1 ความสำคัญและที่มาของปัญหา 8
1.2 วัตถุประสงค์ 9
1.3 ขอบเขตของงาน 9
1.4 ประโยชน์ที่คาดว่าจะได้รับ 10
1.5 ผลที่จะได้เมื่อเสร็จสิ้นโครงงาน 10
1.6 แผนการดำเนินงาน 10
1.7 เครื่องมือที่ใช้ในการพัฒนา 12
บทที่ 2 การทบทวนวรรณกรรม 13
2.1 ทฤษฎีที่เกี่ยวข้อง 13
2.2 เทคโนโลยีที่ใช้ 18
2.3 งานวิจัยหรือระบบที่ใกล้เคียง 24
บทที่ 3 การออกแบบระบบ 29
3.1 สถาปัตยกรรมของระบบ 29
3.2 การกำหนดกลุ่มผู้เข้าร่วมการทดลอง 31
3.3 การออกแบบกระบวนการทดลอง 31
3.4 กระบวนการเก็บข้อมูล 35
3.5 การวิเคราะห์และประมวลผลข้อมูล 36
บทที่ 4 การพัฒนาและการทดสอบ 41
4.1 สถาปัตยกรรมของโมเดล (MODEL ARCHITECTURE) 41
4.2 การอภิปรายผล (RESULT AND DISCUSSION) 46

สารบัญ (ต่อ)

หน้า

บทที่ 5 สรุปผลการดำเนินการ 49
5.1 สรุปผลการดำเนินงาน 49
5.2 ปัญหาในการดำเนินงาน 49
บรรณานุกรม 51
ภาคผนวก 53
ภาคผนวก ก 54
ภาคผนวก ข 56
ภาคผนวก ค 58
ประวัติผู้จัดทำ 59

สารบัญตาราง

หน้า

ตารางที่ 1.1 แผนการดำเนินการ 11
ตารางที่ 2.1 คุณสมบัติของเครื่องขยายสัญญาณ BIOPAC MP36 18
ตารางที่ 2.2 คุณสมบัติของ SS57LA 19
ตารางที่ 2.3 คุณสมบัติของ SS6L 21
ตารางที่ 2.4 คุณสมบัติของอุปกรณ์ที่ใช้ในการวัดอุณหภูมิ 22
ตารางที่ 2.5 สรุปการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง 25
ตารางที่ 3.1 รายละเอียดผู้เข้าร่วมการทดลอง 31
ตารางที่ 3.2 การควบคุมอุณหภูมิที่ใช้กระตุ้นความเจ็บปวดในแต่ละ Condition 33
ตารางที่ 3.3 รายละเอียดของความเจ็บปวด 4 ระดับ 36
ตารางที่ 3.4 ตัวอย่างรายการข้อมูลที่ครบถ้วนสมบูรณ์ 38
ตารางที่ 3.5 ตัวอย่างข้อมูล Missing Value ของกลุ่มสัญญาณ EDA 38
ตารางที่ 3.6 ตัวอย่างข้อมูล Missing Value ของกลุ่มค่า HRV 39
ตารางที่ 3.7 ค่า p-value ของแต่ละ Feature ในแต่ละ Class 39
ตารางที่ 4.1 การกำหนด Hyperparameter 43
ตารางที่ 4.2 Hyperparameter แบบอัตโนมัติ ประกอบด้วย Random search และ Bayesian optimization 44
ตารางที่ 4.3 กลุ่มของฟีเจอร์ที่ได้จากสัญญาณทางสรีรวิทยาร่วมกับคุณลักษณะส่วนบุคคล 46
ตารางที่ 4.4 ผลการทดสอบของประสิทธิภาพของโมเดล 46

สารบัญภาพ

หน้า

ภาพที่ 2.1 การแยกองค์ประกอบ Phasic และ Tonic ออกจาก Raw EDA 15
ภาพที่ 2.2 BIOPAC MP36 19
ภาพที่ 2.3 EDA Lead รหัสรุ่น SS57LA (Biopac, n.d.) 20
ภาพที่ 2.4 ECG BIOPAC รหัสรุ่น SS2LB (Biopac, n.d.) 20
ภาพที่ 2.5 เซนเซอร์ Temperature Transducers รหัสรุ่น SS6L (Biopac, n.d.) 21
ภาพที่ 2.6 รูปตัวอย่างอุปกรณ์ในการวัดอุณหภูมิ 22
ภาพที่ 3.1 สถาปัตยกรรมระบบของการออกแบบและพัฒนาโมเดลเพื่อทำนายระดับความเจ็บปวด ของผู้ป่วยที่ไม่สามารถสื่อได้โดยอาศัยสัญญาณทางสรีรวิทยา 29
ภาพที่ 3.2 การออกแบบกระบวนการและเงื่อนไขในการทดลอง 32
ภาพที่ 3.3 การติดตั้งเซนเซอร์บนสรีระของผู้เข้าร่วมการทดลอง 34
ภาพที่ 3.4 องค์ประกอบของสัญญาณ EDA ที่ผ่านการสกัดจาก NeuroKit2 (cvxEDA) 37
ภาพที่ 4.1 กระบวนการตรวจสอบและประเมินประสิทธิภาพของโมเดล 41
ภาพที่ 4.2 เทียบเปรียบจากค่า F1-score ของโมเดลในการทำนายระดับความเจ็บปวด 47

บทที่ 1
บทนำ

1.1 ความสำคัญและที่มาของปัญหา

การประเมินระดับความเจ็บปวดจากผู้ที่ไม่สามารถสื่อสารโดยเฉพาะกลุ่มผู้ป่วยที่ไม่สามารถช่วยเหลือตนเองได้ เช่น ผู้ป่วยติดเตียง ผู้ป่วยหลังผ่าตัดและผู้ป่วยวิกฤต เป็นเรื่องที่ซับซ้อนและท้าทายสำหรับเจ้าหน้าที่ที่ดูแลผู้ป่วย ด้วยเหตุนี้เจ้าหน้าที่จึงต้องทำประเมินความเจ็บปวดจากการสังเกตจากพฤติกรรมของผู้ป่วยที่แสดงออกทางสีหน้า เช่น การขมวดคิ้ว หรือลักษณะการแสดงออกด้านการเคลื่อนไหวของร่างกาย เช่น อาการทุรนทุรายจากการอดทนต่อความเจ็บปวด ด้วยเหตุนี้จึงทำให้เกิดข้อจำกัด คือ ต้องอาศัยเจ้าหน้าที่ที่เพียงพอต่อจำนวนผู้ป่วยในการติดตามและประเมินอาการของผู้ป่วยดังกล่าว ทำให้เกิดปัญหาภาระงานที่หนักเกินไปของเจ้าหน้าที่ (Labor Intensive) และติดตามอาการผู้ป่วยอย่างต่อเนื่อง (Time Consuming) ซึ่งหากให้การช่วยเหลือไม่ทั่วถึงและไม่ทันท่วงที อาจส่งผลให้ผู้ป่วยทนต่อความเจ็บปวดและยากลำบากในการดำรงชีวิต หรืออาจส่งผลถึงขั้นเสียชีวิตได้ ดังนั้นหากมีเทคโนโลยีการติดตามและการประเมินพฤติกรรมที่บ่งบอกถึงความเจ็บปวดแบบอัตโนมัติอาจจะนำไปสู่การแก้ปัญหาดังกล่าวได้

การเรียนรู้ของเครื่อง (Machine Learning : ML) และการประมวลผลสัญญาณทางสรีรวิทยา (Physiological Signal Processing: PSP) เป็นเทคโนโลยีสำคัญในการนำมาประยุกต์ใช้ในการติดตามและการประเมินระดับความเจ็บปวดแบบอัตโนมัติ โดย PSP ทำหน้าที่วิเคราะห์และจัดการกับสัญญาณที่ได้จากร่างกายมนุษย์ โดยมีจุดประสงค์เพื่อเข้าใจหรือติดตามสภาวะทางสรีรวิทยาของร่างกาย ซึ่งมีประโยชน์อย่างมากในทางการแพทย์และการวิจัยทางชีววิทยา และ ML จะทำหน้าที่สำหรับการทำนายความเจ็บปวด ซึ่งในช่วง 2 ปีที่ผ่านมามีหลายงานวิจัยในการประยุกต์ใช้ ML และ PSP เพื่อติดตามและประเมินระดับความเจ็บปวด

Aziz และคณะ(Aziz et al., 2023) ได้เสนอวิธีการตรวจจับความเจ็บปวดด้วย PSP เพื่อรวบรวมสัญญาณกิจกรรมทางไฟฟ้าบนผิวหนัง (Electrodermal Activity : EDA) โดย ML จะทำหน้าที่สำหรับการทำนายความเจ็บปวด ซึ่งผลการทดลองพบว่าตัวแบบดังกล่าวมีความแม่นยำสูงถึง 90% อย่างไรก็ตามจากงานวิจัยดังกล่าวเป็นการนำข้อมูลของสัญญาณ EDA (สัญญาณกิจกรรมทางไฟฟ้าบนผิวหนังที่ไม่ผ่านการวิเคราะห์) มาใช้ในการนำทายระดับความเจ็บปวด ซึ่งไม่มีความละเอียดของสัญญาณ ไม่มีการจำแนกสัญญาณ Phasic Tonic ซึ่งเป็นสัญญาณที่สามารถบ่งบอกถึงความเจ็บปวด และไม่มีการวัดระดับความเจ็บปวดที่ชัดเจน นอกจากนี้ยังมีงานวิจัยของ Winslow และคณะ (Winslow et al., 2022a) ได้พัฒนาอัลกอริทึมสำหรับตรวจจับความเจ็บปวดแบบอัตโนมัติโดยใช้เทคนิค ML แบบร่วมการถดถอยโลจิสติก โดยเฉพาะอย่างยิ่งจากข้อมูลความผันแปรของ

อัตราการเต้นของหัวใจ (Heart Rate Variability : HRV) จากการทดสอบระดับเจ็บปวดด้วยการจุ่มมือในน้ำเย็น (Cold Pressor Test : CPT) พบว่าตัวแบบสามารถจำแนกความเจ็บปวดโดยใช้ HRV มีประสิทธิภาพในการตรวจจับความเจ็บปวดด้วยคะแนน F1 Score 81.9% สำหรับใช้ในห้องปฏิบัติการ และ 79.4% สำหรับใช้ในสนามหรือสภาพแวดล้อมสำหรับสวมใส่ อย่างไรก็ตามจากงานวิจัยดังกล่าวมุ้งเน้นที่จะพยากรณ์สองความเป็นไปได้ คือ (1) ไม่มีความเจ็บปวด และ (2) มีความเจ็บปวด แต่ยังไม่ได้ให้ความสำคัญกับการเพิ่มขึ้นของระดับความเจ็บปวด เช่น รับรู้ถึงความเจ็บปวดเล็กน้อย รับรู้ถึงความเจ็บปวดปานกลาง และรับรู้ถึงความเจ็บปวดมาก ทำให้เจ้าหน้าที่ทางการแพทย์ไม่สามารถติดตามและประเมินการรับรู้ความเจ็บปวดได้อย่างแม่นยำและยากต่อการวางแผนเพื่อป้องกันความรุนแรงหากไม่สามารถจำแนกระดับความเจ็บปวดที่ละเอียดขึ้นได้

ดังนั้นโครงงานนี้จึงมีแนวคิดที่จะเสนอวิธีการติดตามและประเมินระดับความเจ็บปวดหลายระดับแบบอัตโนมัติสำหรับผู้ป่วยที่ไม่สามารถสื่อสารได้ วิธีการนี้มุ่งเน้นการประยุกต์ใช้เทคโนโลยี ML และ PSP โดยใช้สัญญาณทางสรีรวิทยา ได้แก่ EDA ประกอบด้วยสัญญาณย้อยแบบ Phasic และ Tonic นอกจากนี้จะอาศัยค่า HRV ประกอบด้วยสัญญาณย้อยแบบ High Frequency (HF) Low Frequency (LF) และ LF/HF (Ratio) เพื่อพัฒนาตัวต้นแบบที่สามารถทำนายระดับความเจ็บปวด โดยโครงงานนี้จะอาศัย ML การจำแนกประเภท (Classification) ความเจ็บปวดแบบหลายระดับ

1.2 วัตถุประสงค์

1.2.1 เพื่อศึกษากระบวนการในการวัดและประเมินระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสามารถสื่อสารได้ โดยการผ่านสัญญาณกิจกรรมทางไฟฟ้าบนผิวหนัง (Electrodermal Activity : EDA) สัญญาณคลื่นไฟฟ้าหัวใจ (Electrocardiogram : ECG) และ อุณหภูมิของผิวหนัง (Skin Temperature : SKT)

1.2.2 เพื่อออกแบบและพัฒนาตัวแบบ ML ในการจำแนกระดับความเจ็บปวดแบบหลายระดับ

1.2.3 เพื่อพิสูจน์และประเมินตัวโมเดลที่สามารถจำแนกระดับความเจ็บปวดหลายระดับ โดยใช้สัญญาณทางสรีรวิทยา

1.3 ขอบเขตของงาน

1.3.1 ศึกษาการทำงานของชุดอุปกรณ์เซนเซอร์วัดสัญญาณทางสรีรวิทยา BIOPAC โดยใช้สัญญาณทางสรีรวิทยา ได้แก่ EDA ECG และ SKT ตรวจสอบและวิเคราะห์การตอบสนองของร่างกายเมื่อได้รับความเจ็บปวดจากการสัมผัสแผ่นเจลที่มีอุณหภูมิต่ำและสูง

1.3.2 ออกแบบการทดลองเพื่อติดตามข้อมูลจากสัญญาณ EDA ECG และ SKT ที่ได้จากการตอบสนองของร่างกายเมื่อบริเวณฝ่ามือได้สัมผัสอุณหภูมิความร้อนในช่วง 60 ± 5 องศาเซลเซียส และอุณหภูมิความเย็นในช่วง −10 ± 5 องศาเซลเซียส

1.3.3 ทำการทดลองเพื่อบันทึกข้อมูลและสัญญาณทางสรีรวิทยา

ก. จำนวนผู้เข้าร่วมทดลองจำนวน 30 คน ที่มีสุขภาพดี

ข. กำหนดตัวแปรควบคุม ประกอบด้วย แบ่งเป็นเพศชายและเพศหญิงอย่างละ 15 คน โดยแบ่งกลุ่มตามเกณฑ์ดัชนีมวลกาย (BMI) ได้แก่ ผู้ที่เกินเกณฑ์ ผู้ที่พอดีเกณฑ์ และผู้ที่ต่ำกว่าเกณฑ์

1.3.4 ออกแบบและทดสอบตัวต้นแบบระดับห้องปฏิบัติการเพื่อใช้ในการจำแนกระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ประกอบด้วย 4 ระดับ แบ่งเป็น ระดับ 0 หมายถึง ไม่มีความเจ็บปวด ระดับ 1 หมายถึง มีความเจ็บปวดเล็กน้อย ระดับ 2 หมายถึง มีความเจ็บปวดปานกลาง และระดับ 3 หมายถึง มีความเจ็บปวดมาก

1.4 ประโยชน์ที่คาดว่าจะได้รับ

1.4.1 ได้กระบวนการในการวัดสัญญาณทางสรีรวิทยา การตรวจสอบ และการทำนายความระดับเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยใช้ชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC

1.4.2 ได้ ML ที่สามารถทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้

1.4.3 ได้ผลสรุปการพิสูจน์และผลการประเมินโมเดลที่สามารถทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยใช้ข้อมูลจากสัญญาณทางสรีรวิทยา ได้แก่ EDA ECG และ SKTที่ได้จากชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC

1.5 ผลที่จะได้เมื่อเสร็จสิ้นโครงงาน

เมื่อโครงงานเสร็จสิ้นจะได้กระบวนการวัดสัญญาณทางสรีรวิทยาและโมเดลที่สามารถทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารความเจ็บปวดได้ โดยใช้ชุดอุปกรณ์เซนเซอร์วัดจากเครื่องขยายสัญญาณ BIOPAC

1.6 แผนการดำเนินงาน

โครงงานนี้ใช้ระยะเวลาในการดำเนินการตั้งแต่เดือนมิถุนายน พ.ศ. 2567 ถึงเดือนมีนาคม พ.ศ.2568 รวมเป็นระยะเวลาทั้งสิ้น 9 เดือน โดยมีรายละเอียดดังตารางที่ 1.1

ตารางที่ 1.1 แผนการดำเนินการ

รายละเอียดการดำเนินงาน	ระยะเวลาการดำเนินงาน 2567 – 2568																																			
	มิถุนายน				กรกฎาคม				สิงหาคม				กันยายน				ตุลาคม				พฤศจิกายน				ธันวาคม				มกราคม				กุมภาพันธ์			
	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
1. ศึกษาและวิเคราะห์ปัญหา																																				
1.1 ศึกษาและวิเคราะห์ปัญหา																																				
1.2 ระบุวัตถุประสงค์และขอบเขต																																				
1.3 วางแผนและดำเนินการ																																				
2. ศึกษาเอกสารและงานวิจัยที่เกี่ยวข้อง																																				
2.1 ศึกษาทฤษฎีที่เกี่ยวข้อง																																				
2.2 ศึกษาเทคโนโลยีที่ใช้																																				
2.3 ศึกษางานวิจัยหรือระบบที่ใกล้เคียง																																				
3. ออกแบบและพัฒนาระบบ																																				
3.1 ออกแบบสถาปัตยกรรมภาพรวมของระบบ																																				
3.2 เลือกเครื่องมือและออกแบบการพัฒนาโมเดล																																				
3.3 ทดลองและบันทึกข้อมูล																																				
3.4 พัฒนาและทดสอบตัวโมเดล																																				
4. ประเมินและปรับปรุงประสิทธิภาพของโมเดล																																				
5. สรุปผลการดำเนินงาน																																				

.

1.7 เครื่องมือที่ใช้ในการพัฒนา

1.7.1 ด้านฮาร์ดแวร์

1) เครื่องคอมพิวเตอร์พกพาส่วนบุคคล จำนวน 1 เครื่อง ใช้สำหรับการพัฒนาระบบ มีรายละเอียดดังนี้
   ก. System Manufacturer: LENOVO
   ข. System Model: 82EV
   ค. Central Processing Unit: 11th Gen Intel® Core™ i7-1165G7(4 Cores, 8 Logical Processors)
   ง. Graphic Processing Unit: Intel® Iris® Xe Graphics
   จ. Memory: 16 GB (8 GB x2) DDR4
   ฉ. Storage: SSD 1 TB
2) เซนเซอร์วัดกิจกรรมทางไฟฟ้าบนผิวหนัง (Electrodermal Activity : EDA) รุ่น SS57L จากอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC
3) เซนเซอร์วัดคลื่นไฟฟ้าหัวใจ (Electrocardiogram : ECG) รุ่น SS2LB จากอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC
4) เซนเซอร์วัดอุณหภูมิผิวหนัง (Skin Temperature Sensor : SKT) รุ่น SS6L จากอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC
5) เครื่องวัดอุณหภูมิอินฟราเรดแบบไม่สัมผัส รุ่น Deli DL333380
6) เจลประคบเย็นและร้อน (3 M Nexcare Clod Hot Pack)
7) แผ่นทำความร้อน (Exeter thermo pad)

1.7.2 ด้านซอฟต์แวร์

1) Biopac student Lab 4.1 เป็นโปรแกรมสำหรับการติดตามข้อมูลของสัญญาณทางสรีรวิทยาและใช้ในการบันทึกข้อมูลจากอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC
2) Python เป็นภาษาคอมพิวเตอร์ที่ใช้ในกระบวนการเตรียมข้อมูลและพัฒนาโมเดล
3) PyTorch เป็นไลบรารี่ที่ใช้ในการสร้างโมเดลที่สามารถเร่งความเร็วในการพัฒนาได้ด้วยหน่วยประมวลผลภาพ (GPU)

บทที่ 2
การทบทวนวรรณกรรม

โครงงานนี้มีจุดมุ่งหมายเพื่อออกแบบและพัฒนาโมเดลเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยสัญญาณกิจกรรมทางไฟฟ้าบนผิวหนังและค่าความผันแปรของอัตราการเต้นของหัวใจโดยใช้หลักทฤษฎีและเทคโนโลยีต่าง ๆ ประกอบเข้าด้วยกัน เพื่อให้โมเดลมีความแม่นยำและสามารถนำไปช่วยเหลือหรือแก้ไขปัญหาในผู้ป่วยที่ไม่สามารถสื่อสารความเจ็บปวดได้ โดยในบทนี้จะนำเสนอเอกสารที่เกี่ยวข้องโดยแบ่งออกเป็น 3 ส่วน ได้แก่ 1) ทฤษฎีที่เกี่ยวข้องกับระบบทำนายและวิเคราะห์ความเกี่ยวข้องกับความเจ็บปวด 2) เทคโนโลยีที่ใช้ในการพัฒนา และ 3) งานวิจัยหรือระบบที่ใกล้เคียง ซึ่งข้อมูลเหล่านี้จะเป็นแนวทางที่ใช้ในการออกแบบและพัฒนาโครงงานนี้ต่อไป

2.1 ทฤษฎีที่เกี่ยวข้อง

ทฤษฎีและหลักการที่สำคัญจะนำไปสู่การออกแบบและพัฒนาโมเดลเพื่อประเมินการรับรู้ความเจ็บปวดโดยอาศัยสัญญาณ EDA และค่า HRV รวมไปจนถึงประวัติการรักษาและข้อมูลส่วนบุคคล การวัดสัญญาณไฟฟ้าเชิงสรีรวิทยาของผู้ป่วยแต่ละรายโดยใช้อุปกรณ์วัดสัญญาณทางสรีรวิทยาได้แก่ สัญญาณ EDA สะท้อนให้เห็นถึงการตอบสนองของระบบประสาทอัตโนมัติ (Autonomic Nervous System : ANS) ที่ส่งผลให้เกิดการเปลี่ยนแปลงของต่อมเหงื่อใต้ผิวหนังและส่งผลให้เกิดการเปลี่ยนแปลงค่าความต้านทานไฟฟ้าที่ผิวหนัง ค่า HRV เป็นการเปลี่ยนแปลงในระยะห่างระหว่างการเต้นของหัวใจแต่ละครั้ง ซึ่งสะท้อนถึงความสามารถของระบบ ANS ในการปรับตัว และอุณหภูมิผิวหนังที่จะสะท้อนไปยังความสามารถของระบบร่างกายในการรักษาอุณหภูมิของร่างกายให้ปกติ (Thermoregulator) เพื่อรักษาความสมดุลของร่างกาย ซึ่งข้อมูลเหล่านี้จะสะท้อนให้เห็นถึงพฤติกรรมการตอบสนองของร่างกายผ่านสัญญาณทางสรีรวิทยาที่มีความเกี่ยวข้องกับปัจจัยอื่น ๆ และจะเป็นปัจจัยสำคัญสำหรับนำไปพัฒนาโมเดลเพื่อจะจำแนกความเจ็บปวดได้อย่างแม่นยำในผู้ป่วยที่ไม่สามารถสื่อสารความเจ็บปวด

2.1.1 ผู้ป่วยที่ไม่สามารถสื่อสารได้ (Non-communicative patients)

ผู้ป่วยที่ไม่สามารถสื่อสารได้เป็นกลุ่มผู้ป่วยที่มีข้อจำกัดในการแสดงออกหรือการสื่อสารความต้องการและความรู้สึกของตนเองอย่างชัดเจน ข้อจำกัดเหล่านี้อาจเกิดจากหลายสาเหตุ เช่น ภาวะหมดสติ หรือข้อจำกัดทางกายภาพที่มีผลต่อความสามารถในการสื่อสาร เช่น การใช้ท่อช่วยหายใจ ผู้ป่วยหลังการผ่าตัด หรือผู้ป่วยในสภาวะวิกฤต ซึ่งทำให้การสื่อสารและการแสดงออกถึงความเจ็บปวดเป็นไปได้ยาก การประเมินสภาวะของผู้ป่วยดังกล่าวต้องประเมินอย่างละเอียดโดยครอบคลุมถึงระดับความรู้สึกตัว สัญญาณชีพ และอาการที่ผู้ป่วยแสดงออก เพื่อให้ผู้ป่วยได้รับการดูแลและรักษาอย่างเหมาะสม

2.1.2 ความเจ็บปวด (Pain)

ความเจ็บปวดเป็นประสบการณ์ที่เกิดขึ้นการตอบสนองต่อระบบ ANS และมีความซับซ้อนทั้งในด้านร่างกายและจิตใจ มักเกิดจากการกระตุ้นของปลายประสาทรับความรู้สึกซึ่งตอบสนองต่อการบาดเจ็บทางกายภาพ เช่น การกด การบาด หรือความร้อน นอกจากนั้นความเจ็บปวดยังมีส่วนเชื่อมโยงกับการรับรู้ทางจิตใจและอารมณ์อีกด้วย ส่งผลให้แต่ละคนอาจรับรู้ความเจ็บปวดในระดับที่ต่างกันไปแม้ว่าจะเผชิญกับสิ่งกระตุ้นทางกายภาพที่คล้ายคลึงกัน ด้วยเหตุนี้การประเมินความเจ็บปวดโดยการรายงานจากตัวผู้ป่วยเองจึงมักเป็นวิธีแรกที่ใช้ (Jiang et al., 2024)

จากการทบทวนวรรณกรรมที่ผ่านมาผู้ป่วยที่ไม่สามารถสื่อสารได้ เช่น ผู้ป่วยที่อยู่ระหว่างการดมยาสลบหรือผู้ป่วยวิกฤต ต้องอาศัยการสังเกตพฤติกรรมของผู้ป่วยเพื่อประเมินความเจ็บปวดแทน ซึ่งการศึกษาส่วนใหญ่จะวิเคราะห์พฤติกรรมจากการแสดงออกทางใบหน้า การเคลื่อนไหวร่างกาย และสัญญาณทางสรีรวิทยา เช่น สัญญาณ ECG และการตรวจคลื่นชีพจร โดยใช้ข้อมูลเหล่านี้มาช่วยประเมินระดับความเจ็บปวดได้ (Jiang et al., 2024)

การดูแลและรักษาผู้ป่วยอย่างมีประสิทธิภาพต้องพึ่งพาความสามารถในการสื่อสารและประเมินความเจ็บปวดอย่างถูกต้อง ผู้ป่วยที่ไม่สามารถสื่อสารได้มักประสบปัญหาในการอธิบายอาการ ส่งผลให้การวินิจฉัยและการรักษาอาจไม่ตรงตามอาการจริง ซึ่งอาจทำให้การบรรเทาความเจ็บปวดไม่เพียงพอและเพิ่มความเสี่ยงต่อภาวะแทรกซ้อน รวมถึงความเสี่ยงในการเสียชีวิต

2.1.3 คุณลักษณะเฉพาะบุคคล (Individual Characteristics)

คุณลักษณะเฉพาะบุคคลเป็นปัจจัยที่ทำให้แต่ละบุคคลมีความแตกต่างกันอย่างชัดเจน โดยมีทั้งลักษณะทางกายภาพและประสบการณ์ชีวิต ซึ่งส่งผลกระทบต่อการตอบสนองต่อความเจ็บปวดในรูปแบบที่แตกต่างกัน เช่น ค่า BMI และปริมาณไขมันในร่างกาย ซึ่งมีความสัมพันธ์กับความไวต่อความเจ็บปวด โดยเฉพาะผู้ที่มีภาวะอ้วนมักมีความไวต่อความเจ็บปวดจากแรงกดในบริเวณที่มีไขมันน้อยมากกว่าบริเวณที่มีไขมันมาก ในขณะที่การตอบสนองต่อความร้อนและความเย็นในบริเวณที่มีไขมันมากมักจะต่ำกว่า เนื่องจากการสะสมของไขมันทำให้ความสามารถในการนำความร้อนและความเย็นลดลง ซึ่งส่งผลต่อการรับรู้และประสบการณ์เกี่ยวกับความเจ็บปวดของบุคคลนั้น ๆ อย่างชัดเจน (Tashani et al., 2017)

2.1.4 การวัดสัญญาณไฟฟ้าเชิงสรีรวิทยา (Measurement of Physiological Electrical Signals)

2.1.4.1 สัญญาณกิจกรรมทางไฟฟ้าบนผิวหนัง

สัญญาณ EDA เป็นสัญญาณที่แสดงถึงการเปลี่ยนแปลงทางไฟฟ้าที่เกิดขึ้นที่ผิวหนัง ซึ่งสัมพันธ์กับการทำงานของระบบ ANS โดยเฉพาะในส่วนของระบบประสาทซิมพาเทติก (Sympathetic Nervous System : SNS) เมื่อมีการตอบสนองทางอารมณ์หรือความเครียด สัญญาณ EDA จะเปลี่ยนแปลงตามการทำงานของต่อมเหงื่อ เนื่องจากการกระตุ้นที่เกิดจากภาวะอารมณ์ เช่น

ความตื่นเต้น ความวิตกกังวล หรือความเจ็บปวด โดยทั่วไปแล้ว สัญญาณ EDA สามารถสกัดคุณลักษณะออกเป็น 2 คุณลักษณะ ได้แก่ Phasic และ Tonic ซึ่งมีรายละเอียดดังนี้

1) Phasic หรือที่เรียกอีกชื่อว่า Skin Conductance Response (SCR) คือการเปลี่ยนแปลงของการนำไฟฟ้าบนผิวหนังที่เกิดขึ้นในระยะสั้นเพื่อตอบสนองต่อสิ่งเร้าเฉพาะเจาะจง เช่น ความเจ็บปวด สัญญาณนี้จะเพิ่มขึ้นอย่างรวดเร็วเมื่อเกิดการกระตุ้น และค่อย ๆ ลดลงหลังจากที่ไม่มีอาการเจ็บปวด

2) Tonic หรือ Skin Conductance Level (SCL) หมายถึง ระดับพื้นฐานของการนำไฟฟ้าของผิวหนังที่มีการเปลี่ยนแปลงอย่างช้า ๆ และคงที่ ซึ่งไม่ได้สัมพันธ์กับสิ่งเร้าที่เฉพาะเจาะจง แต่สะท้อนถึงระดับความเจ็บปวดหรือการกระตุ้นโดยรวมในระยะยาว

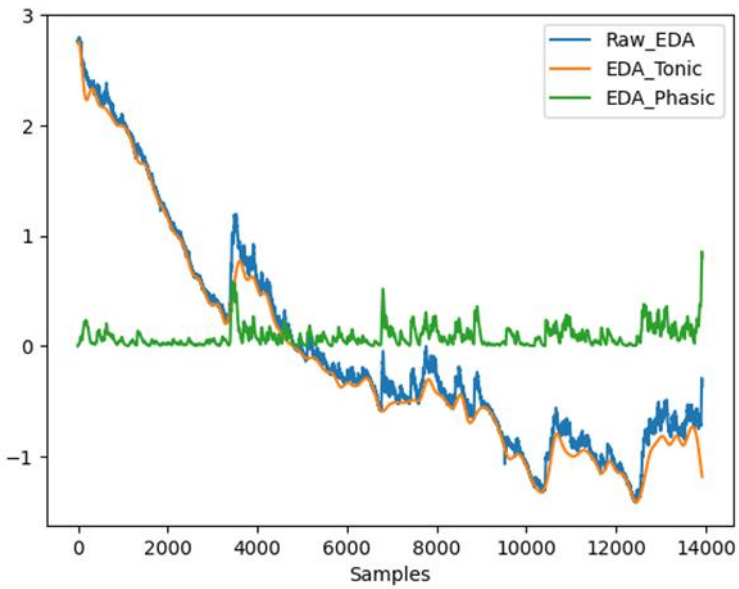

ภาพที่ 2.1 การแยกองค์ประกอบ Phasic และ Tonic ออกจาก Raw EDA

2.1.4.2 สัญญาณคลื่นไฟฟ้าหัวใจ

เป็นเทคนิคทางการแพทย์ที่ใช้ในการบันทึกสัญญาณไฟฟ้าของหัวใจซึ่งเกิดขึ้นจากการทำงานของกล้ามเนื้อหัวใจในระหว่างการเต้นของหัวใจ สัญญาณไฟฟ้าถูกตรวจจับผ่านอิเล็กโทรดที่วางอยู่บนผิวหนังและแสดงผลเป็นกราฟ ซึ่งแสดงถึงการกระตุ้นและการคลายตัวของหัวใจในแต่ละรอบการเต้น นอกจากนี้ สัญญาณ ECG ยังใช้ในการวิเคราะห์การทำงานของระบบ ANS ผ่านการคำนวณความผันแปรของอัตราการเต้นของหัวใจ

2.1.4.3 ความความผันแปรของอัตราการเต้นของหัวใจ

ความผันแปรของระยะเวลาระหว่างการเต้นของหัวใจซึ่งมักจะวัดจากการบันทึกคลื่นไฟฟ้าหัวใจ หรือการวัดอัตราการเต้นของหัวใจ (Heart Rate) โดยค่า HRV แสดงถึงความสามารถของระบบ ANS ในการปรับตัวและรักษาสมดุลระหว่างระบบประสาทซิมพาเทติก

(Sympathetic Nervous System : SNS) และพาราซิมพาเทติก (Parasympathetic Nervous System : PNS) การวิเคราะห์ค่า HRV สามารถทำได้ทั้งในรูปแบบเชิงเวลา (Time-Domain) และเชิงความถี่ (Frequency-Domain) ซึ่งในงานวิจัยนี้จะกล่าวถึง Low frequency (LF), High frequency (HF) และ Ratio of LF-HF (LF/HF)

ก) Low Frequency (LF) เป็นส่วนประกอบของ HRV ในช่วงความถี่ 0.04 ถึง 0.15 Hz สะท้อนถึงการทำงานของทั้งระบบ SNS ที่มีการควบคุมความดันโลหิตและการควบคุมอุณหภูมิร่างกาย การเพิ่มขึ้นของ LF เกิดจากการกระตุ้นระบบประสาทซิมพาเทติก เช่น ในภาวะความเจ็บปวดเฉียบพลัน

ข) High Frequency (HF) เป็นส่วนประกอบของ HRV ในย่านความถี่ 0.15 ถึง 0.4 Hz HF สะท้อนถึงการทำงานของระบบ PNS เป็นหลัก การเพิ่มขึ้นของ HF จะเกี่ยวข้องกับสภาวะการผ่อนคลาย

ค) LF/HF (Ratio) เป็นค่าที่คำนวณจากอัตราส่วนระหว่างกำลังของ LF ต่อ HF ใช้เป็นตัวบ่งชี้สมดุลระหว่างการทำงานของระบบ SNS และ PNS ดังนั้นเมื่อมีความเจ็บปวดระบบ ANS จะตอบสนองด้วยการเพิ่ม LF และลด HF ซึ่งจะส่งผลให้ค่า LF/HF สูงขึ้น

2.1.4.4 อุณหภูมิบริเวณผิวหนัง

อุณหภูมิผิวหนังหมายถึงการวัดอุณหภูมิที่ผิวของร่างกาย ซึ่งมีหน้าที่สำคัญในการรักษาสมดุลความร้อนของร่างกายและป้องกันอวัยวะภายในจากสิ่งแวดล้อมภายนอก การเปลี่ยนแปลงของอุณหภูมิผิวหนังอาจสะท้อนถึงความเครียดทางอารมณ์ ภูมิคุ้มกัน การรับรู้ความเจ็บปวด หรือการอักเสบ โดยเฉพาะเมื่อเกิดอาการเจ็บหรืออักเสบ การไหลเวียนของเลือดและการทำงานของระบบประสาทจะส่งผลต่ออุณหภูมิของผิวหนัง

2.1.5 ระบบประเมินระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสาร

การประเมินและจัดการความเจ็บปวดในผู้ป่วยแบบประคับประคองที่ไม่สามารถสื่อสารได้เป็นเรื่องสำคัญ เพราะความเจ็บปวดส่งผลต่อคุณภาพชีวิตและอาจทำให้การฟื้นตัวช้าลง ผู้ป่วยกลุ่มนี้ ซึ่งมีอัตราสูงถึง 46% ถึง 80% เช่น ผู้ที่มีโรคทางระบบประสาทหรืออยู่ในระยะสุดท้าย มักไม่สามารถบอกความเจ็บปวดได้เอง ทำให้เสี่ยงต่อการประเมินระดับความเจ็บปวดไม่ถูกต้อง จึงต้องใช้วิธีสังเกตพฤติกรรม เช่น การแสดงออกทางสีหน้า หรืออาการทางกายอื่น ๆ เพื่อประเมินความเจ็บปวดแทน (McGuire et al., 2016) ดังนั้นเพื่อเป็นการแก้ปัญหาดังกล่าวการออกแบบและพัฒนาตัวโมเดลเพื่อประเมินและจัดการระดับความเจ็บปวดอย่างเหมาะสม จึงมีความสำคัญอย่างยิ่งในการพัฒนาคุณภาพชีวิตของผู้ป่วยที่ไม่สามารถสื่อสาร จะมีองค์ประกอบพื้นฐานที่สำคัญ ได้แก่

2.1.5.1 การออกแบบและกำหนดค่าเซนเซอร์ (Sensor Design and Configuration)

เซนเซอร์จะทำหน้าที่เสมือนเป็นประสาทรับรู้ของผู้เชี่ยวชาญในการประเมินระดับความเจ็บปวด โดยประกอบด้วยเซนเซอร์ที่ตรวจจับข้อมูลเกี่ยวกับสภาวะทางร่างกายของผู้ป่วย เช่น สัญญาณ EDA ECG และ SKT เป็นต้น ข้อมูลที่ได้จากเซนเซอร์เหล่านี้จะถูกนำมาวิเคราะห์อย่างเป็นระบบเพื่อประเมินระดับความเจ็บปวดของผู้ป่วยอย่างแม่นยำ

2.1.5.2 การแปลงโครงสร้างข้อมูลที่ได้จากเซนเซอร์ (Structural Transformation)

ข้อมูลที่ได้จากเซนเซอร์มักมาในรูปแบบที่คอมพิวเตอร์ไม่สามารถประมวลผลได้โดยตรง เพราะเป็นเพียงชุดตัวเลขต่อเนื่องที่ยังไม่สื่อความหมายชัดเจน ดังนั้นต้องมีการแปลงข้อมูลเป็นสัญญาณดิจิทัลและปรับโครงสร้างข้อมูลให้มีความหมายที่ชัดเจนเพื่อให้ระบบสามารถประมวลผลได้

2.1.5.3 การเตรียมข้อมูล (Data Preparation)

การเตรียมข้อมูลเป็นขั้นตอนที่สำคัญในการทำให้ข้อมูลมีความถูกต้องและมีประสิทธิภาพสูงสุดสำหรับการประมวลผลและวิเคราะห์ข้อมูลต่อไป

2.1.5.4 การเก็บรวบรวมข้อมูล (Data Collection)

เนื่องจากข้อมูลมักกระจัดกระจายจึงจำเป็นต้องรวบรวมข้อมูลจากแหล่งต่าง ๆ ให้มาอยู่ในรูปแบบไฟล์เดียวกัน เพื่อให้ง่ายต่อการนำไปใช้ในกระบวนการสอนและวิเคราะห์ของระบบการเรียนรู้ของเครื่อง

2.1.5.5 การสกัดคุณลักษณะสำคัญ (Feature Extraction)

เป็นกระบวนการสกัดคุณลักษณะเด่นและมีความหมายออกจากชุดข้อมูลทั้งหมดเพื่อใช้ในการวิเคราะห์และทำนายผล

2.1.5.6 การทำนายผลเหตุการณ์ต่าง ๆ (Event Prediction)

การทำนายจะใช้ฟีเจอร์ที่สกัดมาเพื่อฝึกฝนระบบการเรียนรู้ของเครื่องในการจดจำระดับความเจ็บปวด เช่น ในกรณีที่ผู้ป่วยสัมผัสกับอุณหภูมิสูงหรือต่ำเกินไป ซึ่งอาจทำให้เกิดความเจ็บปวดหรือไม่สบาย อย่างไรก็ตามผลลัพธ์การทำนายที่ได้จากการเรียนรู้ของเครื่องยังคงเป็นข้อมูลเชิงตัวเลขที่ต้องแปลงให้เข้าใจง่ายสำหรับผู้ใช้

2.1.5.7 การแสดงผลลัพธ์ (Result Visualization)

เนื่องจากผลลัพธ์จากการทำนายระดับความเจ็บปวดมักจะอยู่ในรูปแบบตัวเลขที่คอมพิวเตอร์เข้าใจได้แต่ผู้ป่วยหรือคนทั่วไปจำเป็นต้องได้รับข้อมูลในรูปแบบที่เข้าใจง่าย เช่น การแสดงข้อความว่า "เจ็บปวดมาก" "เจ็บปวดปานกลาง" "เจ็บปวดเล็กน้อย" หรือ "ไม่มีความเจ็บปวด" เพื่อให้ผลลัพธ์มีความชัดเจนและเข้าถึงได้ง่ายขึ้นสำหรับทุกคน

2.2 เทคโนโลยีที่ใช้

เทคโนโลยีที่สำคัญที่จะนำไปสู่การออกแบบและพัฒนาโมเดลในการทำนายระดับความเจ็บปวดสำหรับผู้ป่วยที่ไม่สามารถสื่อสาร สามารถพิจารณาได้เป็น 2 ด้านหลัก ๆ ได้แก่ 1) ด้านฮาร์ดแวร์ ซึ่งจะประกอบด้วยเซนเซอร์ต่าง ๆ ที่ใช้ในการเก็บข้อมูลทั้งด้านกายภาพและด้านสรีรวิทยา 2) ด้านซอฟต์แวร์เพื่อใช้ในการประมวลผลข้อมูลที่ได้จากเซนเซอร์ดังกล่าวและนำไปพัฒนาโมเดลการเรียนรู้เพื่อทำนายระดับความเจ็บปวด

2.2.1 เทคโนโลยีด้านฮาร์ดแวร์ (Hardware)

เทคโนโลยีทางด้านฮาร์ดแวร์ที่ใช้ในการพัฒนาตัวโมเดลและโครงงานนี้จะปัจจัยทางสรีรวิทยา โดยจะเก็บข้อมูลที่ตอบสนองจากตัวผู้ป่วยโดยตรง ได้แก่ สัญญาณ ECG EDA และ SKT เป็นต้น ซึ่งจะใช้เทคโนโลยีด้านฮาร์ดแวร์ในการประเมินความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารดังนี้

1) ชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC MP36

เป็นอุปกรณ์สำหรับการเก็บข้อมูลที่ใช้ในโครงงานด้านสรีรวิทยาและชีวการแพทย์ ซึ่งช่วยในการบันทึกและวิเคราะห์สัญญาณทางสรีรวิทยา เช่น สัญญาณ ECG EDA และ SKT เป็นต้น โดยทั่วไปจะทำงานร่วมกับซอฟต์แวร์ BIOPAC Student Lab 4.1 ซึ่งมีเครื่องมือสำหรับการเก็บข้อมูล วิเคราะห์ และสามารถบันทึกข้อมูลพร้อมกันได้หลายสัญญาณ และมีคุณสมบัติในการประมวลผลสัญญาณคุณภาพสูงเหมาะสำหรับการใช้งานในห้องทดลองสรีรวิทยาของมนุษย์หรือการวิจัยทางการแพทย์ ตัวเครื่อง MP36 มีความละเอียดในการเก็บข้อมูลสูงทำให้สามารถบันทึกสัญญาณที่ละเอียดอ่อนและมีความแม่นยำสูง ซึ่งคุณสมบัติของ BIOPAC จะแสดงดังตารางที่ 2.1และตัวอย่าง BIOPAC จะแสดงดังภาพที่ 2.2

ตารางที่ 2.1 คุณสมบัติของเครื่องขยายสัญญาณ BIOPAC MP36

คุณสมบัติ	รายละเอียด
Analog Inputs	Front panel DSUB 9f labeled "CH #"
Number of Channels	Isolated human-safe universal input amplifiers
A/D Sampling Resolution	24-bit
Gain Ranges	5x to 50,000x (13 steps)
Input Voltage Range	Adjustable from ±200 μV to ±2 V
Signal to Noise Ratio	≥ 89 dB min

คุณสมบัติ	รายละเอียด
Input Noise Voltage	9 μV rms /sqrt(Hz) and 0.1 μV rms noise (0.1 Hz to 35 Hz) - nominal
Sample Rate	100,000 samples/second for each channel
Serial Interface Type	USB 2.0 full speed

ภาพที่ 2.2 BIOPAC MP36

โครงงานนี้ได้นำชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC MP36 มาใช้สำหรับการวัดสัญญาณทางสรีรวิทยา ได้แก่ สัญญาณ EDA ECG และ SKT เพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสาร

ก) เซนเซอร์วัดกิจกรรมทางไฟฟ้าบนผิวหนัง

เป็นอุปกรณ์ซนเซอร์ในการวัดสัญญาณ EDA ซึ่งวัดความเปลี่ยนแปลงของการนำไฟฟ้าที่ผิวหนังที่เกิดจากการเปลี่ยนแปลงของต่อมเหงื่อ ในโครงงานนี้จะติดตั้งอิเล็กโทรดที่นิ้วชี้และนิ้วกลาง วัดจากเซนเซอร์รุ่น SS57L ดังภาพที่ 2.3 เพื่อวัดกิจกรรมทางไฟฟ้าบนผิวหนัง เซนเซอร์จะจ่ายศักย์ไฟฟ้าระหว่างจุดสองจุดและวัดกระแสไฟฟ้าที่เกิดขึ้นระหว่างจุดทั้งสองผ่านผิวหนัง ซึ่งคุณสมบัติพื้นฐานจะแสดงดังตารางที่ 2.2

ตารางที่ 2.2 คุณสมบัติของ SS57LA

คุณสมบัติ	รายละเอียด
Electrode Type	Requires two Ag/AgCl disposable electrodes (EL507)
Excitation	0.5 V DC
Range	0.1-100 μsiemens (normal human range: 1-20 μsiemens)
Connector Type	9 Pin DIN
Pinch Leads	Red (+), Black (GND)
Weight	4.5 grams

คุณสมบัติ	รายละเอียด
Cable Length	2 meters
Accuracy	Within 5% without calibration (SS57LA only)

ภาพที่ 2.3 EDA Lead รหัสรุ่น SS57LA (Biopac, n.d.)

ข) เซนเซอร์วัดสัญญานคลื่นไฟฟ้าหัวใจ

เซนเซอร์ ECG ใช้ในการตรวจจับสัญญาณไฟฟ้าที่เกิดจากการทำงานของหัวใจ เซนเซอร์นี้ประกอบด้วยอิเล็กโทรดหลายจุดที่ติดตามตำแหน่งต่าง ๆ ของร่างกายเพื่อวัดกิจกรรมทางไฟฟ้าของหัวใจขณะเต้น ซึ่งสามารถแสดงการทำงานของกล้ามเนื้อหัวใจและรูปแบบของคลื่นไฟฟ้าที่สัมพันธ์กับการบีบตัวและการคลายตัวของหัวใจ ซึ่งวัดจากเซนเซอร์รุ่น SS2LB

ภาพที่ 2.4 ECG BIOPAC รหัสรุ่น SS2LB (Biopac, n.d.)

ค) เซนเซอร์อุณหภูมิวัดที่ผิวหนัง

SS6L เป็นเซนเซอร์ขนาดเล็กที่ใช้วัดอุณหภูมิ ดังภาพที่ 2.4 โดยสามารถตรวจจับการเปลี่ยนแปลงเล็กน้อยของอุณหภูมิบนผิวหนัง การเปลี่ยนแปลงของอุณหภูมิที่บันทึกได้สามารถใช้วิเคราะห์สภาวะทางสรีรวิทยาได้เซนเซอร์จะตรวจจับความเปลี่ยนแปลงของอุณหภูมิที่เกิดขึ้นจากการสัมผัสกับผิวหนัง ซึ่งคุณสมบัติพื้นฐานของเซนเซอร์แสดงดังตารางที่ 2.3

ตารางที่ 2.3 คุณสมบัติของ SS6L

คุณสมบัติ	รายละเอียด
Response time (in stirred oil bath)	0.6 sec
Nominal resistance	2252 Ω @ 25° C
Maximum operating temperature	100° C
Accuracy and Interchangeability	±0.1° C
Connector Type	9 Pin DIN
Compatibility	YSI® series 400 temperature probes
Cable Length	2 meters (flexible, lightweight)
Sterilizable	No
Dimensions	5 m x 1.7 m

ภาพที่ 2.5 เซนเซอร์ Temperature Transducers รหัสรุ่น SS6L (Biopac, n.d.)

2) อุปกรณ์ตรวจสอบระดับความร้อนและความเย็น

อุปกรณ์การตรวจสอบระดับอุณหภูมิของเจลความร้อนและความเย็นโดยใช้อุปกรณ์ดังต่อไปนี้

ก) อุปกรณ์วัดอุณหภูมิแบบ Infrared ของแบรนด์ Deli รหัสรุ่น EDL333380 สำหรับการวัดอุณหภูมิบริเวณฝ่ามือก่อนเข้ารับการทดลอง และวัดอุณหภูมิของเจลร้อนและเจลเย็น

ข) อุปกรณ์วัดอุณหภูมิแบบการขยายตัวด้วยวัสดุ ของ Timemore Digitals Thermometer สำหรับการวัดอุณหภูมิเจลความร้อนและความเย็น และใช้เปรียบเทียบอุณหภูมิกับอุปกรณ์ชนิด Infrared ซึ่งคุณสมบัติพื้นฐานของอุปกรณ์สำหรับวัดอุณหภูมิจะแสดงดังตารางที่ 2.4 และตัวอย่างอุปกรณ์วัดอุณหภูมิจะแสดงดังภาพที่ 2.6

ตารางที่ 2.4 คุณสมบัติของอุปกรณ์ที่ใช้ในการวัดอุณหภูมิ

อุปกรณ์	คุณสมบัติ
ก	SAP : 100144966 Reference .No.: EDL333380 Product Color : Yellow Main Material : -30~380 °C SAP Spec : -30~380 °C Measurement Unit : °C / °F Package Type : Color Box Package Manner : 1:PCS 5:BX1 60:CAR Accuracy rate : ± 2 °C
ข	Range :-20 - 120 C Measurement Unit : °C / °F Battery : Disposable CR2032 3V, 210mAh Accuracy rate : ± 0.1 °C

(ก

(ข)

ภาพที่ 1 (ก) รูปตัวอย่างของเครื่องวัดอุณหภูมิแบบใช้ Infrared ของ Deli รุ่น EDL333380

ภาพที่ 2 (ข) รูปตัวอย่างการเครื่องวัดอุณหภูมิแบบใช้ชนิดการขยายตัวของวัสดุ ของ Timemore Digital Thermometer

ภาพที่ 2.6 รูปตัวอย่างอุปกรณ์ในการวัดอุณหภูมิ

2.2.2 เทคโนโลยีด้านซอฟต์แวร์ (Software)

โครงงานนี้จะจำแนกระดับความเจ็บปวดโดยอาศัย ML โดยใช้ภาษา Python ซึ่งเป็นภาษาที่นิยมใช้ในการพัฒนา โดยใช้ Neurokit2 ซึ่งเป็นเครื่องมือในการวิเคราะห์ข้อมูล (Data Analyst: DA) และใช้ PyTorch ซึ่งเป็นเครื่องมือในการพัฒนา ML และ BIOPAC Software ในการจัดการข้อมูลจากชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC โดยมีรายละเอียดของซอฟต์แวร์ที่ใช้ดังนี้

1) การเรียนรู้ของเครื่อง (Machine Learning : ML)

การเรียนรู้ของเครื่องเป็นเทคโนโลยีหนึ่งในสาขาปัญญาประดิษฐ์ (Artificial Intelligence : AI) ที่ทำให้ระบบสามารถเรียนรู้ (Learning) และวิเคราะห์ข้อมูล (Inference) เพื่อแก้ปัญหาได้ เช่น การประเมินระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ ต้องอาศัยการวิเคราะห์สัญญาณทางสรีรวิทยาที่ได้จากผู้ป่วยโดยตรง สัญญาณเหล่านี้มีความแตกต่างกันไปในแต่ละบุคคล กระบวนการนี้ต้องอาศัยการเรียนรู้จากข้อมูลเดิมที่เคยบันทึกไว้ (Experience) และการฝึกด้วยข้อมูล (Training) ที่มีผลเฉลย (Labeled Data) เพื่อให้ระบบสามารถทำนายระดับความเจ็บปวดได้อย่างแม่นยำ ระบบจะเรียนรู้และพัฒนาตัวเองโดยค้นหารูปแบบความสัมพันธ์ในข้อมูลซ้ำ ๆ เช่น การวิเคราะห์ความสัมพันธ์ระหว่างสัญญาณ EDA กับระดับความเจ็บปวด หรือ ค่า HRV กับระดับความเจ็บปวด เป็นต้น ดังนั้น การนำเทคโนโลยีการเรียนรู้ของเครื่องมาช่วยจดจำและวิเคราะห์ข้อมูลทางสรีรวิทยาที่เชื่อมโยงกับระดับความเจ็บปวด จึงเป็นวิธีที่เหมาะสมในการช่วยทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ กระบวนการนี้ใช้ข้อมูลที่มีคำตอบชัดเจน (Labeled Dataset) และอาศัยการเรียนรู้แบบมีผู้สอน (Supervised Learning : SL) เพื่อให้ระบบสามารถวิเคราะห์และทำนายผลได้อย่างถูกต้อง

กระบวนการเรียนรู้แบบ SL เป็นกระบวนการเรียนรู้ของเครื่องจากข้อมูลที่มีผลเฉลยกำกับ ซึ่งหมายความว่าระบบจะเรียนรู้จากข้อมูลตัวอย่างที่มีความถูกต้อง โดยสามารถแบ่งกระบวนการเรียนรู้แบบ SL ได้เป็น 3 กลุ่ม ดังนี้

กลุ่ม Geometry เป็นการวิเคราะห์คุณลักษณะระดับความเจ็บปวดโดยอิงจากการวัดระยะห่างระหว่างแต่ละคลาสโดยเครื่องจะเลือกจัดกลุ่มกับคลาสที่อยู่ใกล้ที่สุด ตัวอย่างอัลกอริทึมได้แก่ Artificial Neural Network (ANN), k-Nearest Neighbors (k-NN) และ Support Vector Machine (SVM)

กลุ่ม Probability เป็นการวิเคราะห์คุณลักษณะของระดับความเจ็บปวดโดยใช้การคำนวณความน่าจะเป็นของแต่ละคลาส โดยใช้การแจกแจงความน่าจะเป็นแบบมีเงื่อนไข $P(Y|X)$ โดยเครื่องจะจัดประเภทให้กับคลาสที่มีค่าความน่าจะเป็นสูงที่สุด ตัวอย่างอัลกอริทึมได้แก่ Naive Bayes

กลุ่ม Logical Expression เป็นการวิเคราะห์คุณลักษณะระดับความเจ็บปวด โดยใช้กฎเชิงตรรกะ (If-Then Expression) โดยอาศัยฟังก์ชัน Boolean (เช่น If X then Y) เพื่อให้เครื่องสามารถจัดประเภทคลาสโดยอิงจากตรรกะที่แตกต่างกัน ตัวอย่างอัลกอริทึมได้แก่ Decision Tree และ Random Forest

2) BIOPAC Student lab 4.1

BIOPAC Student Lab 4.1 เป็นซอฟต์แวร์ที่พัฒนาขึ้นเพื่อใช้ในงานการศึกษาและการวิจัยด้านสรีรวิทยา โดยออกแบบมาเพื่อให้สามารถทำการทดลองเกี่ยวกับสัญญาณทางสรีรวิทยาได้อย่างมีประสิทธิภาพ ซอฟต์แวร์นี้สามารถเก็บข้อมูลจากชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC ที่รองรับการวัดสัญญาณต่าง ๆ เช่น EDA ECG SKT และสัญญาณทางสรีรวิทยาอื่น ๆ ได้ในเวลาเดียวกัน

2.3 งานวิจัยหรือระบบที่ใกล้เคียง

ในการออกแบบและพัฒนาโมเดลในการทำนายระดับความเจ็บปวดสำหรับผู้ป่วยที่ไม่สามารถสื่อสารได้ มีการศึกษางานวิจัยที่เกี่ยวข้องหลายงานวิจัยเพื่อใช้เป็นแนวทางในการปรับปรุงการพัฒนาโครงงานนี้ โดยมุ่งพิจารณาประเด็นหลัก ๆ ซึ่งประกอบด้วย 1) ปัญหาของงานวิจัยที่ใกล้เคียง 2) เทคนิคหรือกระบวนการแก้ปัญหาในงานวิจัย 3) จุดเด่นของงานวิจัย และ 4) ข้อจำกัดของงานวิจัยดังกล่าว ซึ่งสามารถสรุปประเด็นสำคัญได้ดังตารางที่ 2.5

ตารางที่ 2.5 สรุปการเปรียบเทียบงานวิจัยที่เกี่ยวข้อง

เรื่อง	ปัญหา	เทคนิค / วิธีการ	จุดเด่น	ข้อจำกัด
Automated Pain Assessment in Children Using Electrodermal Activity and Video Data Fusion via Machine Learning (Susam et al., 2022)	การประเมินความเจ็บปวดในเด็กทำได้ยากเพราะเด็กบางคนไม่สามารถสื่อสารได้ชัดเจน จำเป็นต้องใช้การประเมินที่ไม่พึ่งพาคำพูด	ใช้สัญญาณ EDA ร่วมกับ Video Facial Expression และสกัดคุณลักษณะจาก EDA เพื่อจำแนกความเจ็บปวด โดยใช้ร่วมกับ Linear SVM	การใช้ข้อมูล EDAและข้อมูลจากวิดีโอร่วมกันสามารถจำแนกระดับความเจ็บปวดได้อย่างแม่นยำถึง 90.91%	ระบบตรวจจับสีหน้ามีข้อจำกัดในการตรวจจับบางการเคลื่อนไหวบนใบหน้า อาจได้รับผลกระทบจากปัจจัยสิ่งแวดล้อม เช่น แสงสว่าง มุมภาพ และเป็นการละเมิดความเป็นส่วนตัว
PainMeter : Automatic Assessment of Pain Intensity Levels from Multiple Physiological Signals Using Machine Learning (Albahdal et al., 2024)	การประเมินความเจ็บปวดที่พึ่งพาการรายงานจากผู้ป่วยอาจไม่แม่นยำในบางกรณี โดยเฉพาะในผู้ที่ไม่สามารถสื่อสารได้ และผลการประเมินอาจถูกบิดเบือนจากอัตวิสัยของผู้ประเมินเอง	ใช้ฐานข้อมูล BioVid Heat Pain Database ที่บันทึกสัญญาณ ECG และ EDA ในการทดลอง โดยใช้เครื่องกระตุ้นความร้อนควบคุมอุณหภูมิและเวลาและใช้เทคนิคการเรียนรู้ของเครื่อง เช่น Random Forest, SVM และ Logistic Regression	มีความแม่นยำสูงในการจำแนกความเจ็บปวดแบบสองระดับ: 87% และจำแนกแบบหลายระดับ(ระดับความเจ็บปวดที่แตกต่างกันถึง 5 ระดับ (0-4)) มีความแม่นยำ: 82% - 85% ในโมเดล Random Forest	การศึกษาใช้การกระตุ้นความเจ็บปวดที่จำกัด เช่น ความเจ็บปวดจากความร้อน ซึ่งอาจไม่สามารถนำไปใช้กับประเภทอื่น ๆ ของความเจ็บปวดได้ และไม่มีสกัดคุณลักษณะจากของสัญญาณ

ตารางที่ 2.5 (ต่อ)

เรื่อง	ปัญหา	เทคนิค / วิธีการ	จุดเด่น	ข้อจำกัด
Assessing Autonomic function from electrodermal Activity and Heart Rate Variability During cold-pressor test and emotional challenge (Ghiasi et al., 2020)	การประเมิน ระบบ ANS ด้วยค่า HRV มีข้อจำกัด เนื่องจากไม่สามารถวัดกิจกรรมของ SNS ได้แม่นยำ ขณะที่ EDA สะท้อน SNS ได้ดี แต่งานวิจัยก่อนหน้านี้มักใช้ HRV และ EDA แยกกัน ยังไม่มีการศึกษาการรวมตัวชี้วัดทั้งสองเพื่อประเมิน ระบบ ANS อย่างครบถ้วน	ทดลองนี้ใช้ BIOPAC MP35 เก็บสัญญาณ ECG และ EDA จากผู้เข้าร่วมการทดลอง 26 คน ผ่านสองขั้นตอนหลัก คือ การทดสอบ CPT เพื่อกระตุ้น SNS และ ดูวิดีโออารมณ์เชิงบวก กลางและลบ โดยใช้โมเดล SVM ทำนายอารมณ์จากการรวมสัญญาณ EDA กับค่า HRV	มีการสกัดคุณลักษณะจากสัญญาณ EDA และ ECG แล้วนำเสนอวิธีการใหม่ที่ใช้สัญญาณ EDA ร่วมกับค่า HRV เพื่อประเมินสมดุลของระบบ ANS อย่างละเอียดและสามารถจำแนกอารมณ์ด้วยความแม่นยำสูงถึง 73.08% โดยใช้โมเดล SVM	จำนวนตัวอย่างมีความไม่สมดุลระหว่างเพศ และความแปรปรวนระหว่างบุคคลในการตอบสนองทางอารมณ์อาจทำให้ความแม่นยำของโมเดลลดลง
Automated Nociceptive Pain Assessment Using Physiological Signals and a Hybrid Deep Learning Network(Subramaniam & Dass, 2021)	การประเมินความเจ็บปวดแบบจากการรายงานจากผู้ป่วยขาดความแม่นยำและใช้ไม่ได้กับผู้ป่วยทุกคน โดยเฉพาะผู้ป่วยที่มีข้อจำกัดในการสื่อสาร	ใช้ข้อมูลจาก BioVid Heat Pain Database ซึ่งเป็นชุดข้อมูลที่รวบรวมสัญญาณ ECG และ EDA จากการกระตุ้นด้วยความเจ็บปวด วิเคราะห์ผ่านโมเดล Hybrid CNN-LSTM	ใช้สัญญาณ ECG และ EDA ร่วมกับการใช้โมเดล CNN-LSTM มีค่าความแม่นยำสูงสุดอยู่ที่ 94.12%	สัญญาณทางสรีรวิทยาอาจได้รับผลกระทบ จากหลายปัจจัย เช่น ยา, ความกลัว, และความเครียดของผู้ป่วย

ตารางที่ 2.5 (ต่อ)

เรื่อง	ปัญหา	เทคนิค / วิธีการ	จุดเด่น	ข้อจำกัด
Sensitive Physiological Indices of Pain Based on Differential Characteristics of Electrodermal Activity(Kong et al., 2021)	วิธีประเมินความเจ็บปวดปัจจุบันมีความไม่แน่นอนส่งผลต่อการรักษาที่ไม่เหมาะสม จึงต้องการวิธีวัดที่อิงข้อมูลทางสรีรวิทยาเพื่อเพิ่มความแม่นยำ	ใช้ Phasic และการกระตุ้นความเจ็บปวดด้วยไฟฟ้าในระดับต่าง ๆ โดยวิธีการจำแนกประเภทด้วย SVM และ MLP	แยกความเจ็บปวดรุนแรงกับไม่มีความเจ็บปวดได้แม่นยำถึง 87% แต่แม่นยำน้อยลงเมื่อต้องแยกหลายระดับ โดยแยก 3 ระดับได้ 63% และ 5 ระดับได้ 44%	ขนาดตัวอย่างจำกัด ทดสอบเฉพาะความเจ็บปวดจากการกระตุ้นด้วยไฟฟ้า อาจไม่ครอบคลุมความเจ็บปวดประเภทอื่น

จากการทบทวนงานวิจัยที่เกี่ยวข้องดังตารางที่ 2.4 การตรวจจับและจำแนกระดับความเจ็บปวดโดยใช้สัญญาณทางสรีรวิทยา พบว่างานวิจัยที่ผ่านมามุ่งเน้นการศึกษาในกลุ่มบุคคลทั่วไปที่สามารถสื่อสารได้ โดยใช้อุปกรณ์เซนเซอร์ในการรวบรวมข้อมูลสัญญาณทางสรีรวิทยา ร่วมกับแบบสอบถามระดับความเจ็บปวด เพื่อสร้างโมเดลจดจำรูปแบบข้อมูล อย่างไรก็ตาม ยังไม่มีการศึกษาที่ครอบคลุมถึงการประยุกต์ใช้ในผู้ป่วยที่ไม่สามารถสื่อสารได้ซึ่งมีความอ่อนไหวมากกว่าคนทั่วไป โครงงานนี้จึงนำเสนอการพัฒนาระบบตรวจจับและจำแนกระดับความเจ็บปวดสำหรับผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยใช้อุปกรณ์เซนเซอร์ที่สามารถรวบรวมข้อมูลสัญญาณทางสรีรวิทยาหลากหลายชนิด เช่น สัญญาณ EDA ECG และ SKT รวมถึงข้อมูลอื่น ๆ เช่น อุณหภูมิ และคุณลักษณะส่วนบุคคล เพื่อนำใช้ในการพัฒนาโมเดลจำแนกระดับความเจ็บปวดที่มีความแม่นยำ โดยมีเป้าหมายให้ระบบนี้สามารถทำงานร่วมกับการดูแลรักษาของบุคลากรทางการแพทย์และผู้ดูแลผู้ป่วย เพื่อช่วยเพิ่มประสิทธิภาพในการประเมินความเจ็บปวดและลดภาระงานของบุคลากรทางการแพทย์ได้อย่างมีประสิทธิภาพ

บทที่ 3
การออกแบบระบบ

การออกแบบระบบมีวัตถุประสงค์เพื่อช่วยให้การพัฒนาระบบเป็นลำดับขั้นตอนตามแบบแผนเพื่อลดโอกาสที่จะเกิดความผิดพลาดและเพิ่มประสิทธิภาพในกระบวนการพัฒนาให้ดียิ่งขึ้น ในบทนี้จะกล่าวถึงกระบวนการต่าง ๆ ที่จำเป็นต่อการพัฒนาโมเดลเพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยมีประเด็นดังต่อไปนี้ 3.1) สถาปัตยกรรมของระบบ 3.2) การกำหนดกลุ่มผู้เข้าร่วมการทดลอง 3.3) การออกแบบกระบวนการทดลอง 3.4) กระบวนการเก็บข้อมูล 3.5) การวิเคราะห์และประม 3.5) การสกัดคุณลักษณะที่สำคัญจากข้อมูล และ 3.6) การทำนายระดับความเจ็บปวด ซึ่งมีรายละเอียดดังนี้

3.1 สถาปัตยกรรมของระบบ

การออกแบบและพัฒนาโมเดลเพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามาถสื่อสารได้โดยอาศัยสัญญาณทางสรีรวิทยาใช้หลักการและแนวคิดที่ได้จากการศึกษางานวิจัยที่เกี่ยวข้อง ซึ่งคำนึงถึงปัจจัยต่าง ๆ ที่ส่งผลต่อระดับความเจ็บปวด เช่น ปัจจัยด้านสภาพแวดล้อมที่เป็นสิ่งกระตุ้นความเจ็บปวด และปัจจัยที่เป็นปัจเจกบุคคล เป็นต้น ในโครงการวิจัยนี้จะเก็บข้อมูลด้านสภาพแวดล้อมที่เป็นสิ่งกระตุ้นความเจ็บปวดโดยใช้เซนเซอร์ที่เกี่ยวข้องและบันทึกข้อมูลการเปลี่ยนแปลงของสัญญาณทางสรีรวิทยาของผู้ร่วมทดลอง ซึ่งเป็นผลมาจากการเปลี่ยนแปลงของภายในร่างกายที่ผิดปกติ จากนั้นจึงนำข้อมูลดังกล่าวไปวิเคราะห์และสกัดฟีเจอร์ที่สำคัญเพื่อนำไปสู่กระบวนกระการพัฒนาโมเดลการเรียนรู้ของเครื่องเพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้

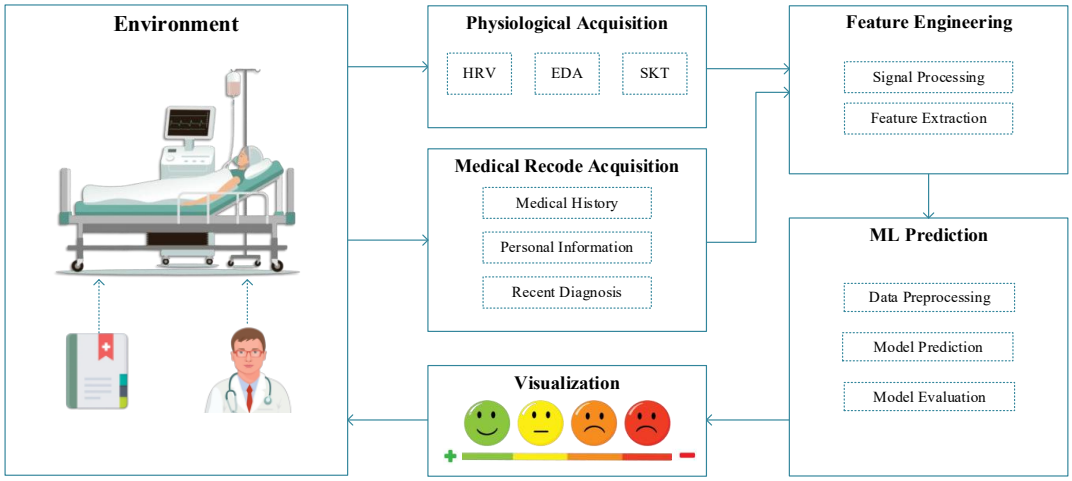

ภาพที่ 3.1 สถาปัตยกรรมระบบของการออกแบบและพัฒนาโมเดลเพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อได้โดยอาศัยสัญญาณทางสรีรวิทยา

จากภาพที่ 3.1 แสดงให้เห็นถึงสถาปัตยกรรมของระบบสำหรับการออกแบบและพัฒนาตัวแบบการเรียนรู้เครื่องเพื่อทำนายระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้โดยสามารถแบ่งออกเป็น 6 ส่วน ได้แก่ 1) สิ่งแวดล้อม (Environment) 2) การได้มาของสัญญาณทางสรีรวิทยา (Physiological Acquisition) 3) การได้มาของข้อมูลทางการแพทย์ (Medical Records Acquisition) 4) การสกัดคุณลักษณะที่สำคัญ (Feature Engineering) 5) การทำนายด้วยการเรียนรู้ของเครื่อง (ML Prediction) และ 6) การแสดงผลการประเมินความเจ็บปวด (Visualization) โดยมีรายละเอียดดังต่อไปนี้

1) สิ่งแวดล้อม (Environment) สภาพแวดล้อมในสถานพยาบาลที่มีผู้ป่วยเข้ารับการรักษาและมีความเสี่ยงต่อการเผชิญกับอาการเจ็บปวดอย่างต่อเนื่อง เช่น ผู้ป่วยวิกฤติ ผู้ป่วยหลังการผ่าตัด ผู้ป่วยสภาวะดังกล่าวต้องได้รับการประเมินความเจ็บปวดอย่างใกล้ชิด เพื่อติดตามอาการเจ็บปวดและให้ยาระงับเพื่อหลีกเลี่ยงความทุกข์ทรมานอันเนื่องมาจากแผลผ่าตัด โดยการติดตามและประเมินความเจ็บปวดจะใช้ข้อมูลสัญญาณทางสรีรวิทยา ซึ่งข้อมูลเหล่านี้จะถูกนำไปประมวลผลเพื่อประเมินระดับความเจ็บปวดได้โดยอัตโนมัติ

2) การได้มาของสัญญาณทางสรีรวิทยา (Physiological Acquisition) เป็นกระบวนการสำคัญในการเชื่อมโยงระหว่างสภาพแวดล้อมของผู้ป่วยในสถานพยาบาลกับกระบวนการประเมินระดับความเจ็บปวด กระบวนการนี้ประกอบด้วยการเก็บรวบรวมสัญญาณทางสรีรวิทยาประกอบด้วยสัญญาณ EDA ECG และ SKT โดยสัญญาณ ECG นำไปวิเคราะห์เป็นค่า HRV

3) การได้มาของข้อมูลทางการแพทย์ (Medical Records Acquisition) ข้อมูลทางการแพทย์ของผู้ป่วยครอบคลุมถึงประวัติการรักษา ผลการวินิจฉัยโรค การให้ยาและการรักษาตลอดจนข้อมูลอื่น ๆ ที่เกี่ยวข้องกับสุขภาพของผู้ป่วย โดยการรวบรวมข้อมูลดังกล่าวมี วัตถุประสงค์เพื่อเพิ่มประสิทธิภาพและความแม่นยำในการประเมินระดับความเจ็บปวด

4) การสกัดคุณลักษณะที่สำคัญ (Feature Engineering) การได้มาของข้อมูลสัญญาณสรีรวิทยาดังที่กล่าวมาข้างต้นเป็นข้อมูลดิบ ซึ่งจะประกอบด้วยสัญญาณรบกวน (Noise) ที่อาจเกิดจากข้อจำกัดในการเก็บข้อมูลและตัวเครื่องมือ ดังนั้นจึงใช้การสกัดคุณลักษณะเพื่อสกัดส่วนของข้อมูลที่สำคัญและจำเป็นต่อการประเมินระดับความเจ็บปวดของผู้ป่วย กระบวนการดังกล่าวช่วยเพิ่มความแม่นยำและความน่าเชื่อถือของข้อมูลจึงนำข้อมูลเข้าสู่กระบวนการเรียนรู้ของเครื่องในการพัฒนาตัวแบบสำหรับการทำนาย

5) การทำนายด้วยการเรียนรู้ของเครื่อง (ML Prediction) เป็นขั้นตอนวิธีการประเมินระดับความเจ็บปวดแบบอัตโนมัติ การประเมินจะแบ่งออกเป็น 4 ระดับ ประกอบด้วยระดับ 0 หมายถึง ไม่มีความเจ็บปวด ระดับ 1 มีความเจ็บปวดเล็กน้อย ระดับ 2 มีความเจ็บปวดปานกลาง และ ระดับ 3 มีความเจ็บปวดมาก ผลลัพธ์จากการทำนายจะแสดงผลในรูปแบบที่บุคลากรทางการแพทย์สามารถเข้าใจได้ง่าย เพื่อให้การช่วยเหลือได้ทันท่วงที

6) การแสดงผลการประเมินความเจ็บปวด (Visualization) ระดับความเจ็บปวดเป็นกระบวนการแปรผลจากการทำนายของตัวแบบ ซึ่งเป็นภาษาทางการประมวลผลโดยคอมพิวเตอร์และแปลงให้อยู่ในรูปแบบภาษาธรรมชาติซึ่งเจ้าหน้าที่ที่เกี่ยวข้องสามารถเข้าใจและตีได้ โดยอาจจะแสดงด้วยสัญลักษณ์และสีที่เป็นการแจ้งเตือนไปยังห้องปฏิบัติการแผนกผู้ป่วยในทันทีที่ตรวจพบระดับความเจ็บปวดที่มีแนวโน้มขึ้น การแจ้งเตือนนี้ช่วยให้บุคลากรทางการแพทย์สามารถประเมินสถานการณ์ได้อย่างรวดเร็วและให้ความช่วยเหลือในการบรรเทาความเจ็บปวดได้อย่างทันท่วงทีและเหมาะสม

3.2 การกำหนดกลุ่มผู้เข้าร่วมการทดลอง

การสร้างโมเดลจำเป็นต้องมีชุดข้อมูล (Dataset) เพื่อฝึกฝนโมเดลให้เรียนรู้จากชุดข้อมูลเหล่านั้น ดังนั้นการเลือกกลุ่มผู้เข้าร่วมการทดลองจึงมีความสำคัญ เนื่องจากการเลือกกลุ่มตัวอย่างผู้เข้าร่วมการทดลองที่มีความหลากหลายและครอบคลุมกลุ่มประชากรทำให้ได้ชุดข้อมูลที่มีความหลากหลายและครบถ้วน ในโครงงานนี้แบ่งกลุ่มผู้เข้าร่วมการทดลองออกเป็น 3 กลุ่ม ได้แก่ กลุ่มที่มีค่าดัชนีมวลกายต่ำกว่าเกณฑ์ กลุ่มที่มีค่าดัชนีมวลกายพอดีเกณฑ์ และกลุ่มที่มีค่าดัชนีมวลกายเกินเกณฑ์ โดยกลุ่มผู้เข้าร่วมการทดลองในโครงงานนี้จะเป็นกลุ่มนักศึกษาที่กำลังศึกษาอยู่ในมหาวิทยาลัยวลัยลักษณ์ ทั้งเพศชายและเพศหญิง มีอายุระหว่าง 19 ถึง 22 ปี จำนวน 30 คน โดยจะมีรายละเอียดจำนวน อายุเฉลี่ย และค่าดัชนีมวลกายเฉลี่ย ดังตารางที่ 3.1

ตารางที่ 3.1 รายละเอียดผู้เข้าร่วมการทดลอง

BMI	เพศ	จำนวน (คน)	อายุเฉลี่ย (ปี)	BMI เฉลี่ย
ต่ำกว่าเกณฑ์ (น้อยกว่า 18.5)	ชาย	5	20.20 ± 0.44	16.58 ± 1.10
	หญิง	5	21.00 ± 0.00	16.86 ± 1.23
พอดีเกณฑ์ (18.5 – 24.9)	ชาย	5	20.40 ± 0.54	20.72 ± 1.34
	หญิง	5	20.60 ± 0.54	21.14 ± 2.16
เกินเกณฑ์ (มากกว่า 24.9)	ชาย	5	20.40 ± 0.89	29.08 ± 3.84
	หญิง	5	21.00 ± 0.70	26.86 ± 1.74
โดยคำนวณจาก BMI = น้ำหนัก (กิโลกรัม) / ส่วนสูง (เมตร2)				

3.3 การออกแบบกระบวนการทดลอง

เมื่อได้กลุ่มผู้เข้าร่วมการทดลองแล้วในส่วนถัดไปจะกล่าวถึงการออกแบบกระบวนการทดลองที่มีความสำคัญเพื่อให้ได้ข้อมูลที่ครบถ้วนที่สุด โดยโครงงานนี้มุ่งเน้นไปที่การพัฒนาเครื่องมือและการเรียนรู้ของเครื่อง โดยการกระตุ้นความเจ็บปวดซึ่งสามารถแบ่งออกเป็นสองประเภท คือ 1) กระตุ้นด้วยความร้อน และ 2) กระตุ้นด้วยความเย็น ทั้งสองวิธีการจะกระตุ้นระบบประสาท

รับความรู้สึกและวัดสัญญาณทางสรีรวิทยาด้วยชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC หลังจากกระตุ้นความเจ็บปวด การออกแบบและตั้งค่าชุดเซนเซอร์และการเก็บรวบรวมข้อมูลมีรายละเอียดดังนี้

3.3.1 การออกแบบด้านสภาพแวดล้อม (Environment Design)

ในการเก็บข้อมูลการเปลี่ยนแปลงทางด้านสัญญาณสรีรวิทยาที่มีผลมาจากความเจ็บปวด โดยแบ่งเงื่อนไข (Condition) การทดลองเพื่อศึกษาและบันทึกกระบวนการตอบสนองทางสัญญาณทางสรีรวิทยาของผู้เข้าร่วมการทดลองเมื่อร่างกายได้รับผลกระทบจากความเจ็บปวดที่เกิดจากการโดนกระตุ้นด้วยความร้อนและความเย็น โดยกระบวนการออกแบบการทดลองได้อ้างอิงถึงงานวิจัยที่ผ่านมาของ Winslow และคณะ (Winslow et al., 2022) ทดสอบการกระตุ้นความเจ็บปวดด้วยความร้อน และงานวิจัยของ Zhi และคณะ (Zhi et al., 2024) ทดสอบการกระตุ้นความเจ็บปวดด้วยความเย็น ซึ่งได้จำลองเงื่อนไข 3 สถานการณ์ ได้แก่ อุณหภูมิปกติ (Normal Condition) อุณหภูมิความร้อน (Warm Condition) และอุณหภูมิความเย็น (Cold Condition) โดยแสดงรายละเอียดได้ดังภาพที่ 3.2

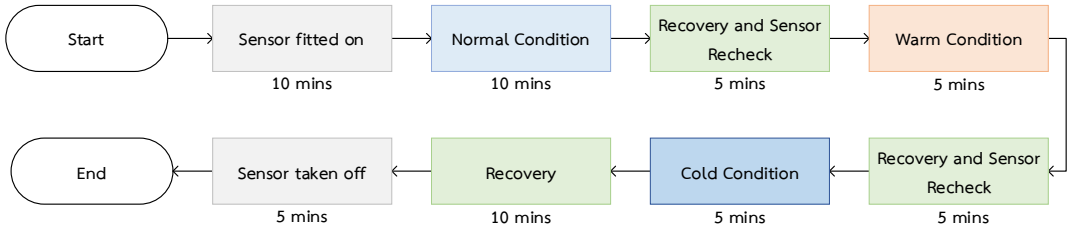

ภาพที่ 3.2 การออกแบบกระบวนการและเงื่อนไขในการทดลอง

จากภาพที่ 3.2 ได้แสดงถึงกระบวนการและเงื่อนในไขทดลองที่เกิดขึ้น โดยใช้ระยะเวลารวมต่อคนประมาณ 55 นาที โดยมีรายละเอียดดังนี้

1. Sensor fitted on : เป็นการติดตั้งชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC และอธิบายกระบวนการทดลองให้ผู้เข้าร่วมการทดลองทราบถึงรายละเอียด รวมถึงการเก็บข้อมูลด้วยแบบสอบถามใช้เวลาประมาณ 10 นาที
2. Normal Condition : เป็นช่วงเวลาให้ผู้เข้าร่วมการทดลองพักและปรับตัวต่อสภาพแวดล้อมเพื่อเก็บข้อมูลสัญญาณทางสรีรวิทยาในสถานะปกติเป็นเวลา 10 นาที
3. Recovery and Sensor Rechecked : เป็นช่วงเวลาให้ผู้เข้าร่วมการทดลองได้พักจากการนั่งเป็นเวลานาน และตรวจสอบเซนเซอร์อีกครั้งเพื่อเตรียมการทดลองลำดับต่อไปใช้เวลาประมาณ 5 นาที

4. Warm Condition : กระตุ้นความเจ็บปวดผู้เข้าร่วมการทดลองด้วยเจลความร้อนเป็นเวลา 5 นาที โดยผู้เข้าร่วมสามารถยกมือออกได้ทุกเมื่อหากไม่สามารถทนต่อความเจ็บปวดที่เกิดขึ้น
5. Recovery and Sensor Rechecked : ช่วงเวลาให้ผู้เข้าร่วมการทดลองได้พัก โดยระหว่างนั้นจะให้ผู้เข้าร่วมการทดลองตอบแบบสอบถามความเจ็บปวดจาก Warm Condition และตรวจสอบเซนเซอร์อีกครั้งเพื่อเตรียมการทดลองลำดับต่อไป ใช้เวลาประมาณ 5 นาที
6. Cold Condition : กระตุ้นความเจ็บปวดผู้เข้าร่วมการทดลองด้วยเจลความเย็นประมาณ 5 นาที โดยผู้เข้าร่วมสามารถยกมือออกได้ทุกเมื่อหากไม่สามารถทนต่อความเจ็บปวดที่เกิดขึ้นได้
7. Recovery : ช่วงเวลาให้ผู้เข้าร่วมการทดลองได้พัก โดยระหว่างนั้นจะให้ผู้เข้าร่วมการทดลองตอบแบบสอบถามความเจ็บปวดจาก Cold Condition โดยใช้เวลาประมาณ 10 นาที
8. Sensor taken off : ถอดชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC และมีการให้ตอบแบบสอบถามระดับความเจ็บปวดที่เกิดจากการสัมผัสความร้อนและความเย็น

ห้องควบคุมสภาพแวดล้อมตั้งอยู่ภายในมหาวิทยาลัยวลัยลักษณ์ จังหวัดนครศรีธรรมราช ในภาคใต้ของประเทศไทย ซึ่งมีสภาพอากาศแบบร้อนชื้นกล่าวคือมีอุณหภูมิอากาศและมีความชื้นสัมพัทธ์ในอากาศค่อนข้างสูง โดยการควบคุมสภาพแวดล้อมอากาศภายในห้องให้มีอุณหภูมิอากาศภายในห้อง 25±1°C และอุณหภูมิที่ใช้ในการกระตุ้นความเจ็บปวดมีรายละเอียดดังตารางที่ 3.2

ตารางที่ 3.2 การควบคุมอุณหภูมิที่ใช้กระตุ้นความเจ็บปวดในแต่ละ Condition

Condition	อุณหภูมิห้อง (°C)	อุณหภูมิที่ใช้กระตุ้น (°C)	รายละเอียด
Normal	25±1°C	-	ไม่มีการกระตุ้นความเจ็บปวด
Warm	25±1°C	60±5°C	กระตุ้นความเจ็บปวดด้วยอุณหภูมิความร้อน
Cold	25±1°C	-10±5°C	กระตุ้นความเจ็บปวดด้วยอุณหภูมิความเย็น

3.3.2 การออกแบบและตั้งค่าชุดเซนเซอร์ (Sensor Design and Configuration)

โครงงานนี้มีการใช้เซนเซอร์ในการเก็บข้อมูลต่าง ๆ ซึ่งจะทำหน้าที่เลียนแบบประสาทการรับรู้ของมนุษย์ผ่านเซนเซอร์การรับรู้เชิงสรีรวิทยา

เซนเซอร์การรับรู้เชิงสรีรวิทยามีความเกี่ยวข้องกับการบันทึกการตอบสนองของสัญญาณที่ได้จากร่างกายเมื่อได้รับรู้ความเจ็บปวด โดยจะบันทึกค่า ECG EDA และ SKT ซึ่งในโครงการนี้ทำการติดตั้งอุปกรณ์บนสรีระของผู้เข้าร่วมการทดลอง โดยวิธีการติดตั้งแสดงดังภาพที่ 3.3

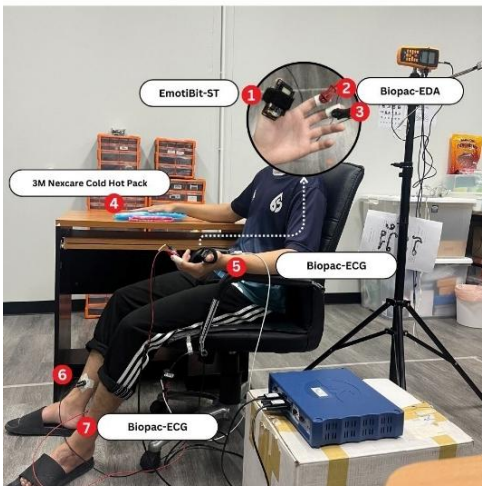

ภาพที่ 3.3 การติดตั้งเซนเซอร์บนสรีระของผู้เข้าร่วมการทดลอง

จากภาพที่ 3.3 แสดงให้เห็นถึงการติดตั้งเซนเซอร์บนสรีระของผู้เข้าร่วมการทดลองเพื่อบันทึกการตอบสนองของร่างกายเมื่อได้รับความเจ็บปวด โดยตัวเลขที่ปรากฏในภาพหมายถึงตำแหน่งในการติดตั้งของชุดเซนเซอร์ ซึ่งมีรายละเอียดดังนี้

หมายเลข 1 เป็น อุปกรณ์เซนเซอร์ของเครื่องขยายสัญญาณ BIOPAC MP36 ใช้ในการเก็บค่า SKT ซึ่งมีการติดตั้งไว้บริเวณนิ้วหัวแม่มือซ้าย

หมายเลข 2 และ หมายเลข 3 เป็นอุปกรณ์เซนเซอร์ของเครื่องขยายสัญญาณ BIOPAC MP36 ใช้ในการวัดสัญญาณ EDA ซึ่งติดตั้งบริเวณปลายนิ้วชี้ (เส้นสีแดง) และ บริเวณปลายนิ้วกลาง (เส้นสีดำ) ของมือซ้าย

หมายเลข 4 เจลประคบเย็นและร้อน (3 M Nexcare Clod Hot Pack) เป็นอุปกรณ์ในการกระตุ้นความเจ็บปวด

หมายเลข 5 หมายเลข 6 และ หมายเลข 7 เป็นอุปกรณ์เซนเซอร์ของเครื่องขยายสัญญาณ BIOPAC MP36 ใช้ในการวัดสัญญาณ ECG ซึ่งติดตั้งบริเวณแขนซ้าย (เส้นสีขาว) บริเวณขาซ้าย (เส้นสีแดง) และ บริเวณขาขวา (เส้นสีดำ)

3.3.3 การเก็บรวบรวมข้อมูล

โครงงานนี้ได้เก็บข้อมูลในช่วงระยะเวลาระหว่างวันที่ 29 กรกฎาคม พ.ศ. 2567 จนถึงวันที่ 4 ตุลาคม พ.ศ. 2567 โดยมีผู้เข้าร่วมการทดลองจำนวน 30 คน กระบวนการเก็บข้อมูลทั้งหมดได้รับการอนุมัติจากคณะกรรมการจริยธรรมการวิจัยในมนุษย์ มหาวิทยาลัยวลัยลักษณ์ (WU-EC–IN–0-273-67, August 19, 2024) โดยมีรายละเอียดในภาคผนวก ก และได้ปฏิบัติตามข้อตกลงของ Ethical Declaration of Helsinki, The Council for International Organizations of Medical Sciences และ The World Health Organization อย่างเคร่งครัด

3.4 กระบวนการเก็บข้อมูล

ข้อมูลที่ได้จากอุปกรณ์เซนเซอร์ต่าง ๆ อยู่ในรูปแบบและโครงสร้างที่แตกต่างกัน จึงจำเป็นต้องมีการออกแบบรูปแบบการจัดเก็บไฟล์ในรูปแบบเดียวกันเพื่อความสะดวกในขั้นตอนการเก็บข้อมูลและจัดการข้อมูลเบื้องต้น ซึ่งกระบวนการดังกล่าวเป็นกระบวนการที่ทำให้ข้อมูลทั้งหมดมีความพร้อมที่จะนำไปใช้งาน

3.4.1 การประแปลงข้อมูลดิจิทัลเชิงโครงสร้าง

การแปลงข้อมูลดิจิทัลเชิงโครงสร้างเป็นขั้นตอนสำคัญเนื่องจากข้อมูลที่ได้จากการเก็บรวบรวมข้อมูลจะแสดงในรูปแบบที่ระบบคอมพิวเตอร์ไม่สามารถนำไปประมวลผลได้โดยตรงดังนั้นจำเป็นต้องแปลงข้อมูลให้อยู่ในรูปแบบที่คอมพิวเตอร์สามารถเข้าใจได้เพื่อนำไปใช้ในกระบวนการสอนให้เครื่องเรียนรู้

3.4.2 การเก็บข้อมูลอื่น ๆ

นอกจากการเก็บข้อมูลทางสรีรวิทยาที่ได้จากชุดอุปกรณ์เซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC แล้ว ในโครงการวิจัยนี้มีการเก็บข้อมูลประวัติส่วนตัว ข้อมูลจากการสอบถามระดับความเจ็บปวด และข้อมูลจากสิ่งแวดล้อมเพื่อนำไปใช้ในการหาคุณลักษณะสำคัญจากข้อมูลและใช้ในกระบวนการสอนเครื่องให้เรียนรู้ โดยมีรายละเอียดดังนี้

ข้อมูลประวัติส่วนตัว (Personal Information) จะเก็บรวบรวมข้อมูล เช่น ค่า BMI ระดับไขมันในร่างกาย น้ำหนักมวลไขมัน ระดับกล้ามเนื้อ น้ำหนักมวลกล้ามเนื้อ มวลกระดูก และอัตราการเผาผลาญ เป็นต้น โดยข้อมูลส่วนนี้จะเป็นข้อมูลที่บ่งบอกถึงลักษณะที่เป็นปัจเจกบุคคล

ข้อมูลอุณหภูมิจากสภาพแวดล้อม (Environment Data) อุณหภูมิในอากาศบันทึกได้จากเครื่อง Hot Wire Anemometer เนื่องจากอุณหภูมิสภาพแวดล้อมมีผลต่อความเจ็บปวดที่เกิดจากการกระตุ้นด้วยความร้อนและความเย็น จากงานวิจัยที่ผ่านมาของ Strigo, และคณะ (Strigo et al., 2000) ระบุว่าอุณหภูมิสภาพแวดล้อมที่เย็นลงช่วยลดการรับรู้ความเจ็บปวดจากความร้อน

ข้อมูลระดับความเจ็บปวด (Pain Level Data) จะบันทึกไว้ทันทีหลังจากทดลองเสร็จสิ้นในแต่ละรอบซึ่งสามารถแบ่งระดับความเจ็บปวดได้ 4 ระดับและนำข้อมูลดังกล่าวเป็นผลเฉลย (Label) สำหรับการสอนเครื่องให้เรียนรู้ โดยมีรายละเอียดดังตารางที่ 3.3

ตารางที่ 3.3 รายละเอียดของความเจ็บปวด 4 ระดับ

ระดับ	ความรู้สึก	รายละเอียด
0	No pain (ไม่มีความรู้สึกเจ็บปวด)	ไม่มีความเจ็บปวด ร่างกายอยู่ในสภาวะปกติ ไม่มีการตอบสนองต่อความเจ็บปวดทั้งทางร่างกายและจิตใจ
1	Mild pain (รู้สึกเจ็บปวดเล็กน้อย)	เจ็บปวดเล็กน้อย รับรู้ได้ถึงความเจ็บปวดแต่ไม่รบกวนการทำกิจวัตรประจำวัน
2	Moderate pain (รู้สึกเจ็บปวดปานกลาง)	เจ็บปวดปานกลาง ส่งผลต่อการทำกิจวัตรประจำวันบางอย่าง มีความรู้สึกเจ็บปวดแต่ยังสามารถทนได้
3	Severe pain (รู้สึกเจ็บปวดมากที่สุด)	เจ็บปวดรุนแรงมากที่สุด ไม่สามารถทำกิจวัตรประจำวันได้ ส่งผลกระทบทั้งทางร่างกายและจิตใจอย่างรุนแรง

3.5 การวิเคราะห์และประมวลผลข้อมูล

เมื่อมีการเก็บข้อมูลเสร็จสิ้น จำเป็นต้องมีการวิเคราะห์และประมวลผลข้อมูลเบื้องต้น (Data Preprocessing) เพื่อเตรียมข้อมูลให้พร้อมสำหรับการใช้งานในขั้นถัดไป โดยในกระบวนการนี้จะประกอบด้วยการวิเคราะห์และสกัดองค์ประกอบย่อยของสัญญาณทางสรีรวิทยาบางตัว เช่น การสกัดองค์ประกอบของสัญญาณ EDA ได้แก่ Tonic และ Phasic และการคำนวณหาความผันแปรของอัตราการเต้นของหัวใจ (HRV) จากสัญญาณ ECG รวมถึงกระบวนการสำคัญต่าง ๆ ที่ทำให้ได้ชุดข้อมูลที่มีความพร้อมต่อการนำไปใช้ในกระบวนการสอนเครื่องให้เรียนรู้ เช่น การทำความสะอาดข้อมูลและการสกัดคุณลักษณะเด่นจากข้อมูล โดยมีรายละเอียดดังนี้

3.5.1 การสกัดสัญญาณกิจกรรมทางไฟฟ้าบนผิวหนัง (EDA)

สัญญาณกิจกรรมทางไฟฟ้าบนผิวหนังที่บันทึกไว้มีอัตราการสุ่ม (Sampling Rate) เท่ากับ 5000 ครั้งต่อวินาทีซึ่งเป็นข้อมูลที่มีขนาดใหญ่จึงจำเป็นต้องลดขนาดของข้อมูลด้วยการ Down sampling ให้เหลือ 100 ครั้งต่อวินาที จากนั้นนำข้อมูลดังกล่าวเข้าสู่การกรองสัญญาณผ่านไลบรารี NeuroKit2 ด้วยวิธี cvxeda (Convex Optimization) ซึ่งเป็นอัลกอริทึมพื้นฐานบน Bayesian statistics และ Mathematical convex optimization and sparsity ที่มีความสามารถในการจัดการกับข้อมูลที่ผิดพลาดจากการบันทึกและจัดการกับข้อมูลที่มี Noise ได้ โดยจะได้ตัวอย่างของสัญญาณที่ผ่านการกรองและแยกองค์ประกอบ Phasic และ Tonic ดังภาพที่ 3.4

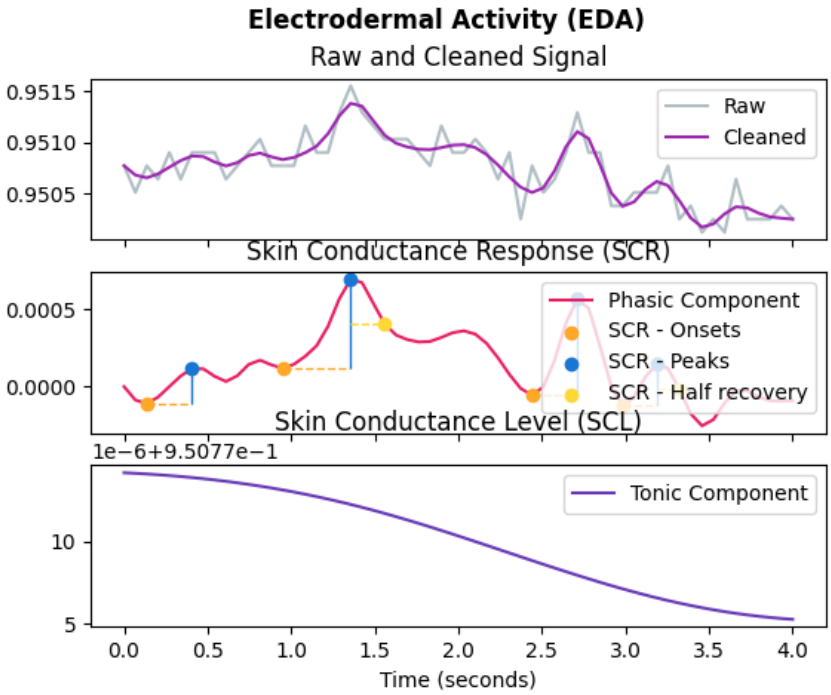

ภาพที่ 3.4 องค์ประกอบของสัญญาณ EDA ที่ผ่านการสกัดจาก NeuroKit2 (cvxEDA)

3.5.2 การสกัดความผันแปรของอัตราการเต้นของหัวใจ (HRV)

ข้อมูลคลื่นไฟฟ้าหัวใจจะจัดเก็บในรูปแบบสัญญาณ ECG ที่บันทึกไว้มี Sampling Rate เท่ากับ 5000 ครั้งต่อวินาที โดยสัญญาณจะมีการกำหนดขอบที่อยู่ในช่วง 0.5 ถึง 3.7 Hz ซึ่งจะใช้ NeuroKit2 ในการวิเคราะห์ค่า HRV ได้แก่

- Low Frequency (LF) เป็นช่วงความถี่ต่ำ 0.05 ถึง 0.15 Hz โดยมีระยะเวลาในการคำนวณอย่างต่ำ คือ 2 นาที
- High Frequency (HF) เป็นช่วงความถี่สูง 0.15 ถึง 0.5 Hz โดยมีระยะเวลาในการคำนวณอย่างต่ำ คือ 1 นาที
- Raito of LF and HF (LFHF) เป็นอัตราส่วนระหว่าง LF และ HF โดยมีระยะเวลาในการคำนวณอย่างต่ำ คือ 5 นาที

3.5.3 สัญญาณสรีรวิทยาอื่น ๆ

ข้อมูลอุณหภูมิผิวหนัง

3.5.4 ข้อมูลอื่น ๆ

ข้อมูลบุคคลจำเป็นต้องมีการแปลงจากข้อมูลตัวอักษรเป็นข้อมูลตัวเลข (Encoding) ได้แก่ เพศ (เพศชายแทนเป็นเลข 1 และเพศหญิงแทนเป็นเลข 2) และระดับความเจ็บปวด มีการแทนด้วยตัวเลขดังนี้

- ไม่มีความเจ็บปวด แทนเป็นเลข 0
- มีความเจ็บปวดเล็กน้อย แทนเป็นเลข 1
- มีความเจ็บปวดปานกลาง แทนเป็นเลข 2
- มีความเจ็บปวดมาก แทนเป็นเลข 3

เมื่อได้ข้อมูลทั้งหมดจึงมารวมเป็นไฟล์เดียวกันซึ่งเป็นชุดข้อมูลที่รวบรวมโดย 1 ชุดทรานเซกชัน (Transaction) จะถูกเฉลี่ยมาจากทุก ๆ 15 วินาทีของช่วงสัญญาณ เนื่องจากช่วงนี้เป็นช่วงที่บ่งชี้ถึงระดับความเจ็บปวดได้อย่างชัดเจนและมีนัยสำคัญ แม้ว่าข้อมูลในกลุ่มสัญญาณ EDA หรือค่า HRV จะขาดหายไปบางส่วน (Missing Value) ซึ่งจะแสดงตัวอย่างข้อมูลปกติที่สมบูรณ์ดังตารางที่ 3.4 แสดงตัวอย่างข้อมูล Missing Value ของกลุ่มสัญญาณ EDA ดังตารางที่ 3.5 และ แสดงตัวอย่างข้อมูล Missing Value ของกลุ่มค่า HRV ดังตารางที่ 3.6

ตารางที่ 3.4 ตัวอย่างรายการข้อมูลที่ครบถ้วนสมบูรณ์

EDA_Raw	Phasic	Tonic	LFHF	LF	HF	SKT	...	PainLevel
33.22	0.63	32.54	0.60	0.03	0.09	32.96	...	0
38.02	1.93	36.13	2.41	0.20	0.22	33.79	...	3
40.26	0.44	39.89	1.69	0.05	0.04	34.60	...	2
38.49	0.22	38.35	0.68	0.02	0.03	32.35	...	0
...	...	...	...	...	...	...	...	...
34.73	0.01	34.66	0.92	0.04	0.13	34.58	...	1

ตารางที่ 3.5 ตัวอย่างข้อมูล Missing Value ของกลุ่มสัญญาณ EDA

EDA_Raw	Phasic	Tonic	LFHF	LF	HF	SKT	...	PainLevel
	0.63	32.54	0.60	0.03	0.09	32.96	...	0
38.02		36.13	2.41	0.20	0.22	33.79	...	3
	0.44		1.69	0.05	0.04	34.60	...	2
38.49		38.35	0.68	0.02	0.03	32.35	...	0
...	...	...	...	...	...	...	...	...
34.73	0.01	34.66	0.92	0.04	0.13	34.58	...	1

ตารางที่ 3.6 ตัวอย่างข้อมูล Missing Value ของกลุ่มค่า HRV

EDA_Raw	Phasic	Tonic	LFHF	LF	HF	SKT	...	PainLevel
33.22	0.63	32.54		0.03	0.09	32.96	...	0
38.02	1.93	36.13	2.41	0.20		33.79	...	3
40.26	0.44	39.89	1.69		0.04	34.60	...	2
38.49	0.22	38.35		0.02		32.35	...	0
...	...	...	...	...	...	...	...	...
34.73	0.01	34.66	0.92	0.04	0.13	34.58	...	1

อย่างไรก็ตามข้อมูลดังกล่าวเป็นเพียงข้อมูลทั่วไป ไม่บ่งชี้ถึงระดับความเจ็บปวดได้ จึงต้องมีการสกัดคุณลักษณะสำคัญจากข้อมูล

3.6 การสกัดคุณลักษณะสำคัญจากข้อมูล (Feature Extraction)

การสกัดคุณลักษณะสำคัญเป็นกระบวนการดึงคุณลักษณะที่โดดเด่นที่อยู่ในสัญญาณทั่วไป เพื่อให้สามารถนำไปสร้างและทดสอบตัวแบบการเรียนรู้ของเครื่องในการจำแนกระดับความเจ็บปวดของผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยในโครงงานนี้ผู้จัดทำใช้วิธีการเลือกคุณลักษณะที่มีนัยสำคัญต่อการทำนายระดับความเจ็บปวด โดยการวิเคราะห์ความสัมพันธ์ระหว่างแต่ละคุณลักษณะ (Feature) กับผลระดับความเจ็บปวด (Lable) ซึ่งประเมินจากค่า p-value โดยค่ามาตรฐานต้องน้อยกว่า 0.05 (สามารถตีความได้ว่าในทุก ๆ 100 เหตุการณ์ คุณลักษณะที่เลือกจะไม่มีความสัมพันธ์กับระดับความเจ็บปวดน้อยกว่า 5 ครั้ง) และค่าโดยสัญญาณทางสรีรวิทยาที่เป็น Feature ที่สัมพันธ์กับระดับความเจ็บปวด ได้แก่ EDA Raw, Phasic, Tonic, LF, HF, LFHF, Skin Temp และข้อมูลส่วนบุคคลที่เป็นคุณลักษณะสำคัญ คือ ค่า BMI โดยแต่ละ Feature มีค่า p-value ในแต่ละ Class ของความเจ็บปวด ดังตารางที่ 3.7

ตารางที่ 3.7 ค่า p-value ของแต่ละ Feature ในแต่ละ Class

Feature	p-value Class 1	p-value Class 2	p-value Class 3
LF/HF	**9.70×10^{-20}**	**9.63×10^{-5}**	**3.90×10^{-5}**
LF	**5.94×10^{-9}**	**1.96×10^{-8}**	**1.00×10^{-12}**
HF	**1.12×10^{-3}**	**6.75×10^{-5}**	4.02×10^{-1}
EDA Raw	**3.01×10^{-14}**	**7.55×10^{-22}**	**1.05×10^{-11}**
Tonic	**4.60×10^{-15}**	**8.38×10^{-25}**	**1.45×10^{-10}**
Phasic	6.84×10^{-2}	8.74×10^{-1}	**8.18×10^{-9}**

Feature	p-value Class 1	p-value Class 2	p-value Class 3
SKT	3.79×10^{-1}	**6.45×10^{-13}**	**1.33×10^{-33}**
BMI	**1.30×10^{-5}**	**2.32×10^{-8}**	2.07×10^{-1}

จากตารางที่ 3.7 จะพบว่ามี Feature LF/HF, LF, EDA Raw และ Tonic ที่มีค่านัยสำคัญต่อการทำนายความเจ็บปวดทั้ง 3 Class ได้แก่ 1) Class 1 = มีความเจ็บปวดเล็กน้อย 2) Class 2 = มีความเจ็บปวดปานกลาง และ 3) Class 3 = มีความเจ็บปวดมาก และพบว่ามีบาง Feature ไม่มีค่านัยสำคัญในบาง Class ได้แก่ HF, Phasic, SKT และ BMI แต่ยังมีบทบาทสำคัญในโมเดล นอกจากนี้การรวม Feature Phasic และ BMI ซึ่งมีค่านัยสำคัญในบาง Class อาจช่วยเพิ่มความแม่นยำในการสะท้อนอารมณ์ที่เปลี่ยนแปลงได้รวดเร็ว เนื่องจาก Phasic มีความสัมพันธ์กับการทำงานของระบบ ANS โดยเฉพาะในส่วนของระบบประสาทซิมพาเทติกที่บ่งบอกถึงความเจ็บปวดเมื่อร่างกายได้รับกระตุ้นต่อสิ่งเร้า และ BMI เป็นข้อมูลพื้นฐาน (Default) ที่สามารถคุณลักษณะส่วนบุคคลได้อย่างรวดเร็ว

ดังนั้นในโครงงานนี้จะใช้ฟีเจอร์เหล่านี้ในการสร้างโมเดลเพื่อทำนายระดับความเจ็บปวดของผู้ที่ไม่สามารถสื่อสารได้ โดยมีฟีเจอร์ 5 รายการดังนี้

1. SKT อุณหภูมิผิวหนัง
2. BMI ค่าดัชนีมวลกาย
3. LF/HF (Ratio of LF and HF) เป็นคุณลักษณะที่ได้จากค่า HRV
4. Tonic เป็นคุณลักษณะที่ได้จาก EDA Raw
5. Phasic เป็นคุณลักษณะที่ได้จาก EDA Raw

-

บทที่ 4
การพัฒนาและการทดสอบ

บทนี้นำเสนอกระบวนการพัฒนาและทดสอบโมเดลที่ใช้ในการประเมินระดับความเจ็บปวด โดยอาศัยกระบวนการ ML ใช้ในขั้นตอนการพัฒนาโมเดล การปรับปรุงโมเดลเพื่อเพิ่มประสิทธิภาพ ไปจนถึงการทดสอบเพื่อประเมินความแม่นยำและประสิทธิภาพของโมเดล โดยใช้ Feature ที่มีความสำคัญซึ่งได้มาจากขั้นตอน Feature Extraction ในหัวข้อ 3.6 เพื่อให้ได้ ML ที่สามารถจำแนกระดับความเจ็บปวดได้อย่างมีประสิทธิภาพ

4.1 สถาปัตยกรรมของโมเดล (Model Architecture)

โครงงานนี้มีการพัฒนาโมเดลที่ควบคุมผ่านภาษา Python โดยการใช้ Boosting algorithms ร่วมกับ Scikit-Learn และประยุกต์ใช้การเรียนรู้ของเครื่องเพื่อกำหนดชุดคำสั่งให้เครื่องเรียนรู้และจดจำระดับความเจ็บปวดของกลุ่มตัวอย่าง และฝึกตัวแบบ ซึ่งผลลัพธ์ที่ได้จะเป็นตัวแบบที่สามารถเรียนรู้และจำแนกระดับความเจ็บปวดได้อย่างแม่นยำ แม้ว่ากรณีที่มีข้อมูล Missing Value โดยมีกระบวนการตรวจสอบและประเมินประสิทธิภาพของโมเดลดังภาพที่ 4.1

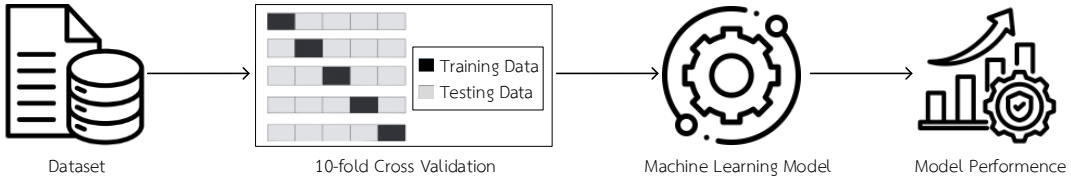

ภาพที่ 4.1 กระบวนการตรวจสอบและประเมินประสิทธิภาพของโมเดล

4.1.1 การสร้างตัวแบบ (Modeling)

การสร้างตัวแบบเป็นกระบวนการออกแบบและพัฒนาตัวแบบ ML โดยใช้ชุดข้อมูล (Dataset) ที่ได้จากกลุ่มตัวอย่าง โดยใช้เทคนิค Cross-Validation ด้วย K-Fold เท่ากับ 10 (10-fold Cross-Validation) ซึ่งเป็นกระบวนการแบ่งข้อมูลออกเป็น 10 ส่วน และทำการฝึกและทดสอบโมเดลทั้งหมด 10 รอบ ในแต่ละรอบข้อมูลจะถูกแบ่งเป็นสำหรับการฝึกโมเดล(Training Data) และสำหรับการทดสอบ (Testing Data) เพื่อให้โมเดลสามารถเรียนรู้จากข้อมูลที่หลากหลายและลดปัญหา Overfitting จากนั้นเข้าสู่กระบวนการสร้างโมเดล ML ซึ่งเป็นขั้นตอนที่โมเดลเรียนรู้จาก Training Data ที่ถูกแบ่งไว้ก่อนหน้านี้ และเมื่อกระบวนการเรียนรู้เสร็จสิ้นจะมีการประเมินประสิทธิภาพของโมเดล และมีการทำ Dataset ให้ข้อมูล Missing Value ของสัญญาณทางสรีรวิทยากลุ่มสัญญาณ EDA หรือค่า HRV ดังตามตารางที่ 3.5 และ ตารางที่ 3.6 ตามลำดับ

4.1.2 การกำหนดค่าไฮเปอร์พารามิเตอร์ (Hyperparameter Configuration)

การกำหนดค่าไฮเปอร์พารามิเตอร์เป็นขั้นตอนสำคัญในการพัฒนาแบบจำลอง ML เนื่องจากค่าพารามิเตอร์ที่กำหนดโดยค่าเริ่มต้นอาจไม่เหมาะสมที่สุดสำหรับชุดข้อมูลที่ใช้ในการศึกษา การหาค่าพารามิเตอร์ที่เหมาะสมด้วยการปรับแต่งแบบ Manual Tuning นั้นเป็นกระบวนการที่ใช้ระยะเวลานานและอาจไม่นำไปสู่ผลลัพธ์ที่ดีที่สุด ดังนั้นการปรับแต่งไฮเปอร์พารามิเตอร์แบบอัตโนมัติ (Automated Hyperparameter Optimization) จึงเป็นวิธีที่มีประสิทธิภาพในการเพิ่มความแม่นยำและลดระยะเวลาในการค้นหาค่าที่เหมาะสมที่สุด โดยในโครงงานนี้ได้ใช้เทคนิคการค้นหาค่าไฮเปอร์พารามิเตอร์แบบอัตโนมัติสองวิธี ได้แก่ Random Search ซึ่งเป็นเทคนิคที่ทำการสุ่มเลือกชุดค่าไฮเปอร์พารามิเตอร์จากขอบเขตที่กำหนดไว้ในจำนวนรอบที่กำหนด วิธีนี้มีประสิทธิภาพในการค้นหาค่าที่เหมาะสมในชุดค่าพารามิเตอร์ที่หลากหลายโดยใช้ทรัพยากรในการคำนวณอย่างมีประสิทธิภาพ และ Bayesian Optimization ซึ่งเป็นเทคนิคที่ใช้แบบจำลองความน่าจะเป็นเพื่อคาดการณ์ประสิทธิภาพของชุดค่าไฮเปอร์พารามิเตอร์ โดยอาศัยข้อมูลจากการทดลองก่อนหน้า ทั้งสองวิธีนี้จะใช้งานผ่านไลบรารี scikit-learn สำหรับ Random Search และ scikit-optimize สำหรับ Bayesian Optimization ซึ่งเป็นเครื่องมือที่ได้รับการยอมรับในการทำ Hyperparameter tuning ในงานการเรียนรู้ของเครื่อง ดังตารางที่ 4.2

การเลือกค่าไฮเปอร์พารามิเตอร์ที่เหมาะสมมีความสำคัญในการกำหนดประสิทธิภาพของโมเดลการเรียนรู้ของเครื่อง โดยเฉพาะในงานที่ต้องจัดการกับข้อมูลที่ซับซ้อนและละเอียดอ่อน เช่น ข้อมูลทางสัญญาณสรีรวิทยา ซึ่งต้องการความแม่นยำในการจำแนกระดับความเจ็บปวด โดยในโครงงานนี้ได้ศึกษาการปรับค่าไฮเปอร์พารามิเตอร์สำหรับอัลกอริทึมที่นิยมใช้ในการจัดการข้อมูลประเภทต่างๆ ได้แก่ Categorical Boosting (CatBoost) ซึ่งมีความเชี่ยวชาญในการจัดการข้อมูลประเภทหมวดหมู่ (categorical data) Light Gradient Boosting Machine (LightGBM) ที่เหมาะกับการจัดการข้อมูลขนาดใหญ่โดยเน้นที่ความเร็วและประสิทธิภาพ และ Extreme Gradient Boosting (XGBoost) ที่เหมาะสำหรับการจัดการข้อมูลขนาดเล็กถึงขนาดกลาง โดยมีความเร็วในการฝึกโมเดลที่สูง โดยโครงงานนี้มีขอบเขตการศึกษาของ Hyperparameter ดังตาราง ที่ 4.1

ตารางที่ 4.1 การกำหนด Hyperparameter

Algorithm	Hyperparameter	Search space
Catboost	n_estimator	[100, 200, 300, 400, 500, 600, 700, 800, 900]
	max_depth	[1, 2, 3, 4, 5, 6, 7, 8, 9]
	learning_rate	[0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]
LightGBM	n_estimato	[100, 200, 300, 400, 500, 600, 700, 800, 900]
	max_depth	[1, 2, 3, 4, 5, 6, 7, 8, 9]
	learning_rate	[0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9]
	num_leaves	[2, 4, 8, 16, 32, 64, 128, 256, 512, 1024]
XGBoost	n_estimator	[100, 200, 300, 400, 500, 600, 700, 800, 900]
	max_depth	[1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12]
	learning_rate	[0.01, 0.05, 0.1, 0.15, 0.2, 0.25, 0.3, 0.35, 0.4, 0.45, 0.5]
	subsample	[0.6, 0.7, 0.8, 0.9, 1.0]
	colsample	[0.1, 0.2, 0.3, 0.4, 0.5, 0.6, 0.7, 0.8, 0.9, 1.0]
	alpha	[0.1, 0.5, 1.0, 1.5, 2.0]
	lambda	[0.1, 0.5, 1.0, 1.5, 2.0]

จากตารางที่ 4.1 แสดงการกำหนด Hyperparameter และขอบเขตการค้นหาสำหรับ CatBoost LightGBM และ XGBoost โดยพารามิเตอร์หลักที่กำหนด ได้แก่ n_estimators ซึ่งหมายถึงจำนวนรอบการฝึกโมเดล max_depth ที่กำหนดความลึกสูงสุดของโครงสร้างการตัดสินใจเพื่อควบคุมความซับซ้อนของโมเดลและ learning_rate ที่ใช้ในการควบคุมอัตราการปรับค่าของพารามิเตอร์ในแต่ละรอบการฝึก นอกจากนี้สำหรับ LightGBM ที่ใช้ num_leaves ซึ่งควบคุมจำนวนหน่วยย่อยในโครงสร้างการตัดสินใจ และพารามิเตอร์เพิ่มเติมสำหรับ XGBoost ได้แก่ subsample ซึ่งเป็นสัดส่วนของข้อมูลที่ใช้ในการฝึกในแต่ละรอบ colsample ซึ่งควบคุมสัดส่วนของคุณลักษณะที่เลือกใช้ และ alpha และ lambda ซึ่งใช้ในการปรับสมดุลการฝึกเพื่อป้องกัน overfitting และค่าพารามิเตอร์ที่เหมาะสมที่สุดสำหรับแต่ละอัลกอริทึมจะมีความแตกต่างกันขึ้นอยู่กับเทคนิคที่ใช้ ดังตารางที่ 4.2

ตารางที่ 4.2 Hyperparameter แบบอัตโนมัติ ประกอบด้วย Random search และ Bayesian optimization

Algorithm	Approach	Optimal hyperparameter combination
CatBoost	Random Search	{n_estimators : 900, max_depth : 3, learning_rate : 0.9}
	Bayesian optimization	{n_estimators : 700, max_depth : 6, learning_rate : 0.4}
LightGBM	Random Search	{n_estimators : 400, max_depth : 4, learning_rate : 0.8, num_leaves : 8}
	Bayesian optimization	{n_estimators : 800, max_depth : 5, learning_rate : 0.5, num_leaves : 4}
XGBoost	Random Search	{n_estimators : 600, max_depth : 4, learning_rate : 0.3, subsample : 1.0, lambda : 2.0, alpha : 0.5, colsample_bytree : 0.8}
	Bayesian optimization	{n_estimators : 300, max_depth : 7, learning_rate : 0.25, subsample : 0.8, lambda : 1.5, alpha : 0.5, colsample_bytree : 0.6}

จากตารางที่ 4.2 แสดงค่าพารามิเตอร์ที่ได้รับการปรับแต่งและค่าที่เหมาะสมที่สุดสำหรับแต่ละอัลกอริทึม โดยใช้ Random Search และ Bayesian Optimization เพื่อค้นหาค่าที่ให้ประสิทธิภาพสูงสุด ในการศึกษานี้เลือกใช้ Random Search สำหรับ XGBoost เนื่องจากสามารถสำรวจช่วงค่าพารามิเตอร์ที่หลากหลายได้อย่างมีประสิทธิภาพ ขณะที่ Bayesian Optimization ถูกนำมาใช้กับ LightGBM และ CatBoost เนื่องจากสามารถคาดการณ์ค่าพารามิเตอร์ได้อย่างแม่นยำและมีประสิทธิภาพ ทั้งนี้การปรับแต่งไฮเปอร์พารามิเตอร์มีเป้าหมายเพื่อพัฒนาโมเดลการจำแนกระดับความเจ็บปวดแบบอัตโนมัติให้มีความแม่นยำและประสิทธิภาพสูงสุด

4.1.3 การประเมินตัวแบบ (Evaluation)

การประเมินประสิทธิภาพตัวแบบการเรียนรู้ของเครื่องเป็นขั้นตอนสำคัญในการพัฒนาตัวแบบ เพื่อวัดความถูกต้องและประสิทธิภาพของตัวแบบในการทำนายข้อมูลใหม่ ซึ่งเป็นข้อมูลที่ไม่ได้ใช้ในกระบวนการฝึก การประเมินผลจะช่วยให้เราทราบถึงความสามารถในการนำไปประยุกต์ใช้ของตัวแบบในสถานการณ์จริง และพิสูจน์สมมติฐานของโครงงานนี้ โดยจะใช้ขั้นตอนวิธีการประเมินประสิทธิภาพองโมเดล (Metrics) ได้แก่ 1) Accuracy 2) Precision 3) Recall และ 4) F1-Score โดยสามารถแสดงรายละเอียดได้ดังนี้

1. Accuracy (Acc) คือ สัดส่วนของจำนวนข้อมูลที่โมเดลสามารถจำแนกได้อย่างถูกต้องเมื่อเปรียบเทียบกับจำนวนข้อมูลทั้งหมดในชุดทดสอบ โดยโมเดลจะถือว่าจำแนกได้ถูกต้องเมื่อผลลัพธ์ที่โมเดลทำนายตรงกับค่าจริง (True Label) ของข้อมูลนั้น ๆ

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

จากสมการดังกล่าว True Positive (TP) คือ ผลลัพธ์จากการทำนายที่ถูกต้อง True Negative (TN) คือ True Negative (TN) คือ ผลลัพธ์จากการทำนายที่ถูกต้องแต่ไม่ใช่กรณีที่สนใจ False Positive (FP) คือ ผลลัพธ์จากการทำนายที่ผิด และ False Negative (FN) ผลลัพธ์จากการทำนายที่ไม่สามารถทำนายได้

2. Precision (PS) คือ ค่าความแม่นยำในการทำนายในกลุ่มเป้าหมายหรือพิจารณาเฉพาะที่เป็น TP โดยสามารถคำนวณได้จาก

$$\text{Precision} = \frac{TP}{TP+FP}$$

3. Recall (RC) คือ ค่าที่บ่งบอกถึงความสามารถของโมเดลในการตรวจจับข้อมูลที่เป็น Positive ได้ครบถ้วนเพียงใด คำนวณได้จาก

$$\text{Recall} = \frac{TP}{TP+FN}$$

4. F1-Score (F1) คือ ค่าที่ใช้วัดประสิทธิภาพโดยรวมของโมเดล โดยคำนึงถึงทั้ง Precision และ Recall อย่างสมดุล เหมาะสำหรับกรณีที่ข้อมูลไม่สมดุล (Imbalanced Data) หรือเมื่อจำเป็นต้องลดข้อผิดพลาดทั้งสองประเภทให้มากที่สุด

$$\text{F1-Score} = \frac{2 \times (\text{Precision} \times \text{Recall})}{\text{Presicion} + \text{Recall}}$$

4.2 การอภิปรายผล (Result and Discussion)

โครงงานนี้มุ่งเน้นการวิเคราะห์และพิสูจน์ประสิทธิภาพของตัวแบบการเรียนรู้ของเครื่องร่วมกับสัญญาณทางสรีรวิทยาในการทำนายระดับความเจ็บปวดแบบอัตโนมัติ โดยมีการจัดกลุ่มของสัญญาณทางสรีรวิทยา EDA และ HRV เป็น 3 กลุ่ม ได้แก่ กลุ่ม G1 G2 และ G3 ดังตารางที่ 4.3 และแสดงผลการทดลองประสิทธิภาพของโมเดลของละกลุ่มของฟีเจอร์ดังตารางที่ 4.4

ตารางที่ 4.3 กลุ่มของฟีเจอร์ที่ได้จากสัญญาณทางสรีรวิทยาร่วมกับคุณลักษณะส่วนบุคคล

Group	Feature Description
G1	BMI + SKT + Tonic + Phasic
G2	BMI + SKT + HF + LF + LF/HF
G3	BMI + SKT + Tonic + Phasic + LF/HF

ตารางที่ 4.4 ผลการทดสอบของประสิทธิภาพของโมเดล

Group	G1			G2			G3		
Model	PS	RC	F1	PS	RC	F1	PS	RC	F1
Catboost	91.64	91.58	91.54	99.79	99.79	99.79	99.35	99.33	99.33
LightGBM	91.22	91.13	91.09	100.00	100.00	100.00	99.92	99.92	99.92
XGBoost	90.98	90.75	90.70	99.96	99.96	99.96	99.55	99.54	99.54

จากตารางที่ 4.4 พบว่าการใช้กลุ่มฟีเจอร์ G2 มีประสิทธิภาพสูงสุดในการทำนายระดับความเจ็บปวด โดยกลุ่มฟีเจอร์ G2 ประกอบไปด้วยฟีเจอร์คุณลักษณะส่วนบุคคลร่วมกับค่า HRV ที่สามารถสะท้อนถึงการตอบสนองของระบบ ANS ซึ่งควบคุมการทำงานของหัวใจได้โดยตรงทำให้ฟีเจอร์ HRV สามารถสะท้อนข้อมูลที่เกี่ยวข้องกับระบบ ANS ที่เกี่ยวข้องกับระดับความเจ็บปวด ส่งผลให้กลุ่มฟีเจอร์ G2 สามารถทำนายระดับความเจ็บปวดได้อย่างแม่นยำและมีค่า F1-score ที่ 100% โดยใช้โมเดล LightGBM อย่างไรก็ตาม การคำนวณค่าดังกล่าวจำเป็นต้องอาศัยข้อมูลที่รวบรวมจากการวัดคลื่นไฟฟ้าหัวใจในช่วงระยะเวลาอย่างน้อย 1 2 และ 5 นาที เพื่อให้ได้ข้อมูลที่เพียงพอสำหรับการประมวลผลค่า HF LF และ LF/HF ตามลำดับ การใช้กลุ่มฟีเจอร์ G1 ประกอบด้วยฟีเจอร์คุณลักษณะส่วนบุคคลร่วมกับสัญญาณ EDA ที่สามารถสะท้อนการทำงานของระบบ ANS โดยส่งสัญญาณจากสมองไปยังต่อมเหงื่อผ่านกลไกที่เกี่ยวข้องกับการควบคุมของระบบไหลเวียนโลหิต การตอบสนองของต่อมเหงื่อ อุณหภูมิของผิวหนัง ซึ่งส่งผลต่อการตอบสนองของร่างกาย ทำให้กลุ่มฟีเจอร์ G1 สามารถทำนายระดับความเจ็บปวดโดยมีค่า F1-score ที่ 91.09% โดยใช้โมเดล LightGBM จะเห็นได้ว่ามีความแม่นยำน้อยกว่ากลุ่มฟีเจอร์ G2 ที่ใช้ค่า HRV เนื่องจากสัญญาณ EDA

ส่งสัญญาณจากสมองไปยังต่อมเหงื่อ ผ่านตัวกลางอื่น ๆ มากมาย อย่างไรก็ตาม การใช้สัญญาณ EDA มีข้อได้เปรียบที่สามารถแสดงผลในลักษณะเรียลไทม์ได้ทันที ดังนั้นในโครงงานนี้จึงได้ใช้กลุ่มฟีเจอร์ G3 เป็นการนำคุณลักษณะส่วนบุคคลร่วมกับสัญญาณ EDA และค่า HRV เพื่อเพิ่มความแม่นยำในการทำนายระดับความเจ็บปวด โดยใช้โมเดล LightGBMซึ่งมีค่า F1-score ที่ 99.92% และแม้ว่าข้อมูลจะมีสัญญาณรบกวน หรือการขาดหายไปของข้อมูล ความความแม่นยำ และค่า F1-score ของโมเดล Catboost LightGBM และ XGBoost ก็ยังสามารถทำนายได้อย่างแม่นยำเหมือนเดิม โดยเปรียบเทียบจากค่า F1-score ของแต่ละโมเดล ดังภาพที่ 4.2

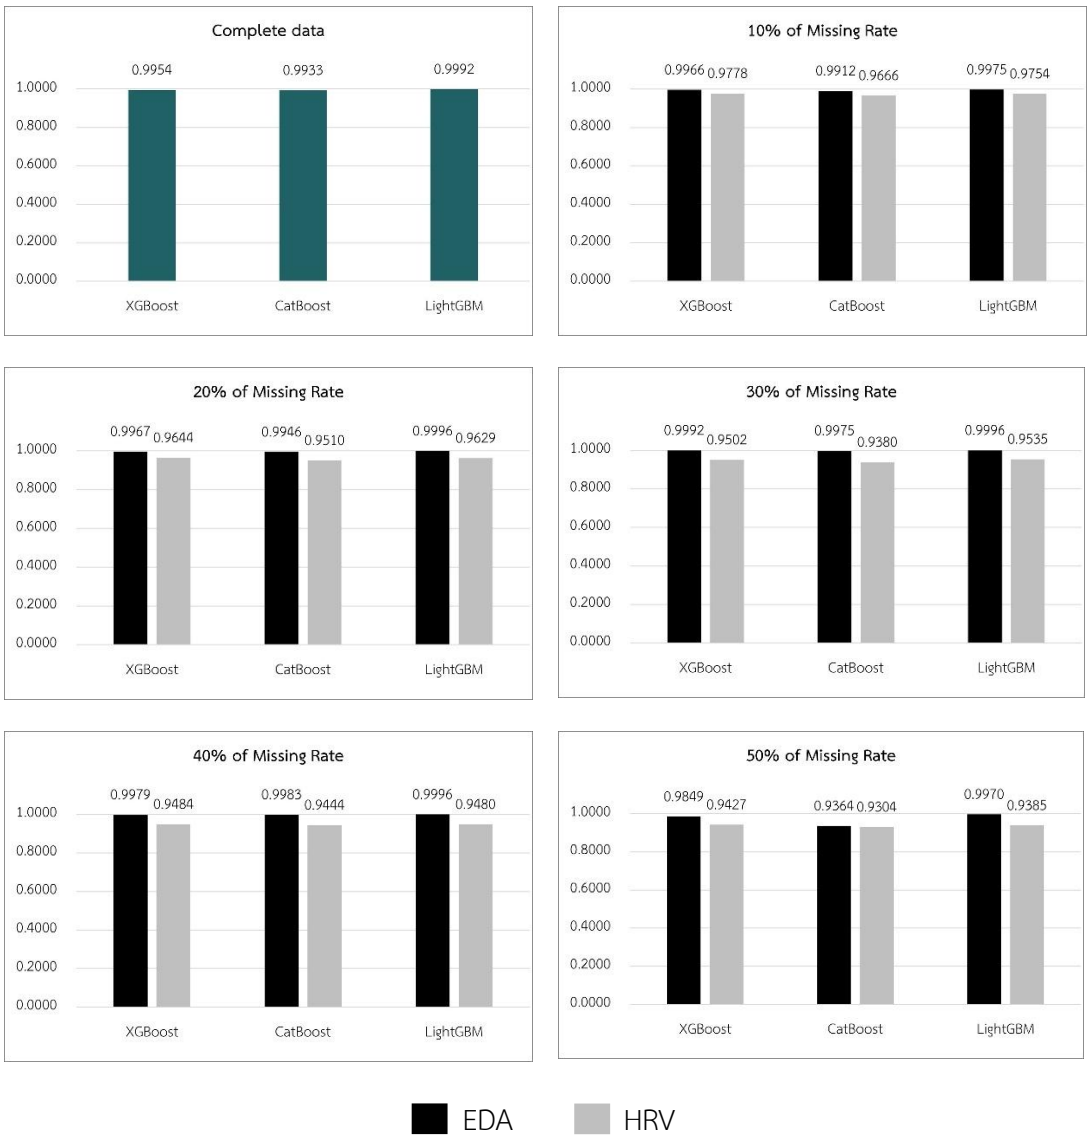

ภาพที่ 4.2 เทียบเปรียบจากค่า F1-score ของโมเดลในการทำนายระดับความเจ็บปวด

จากกราฟในภาพที่ 4.2 จะเห็นได้ว่าโมเดล XGBoost LightGBM และ Catboost สามารถทำนายระดับความเจ็บปวดโดยใช้สัญญาณทางสรีวิทยาในกลุ่มฟีเจอร์ G3 และมีประสิทธิภาพอยู่ใน

ระดับดีเยี่ยม ค่าเฉลี่ยของประสิทธิภาพโดยรวม F1-Score ของโมเดลแต่ละตัวลดลงอย่างไม่มีนัยสำคัญ ดังนี้

โมเดล CatBoost ใช้ชุดข้อมูลที่สมบูรณ์ (Complete data) มีค่า F1-Score 99.33% และเมื่อทดลองประสิทธิภาพของโมเดล โดยใช้ชุดข้อมูล Missing Value 10-50% ลดลงเพียงเล็กน้อย เช่น สัญญาณ EDA ลดลงจาก 99.12% เป็น 93.64% และค่า HRV ลดลงจาก 96.66% เป็น 93.04%

โมเดล LightGBM ใช้ชุดข้อมูล Complete data มีค่า F1-Score 99.92 % และเมื่อทดลองประสิทธิภาพของโมเดล โดยใช้ชุด Missing Value 10-50% ลดลงเพียงเล็กน้อย เช่น สัญญาณ EDA ลดลงจาก 99.75% เป็น 99.70% และค่า HRV เพิ่มจาก 97.54% เป็น 93.85%

โมเดล XGBoost ใช้ชุดข้อมูล Complete data มีค่า F1-Score 99.54% และเมื่อทดลองประสิทธิภาพของโมเดล โดยใช้ชุดข้อมูล Missing Value 10-50% ลดลงเพียงเล็กน้อย เช่น สัญญาณ EDA ลดลงจาก 99.66% เป็น 98.49% และค่า HRV ลดลงจาก 97.78% เป็น 94.27%

จะเห็นว่าทั้งสามโมเดลสามารถทำนายระดับความเจ็บปวด โดยยังคงประสิทธิภาพในระดับสูงแม้มีการขาดหายไปของข้อมูลในบางส่วน โดยเฉพาะอย่างอัลกอริทึม LightGBM โดยมีค่า F1-score ที่ 99.92 % ซึ่งสะท้อนให้เห็นถึงความยืดหยุ่นและความแม่นยำของโมเดลในการจัดการข้อมูลที่มีความซับซ้อนและมีขนาดใหญ่ จึงสามารถสรุปได้ว่าการนำสัญญาณทางสรีวิทยา EDA และ HRV ร่วมกับการเรียนรู้ของเครื่องสามารถประยุกต์ใช้ในการประเมินความเจ็บปวดแบบอัตโนมัติได้

บทที่ 5
สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินงาน

โครงงานนี้ได้เสนอการออกแบบและพัฒนาโมเดล ML สำหรับจำแนกระดับความเจ็บปวดที่มีความสัมพันธ์กับสัญญาณทางสรีรวิทยา ผู้จัดทำได้ออกแบบห้องทดลองเพื่อควบคุมปัจจัยที่ส่งผลต่อความเจ็บปวด ได้แก่ อุณภูมิห้อง อุณหภูมิเจลร้อนและเจลเย็น ร่วมกับการวิเคราะห์ข้อมูลระดับปัจเจกบุคคล ประกอบด้วย LFHF, Phasic, Tonic และ SKT โดยมีค่า P-Value น้อยกว่า 0.05 ซึ่งบ่งชี้ว่าคุณลักษณะดังกล่าวมีความสัมพันธ์กับระดับความเจ็บปวดอย่างมีนัยสำคัญ นอกจากนี้ยังคำนึงถึงคุณลักษณะส่วนบุคคล ได้แก่ เพศ อายุ ค่า BMI และเป็นบุคคลที่มีสุขภาพดี โดยจะนำคุณลักษณะดังกล่าวไปพัฒนาโมเดลการเรียนรู้ของเครื่อง

จากผลการประเมินประสิทธิภาพของโมเดลโดยใช้วิธี k-fold Cross Validation ซึ่งแบ่งข้อมูลออกเป็น 10ส่วน (k=10) เพื่อให้ผลการประเมินมีความน่าเชื่อถือ พบว่าโมเดลมีค่า F1-score 99.92% ซึ่งอยู่ในเกณฑ์ที่ดีมากแสดงให้เห็นถึงความสมดุลระหว่างค่า Precision และ Recall ผลการประเมินดังกล่าวบ่งชี้ว่าโมเดลมีประสิทธิภาพที่จะประยุกต์ใช้และนำไปต่อยอดในอนาคต เช่น การนำไปใช้ร่วมกับอุปกรณ์สวมใส่อัจฉริยะเพื่อติดตามและประเมินระดับความเจ็บปวด เพื่อช่วยในการเฝ้าระวังแนวโน้มที่จะเกิดความเจ็บปวดที่มากขึ้น ซึ่งช่วยในการดูแลและการตัดสินใจในการรักษาของเจ้าหน้าที่ทางการแพทย์ให้มีความแม่นยำและทันท่วงที

5.2 ปัญหาในการดำเนินงาน

5.2.1 การติดตั้งเซนเซอร์จากเครื่องขยายสัญญาณ BIOPAC MP36 สำหรับการเก็บข้อมูลทางสรีรวิทยา อาจมีขั้นตอนที่ซับซ้อน โดยเฉพาะในบริเวณข้อเท้า ซึ่งอาจมีปัจจัยที่รบกวนการวัดสัญญาณ เช่น การมีขนบริเวณหน้าแข้ง ดังนั้น จึงจำเป็นต้องกำจัดขนในบริเวณดังกล่าวก่อนการติดตั้งอิเล็กโทรดเพื่อเพิ่มความแม่นยำในการวัดสัญญาณทางสรีรวิทยา

5.2.2 การรับรู้ความเจ็บปวดที่แตกต่างกันของลักษณะเฉพาะบุคคล (Individual Variation) ทำให้ผู้เข้าร่วมการทดลองมีแนวโน้มรายงานระดับความเจ็บปวดสูงสุดจากความรู้สึกล่าสุด ส่งผลให้เกิดความไม่สมดุลของข้อมูล (Class Imbalance)

5.2.3 ระยะเวลาทดลองใช้เวลานาน (55นาที) อาจทำให้ผู้เข้าร่วมการทดลองเหนื่อยล้าหรือรู้สึกเบื่อหน่าย ส่งผลต่อการเปลี่ยนแปลงของสัญญาณทางสรีรวิทยาที่อาจไม่สะท้อนความเจ็บปวดที่แท้จริง

5.2.4 ขนาดของชุดข้อมูลมีจำนวนจำกัดและขาดความหลากหลายในช่วงอายุ ส่งผลต่อความครอบคลุมและความสามารถในการจำแนกของโมเดล

5.3 ข้อเสนอแนะ

5.3.1 ควรพัฒนาเกณฑ์การประเมินระดับความเจ็บปวดให้มีความชัดเจนและเป็นมาตรฐาน รวมถึงกำหนดช่วงเวลาในการประเมินที่เหมาะสม เพื่อให้ได้ข้อมูลที่สะท้อนระดับความเจ็บปวดที่แท้จริง

5.3.2 ควรกำหนดแนวทางการเตรียมความพร้อมของผู้เข้าร่วมการทดลองอย่างชัดเจน โดยเน้นการพักผ่อนที่เพียงพอและการปฏิบัติตามข้อกำหนดของการทดลองอย่างเคร่งครัด เพื่อให้ได้ข้อมูลที่มีคุณภาพสูง

5.3.3 ควรศึกษาตำแหน่งที่เหมาะสมสำหรับติดอิเล็กโทรดและติดเซนเซอร์ในการวัดสัญญาณ EDA และ ECG ที่สามารถใช้ได้ในทุกกลุ่มตัวอย่างเพื่อความแม่นยำและเป็นมาตรฐานเดียวกันในการเก็บข้อมูล

5.3.4 ควรควบคุมการทดลองให้เข้มงวดมากขึ้น เช่น การควบคุมสิ่งเร้าภายนอกระหว่างการทดลอง เพื่อลดสิ่งรบกวนที่อาจก่อให้เกิดความเบี่ยงเบนของข้อมูล (Bias) ในชุดข้อมูลได้

5.3.5 ควรกำหนด Hyperparameter อย่างรอบคอบเพื่อลด Bias ให้มากที่สุด

บรรณานุกรม

Albahdal, D., Aljebreen, W., & Ibrahim, D. M. (2024). PainMeter: Automatic Assessment of Pain Intensity Levels from Multiple Physiological Signals Using Machine Learning. *IEEE Access*, *12*, 48349–48365. https://doi.org/10.1109/ACCESS.2024.3384359

Aziz, S., Khan, M. U., Hirachan, N., Chetty, G., Goecke, R., & Fernandez-Rojas, R. (2023). "Where does it hurt?": Exploring EDA Signals to Detect and Localise Acute Pain. *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS*. https://doi.org/10.1109/EMBC40787.2023.10341157

Biopac. (n.d.). Retrieved October 1, 2024, from https://www.biopac.com/

Ghiasi, S., Greco, A., Barbieri, R., Scilingo, E. P., & Valenza, G. (2020). Assessing Autonomic Function from Electrodermal Activity and Heart Rate Variability During Cold-Pressor Test and Emotional Challenge. *Scientific Reports*, *10*(1). https://doi.org/10.1038/s41598-020-62225-2

Jiang, M., Rosio, R., Salanterä, S., Rahmani, A. M., Liljeberg, P., da Silva, D. S., de Albuquerque, V. H. C., & Wu, W. (2024). Personalized and adaptive neural networks for pain detection from multi-modal physiological features. *Expert Systems with Applications*, *235*. https://doi.org/10.1016/j.eswa.2023.121082

Kong, Y., Posada-Quintero, H. F., & Chon, K. H. (2021). Sensitive Physiological Indices of Pain Based on Differential Characteristics of Electrodermal Activity. *IEEE Transactions on Biomedical Engineering*, *68*(10), 3122–3130. https://doi.org/10.1109/TBME.2021.3065218

McGuire, D. B., Kaiser, K. S., Haisfield-Wolfe, M. E., & Iyamu, F. (2016). Pain Assessment in Noncommunicative Adult Palliative Care Patients. In *Nursing Clinics of North America* (Vol. 51, Issue 3, pp. 397–431). W.B. Saunders. https://doi.org/10.1016/j.cnur.2016.05.009

Strigo, I. A., Carli, F., & Bushnell, M. C. (2000). Effect of Ambient Temperature on Human Pain and Temperature Perception. In *Anesthesiology* (Vol. 92). http://pubs.asahq.org/anesthesiology/article-pdf/92/3/699/400183/0000542-200003000-00014.pdf

บรรณานุกรม (ต่อ)

Subramaniam, S. D., & Dass, B. (2021). Automated Nociceptive Pain Assessment Using Physiological Signals and a Hybrid Deep Learning Network. *IEEE Sensors Journal*, *21*(3), 3335–3343. https://doi.org/10.1109/JSEN.2020.3023656

Susam, B., Riek, N., Akcakaya, M., Xu, X., De Sa, V., Nezamfar, H., Diaz, D., Craig, K., Goodwin, M., & Huang, J. (2022). Automated Pain Assessment in Children Using Electrodermal Activity and Video Data Fusion via Machine Learning. *IEEE Transactions on Biomedical Engineering*, *69*(1), 422–431. https://doi.org/10.1109/TBME.2021.3096137

Tashani, O. A., Astita, R., Sharp, D., & Johnson, M. I. (2017). Body mass index and distribution of body fat can influence sensory detection and pain sensitivity. *European Journal of Pain (United Kingdom)*, *21*(7), 1186–1196. https://doi.org/10.1002/ejp.1019

Winslow, B. D., Kwasinski, R., Whirlow, K., Mills, E., Hullfish, J., & Carroll, M. (2022a). Automatic detection of pain using machine learning. *Frontiers in Pain Research*, *3*. https://doi.org/10.3389/fpain.2022.1044518

Winslow, B. D., Kwasinski, R., Whirlow, K., Mills, E., Hullfish, J., & Carroll, M. (2022b). Automatic detection of pain using machine learning. *Frontiers in Pain Research*, *3*. https://doi.org/10.3389/fpain.2022.1044518

Zhi, Y., Zhang, Y., Zhang, Y., Zhang, M., & Kong, Y. (2024). Age-associated changes in multimodal pain perception. *Age and Ageing*, *53*(5). https://doi.org/10.1093/ageing/afae107

ภาคผนวก

ภาคผนวก ก

เอกสารรับรองโครงการวิจัยในมนุษย์ คณะกรรมการจริยธรรมการวิจัยในมนุษย์

1. เอกสารฉบับภาษาไทย

WUF06-09/1.0 May, 2021

เอกสารรับรองโครงการวิจัยในมนุษย์
คณะกรรมการจริยธรรมการวิจัยในมนุษย์ มหาวิทยาลัยวลัยลักษณ์
222 ตำบลไทยบุรี อำเภอท่าศาลา จังหวัดนครศรีธรรมราช 80160

รหัสโครงการ WU-EC-IN-0-273-67

ชื่อโครงการ

วิธีการตรวจจับความเจ็บปวดแบบรายบุคคลโดยอาศัยสัญญาณทางสรีรวิทยาด้วยเทคโนโลยีแบบสวมใส่

เลขที่เอกสารรับรอง

WUEC-24-287-01

ชื่อหัวหน้าโครงการ

ผู้ช่วยศาสตราจารย์ ดร.บูคอรี ซาเหาะ และนายเดชธนา อรัญชัยยะ

สังกัด หน่วยงาน

สำนักวิชาสารสนเทศศาสตร์ มหาวิทยาลัยวลัยลักษณ์

ระยะเวลาที่รับรอง 1 ปี

ตั้งแต่วันเดือนปี 19 สิงหาคม 2567 **ถึงวันเดือนปี** 18 สิงหาคม 2568

เอกสารที่ได้รับการรับรอง

1. เอกสารโครงร่างการวิจัย
2. เอกสารชี้แจงผู้เข้าร่วมโครงการวิจัย
3. เอกสารยินยอมการเข้าร่วมโครงการวิจัย
4. เอกสารเครื่องมือวิจัย

ขอรับรองว่าโครงการวิจัยดังกล่าวข้างต้นได้ผ่านการพิจารณาเห็นชอบโดยสอดคล้องกับคำปฏิญญาเฮลซิงกิ จากคณะกรรมการจริยธรรมการวิจัยในมนุษย์ มหาวิทยาลัยวลัยลักษณ์

ลงนาม.....
(รองศาสตราจารย์ ดร.ชูชาติ พันธ์สวัสดิ์)
ประธานคณะกรรมการจริยธรรมการวิจัยในมนุษย์

ลงนาม.....
(ศาสตราจารย์ ดร.สมบัติ ธำรงธัญวงศ์)
รักษาการแทนอธิการบดีมหาวิทยาลัยวลัยลักษณ์
รับรอง ณ วันที่ 19 สิงหาคม 2567

2. เอกสารฉบับภาษาอังกฤษ

WUF06-09/1.0 May, 2021

CERTIFICATE OF ETHICAL APPROVAL

Ethics Committee in Human Research Walailak University

222 Thaiburi, Thasala District, Nakhon Si Thammarat 80160, Thailand

Project No. WU-EC-IN-0-273-67

Title of Project :

Individual Pain Detection Approach based on Physiological Signals using Wearable Technology

Approval Number :

WUEC-24-287-01

Principal Investigator :

Assistant Professor Dr.Bukhoree Sahoh and Mr. Dechthana Arunchaiya

Official Address :

School of Informatics, Walailak University, 222 Thaiburi, Thasala District, Nakhon Si Thammarat 80160, Thailand

This Project has been approved for one year

From 19 August 2024 **to** 18 August 2025

Approval

1. Research Proposals
2. Participant Information Sheet
3. Informed Consent Form
4. Research Tools

The aforementioned project and informed consent have been reviewed and approved by Ethics Committee in Human Research Walailak University, based on the Declaration of Helsinki

Signature.....Chuchard Punsawad.....

(Associate Professor Chuchard Punsawad Ph.D)

Chairman of the Ethics Committee in Human Research Walailak University

Signature.....S. Thamrong.....

(Professor Sombat Thamrongthanyawong Ph.D)

Acting President of Walailak University

Approval Date 19 August 2024

ภาคผนวก ข

ผู้จัดทำโครงงานได้จัดทำแบบฟอร์มเพื่อใช้ในการเก็บรวบรวมข้อมูลส่วนบุคคลของผู้เข้าร่วมการทดลอง ซึ่งประกอบด้วยข้อมูลเกี่ยวกับเพศ อายุ น้ำหนัก ส่วนสูง ข้อมูลเกี่ยวกับการพักผ่อนและกิจกรรมที่กระทำก่อนการเริ่มต้นการทดลอง รวมถึงแบบสอบถามเกี่ยวกับระดับความเจ็บปวดของผู้เข้าร่วมการทดลอง ทั้งนี้ ข้อมูลดังกล่าวจะถูกนำมารวมกับชุดข้อมูลที่ได้จากสัญญาณทางสรีรวิทยา โดยข้อมูลที่ได้จากแบบสอบถามระดับความเจ็บปวดจะถูกใช้เป็นผลเฉลย (Label) สำหรับชุดข้อมูลในส่วนของแบบสอบถามระดับความเจ็บปวดนั้น ประกอบด้วยคำถามที่มุ่งเน้นการประเมินความรู้สึกเจ็บปวดของผู้เข้าร่วมการทดลอง โดยมีรายละเอียดของคำถามดังต่อไปนี้

หัวข้อแบบสอบถาม : แบบประเมินการเก็บข้อมูลผู้เข้าร่วมทดลอง Pain Management
คำชี้แจ้ง : แบบสอบถามนี้จัดทำขึ้นเพื่อเก็บข้อมูลการทดลองเพื่อนำไปศึกษาและพัฒนาโมเดลเพื่อจำแนกระดับความเจ็บปวดอัตโนมัติ เพื่อช่วยเหลือผู้ป่วยที่ไม่สามารถสื่อสารได้ โดยการใช้ Machine Learning รวมกับสัญญาณทางสรีรวิทยาและข้อมูลส่วนบุคคล

ส่วนที่ 1 ข้อมูลส่วนตัวของผู้เข้าร่วมทดลอง

1.1 เพศกำเนิด ☐ ชาย ☐ หญิง
1.2 อายุ .....ปี
1.3 น้ำหนัก .....กิโลกรัม
1.4 ส่วนสูง .....เซนติเมตร

ส่วนที่ 2 ข้อมูลการพักผ่อนและกิจกรรมก่อนเริ่มการทดลอง
โปรดใส่เครื่องหมาย ✓ ลงในช่อง ☐

ข้อมูลการพักผ่อนและกิจกรรมก่อนเริ่มการทดลอง	
2.1 คุณนอนหลับพักผ่อนดีเพียงใดในคืนก่อนเข้าร่วมการทดสอบ	☐ แย่มาก ☐ แย่ ☐ ปานกลาง ☐ ดี ☐ ดีมาก
2.2 คุณได้ดื่มเครื่องดื่มที่มีคาเฟอีนหรือไม่ (เช่น กาแฟ ชา เครื่องดื่มเอนเนอร์จี้) ภายใน 2 ชั่วโมงก่อนเริ่มการทดสอบ	☐ ใช่ ☐ ไม่ใช่

ข้อมูลการพักผ่อนและกิจกรรมก่อนเริ่มการทดลอง	
2.3 คุณได้ดื่มเครื่องดื่มแอลกอฮอล์ในคืนก่อนการทดสอบครั้งนี้หรือไม่	☐ ใช่ ☐ ไม่ใช่
2.4 คุณได้รับประทานอาหารโซเดียมสูง (เช่น อาหารสำเร็จรูปแปรรูป หมักดอง ขนมขบเคี้ยว)	☐ ใช่ ☐ ไม่ใช่
2.5 สภาพร่างกายของคุณในวันนี้เป็นอย่างไร	☐ แย่มาก ☐ แย่ ☐ ปานกลาง ☐ ดี ☐ ดีมาก

ส่วนที่ 3 ประเมินระดับความเจ็บปวดหลังกระตุ้นด้วยความร้อนและความเย็น

ระดับความเจ็บปวด ระดับ 0 หมายถึง ไม่มีความเจ็บปวด

ระดับ 1 หมายถึง มีความเจ็บปวดเล็กน้อย

ระดับ 2 หมายถึง มีความเจ็บปวดปานกลาง

ระดับ 3 หมายถึง มีความเจ็บปวดมาก

โปรดใส่เครื่องหมาย ✓ ลงในช่องที่ตรงกับระดับความเจ็บปวดของผู้เข้าร่วมการทดลอง

รายการประเมิน	ระดับความเจ็บปวด			
	0	1	2	3
ระดับความเจ็บที่กระตุ้นด้วยความร้อน				
ระดับความเจ็บที่กระตุ้นด้วยความเย็น				

ภาคผนวก ค

โครงงานนี้มุ่งเน้นการศึกษาเกี่ยวกับการประเมินการรับรู้ความเจ็บปวด โดยใช้ค่าทางสถิติพื้นฐาน ได้แก่ ค่าต่ำสุด (Minimum: Min), ค่าสูงสุด (Maximum: Max) และ ค่าเฉลี่ย (Mean) ซึ่งได้จากข้อมูลทางสรีรวิทยาและคุณลักษณะส่วนบุคคล การวิเคราะห์ค่าสถิติเหล่านี้ช่วยสะท้อนถึงการกระจายตัวและลักษณะของความเจ็บปวดในแต่ละกรณี ข้อมูลที่ได้สามารถนำไปใช้เป็นพื้นฐานสำหรับการพัฒนาและประยุกต์ใช้ระบบประเมินความเจ็บปวดแบบอัตโนมัติ เพื่อเพิ่มประสิทธิภาพในการวิเคราะห์และวินิจฉัยทางการแพทย์ต่อไปได้ในอนาคต

ตาราง ค่าทางสถิติพื้นฐานของข้อมูลทางสรีรวิทยาและคุณลักษณะส่วนบุคคล

Feature	Description	Min	Mean	Max	Unit
Phasic	สัญญาณทางสรีรวิทยาที่เกี่ยวข้องโดยตรงกับการทำงานของระบบ SNS แสดงถึงการตอบสนองแบบฉับพลันต่อสิ่งเร้า	0.00	2.14	25.98	μS
Tonic	สัญญาณทางสรีรวิทยามีความเกี่ยวข้องโดยตรงกับการทำงานของระบบ PNS สะท้อนถึงการเปลี่ยนแปลงในระยะยาว	1.23	35.51	71.83	μS
HF	ความผันแปรของอัตราการเต้นของหัวใจ เป็นตัวบ่งชี้ที่สัมพันธ์กับการทำงานของระบบ PNS	0.00	0.05	0.15	ms^2
LF	ความผันแปรของอัตราการเต้นของหัวใจ เป็นตัวบ่งชี้ที่สัมพันธ์กับการทำงานของระบบ PNS และ SNS	0.00	0.02	0.07	ms^2
LF/HF	อัตราส่วนระหว่าง LF ต่อ HF เป็นตัวบ่งชี้สมดุลอัตโนมัติระหว่างระบบ PNS และ SNS	0.17	1.29	5.68	Ratio
SKT	อุณหภูมิของผิวหนังที่สะท้อนการเปลี่ยนแปลงของการไหลเวียนเลือดและการควบคุมอุณหภูมิของร่างกาย โดยได้รับอิทธิพลจากปัจจัยภายในและภายนอกร่างกาย	28.05	34.78	38.89	°C
BMI	ค่าดัชนีมวลกายเป็นตัวบ่งชี้ภาวะน้ำหนักตัวสัมพันธ์กับสุขภาพ เช่น ผอม ปกติ น้ำหนักเกินและอ้วน	15.10	21.55	33.40	(kg/m^2)

ประวัติผู้จัดทำ

ชื่อผู้จัดทำ	ทิชานนท์ ทรงเลิศ
รหัสประจำตัว	65103533
สำนักวิชา	สารสนเทศศาสตร์
	สาขา นวัตกรรมสารสนเทศทางการแพทย์
วันเดือนปีเกิด	3 กรกฎาคม พ.ศ.2546
ที่อยู่	231/6 หมู่ 8 ตำบลโพธิ์ทอง อำเภอท่าศาลา
	จังหวัดนครศรีธรรมราช 80160

ชื่อผู้จัดทำ	อานิต้า อิสสภาพ
รหัสประจำตัว	65133646
สำนักวิชา	สารสนเทศศาสตร์
	สาขา นวัตกรรมสารสนเทศทางการแพทย์
วันเดือนปีเกิด	5 ธันวาคม พ.ศ.2546
ที่อยู่	152/9 หมู่ 14 ตำบลท่าศาลา อำเภอท่าศาลา
	จังหวัดนครศรีธรรมราช 80160